Statistik I für Cognitive Science und Wirtschaftswissenschaften

– Wintersemester 2025/2026 –

Dozent: Prof. Dr. Frank Aurzada
Fachbereich Mathematik, TU Darmstadt

Das vorliegende **Vorlesungsskript** basiert auf einer Vorlage von Prof. Dr. W. Stannat, mit Überarbeitungen und Erweiterungen durch Dr. C.H. Weiß, Prof. Dr. F. Aurzada und PD Dr. C. Wichelhaus.

Korrekturvorschläge bitte per E-Mail an: `aurzada@mathematik.tu-darmstadt.de`

Stand: 15. September 2025

Inhaltsverzeichnis

I Deskriptive Statistik **5**
I.1 Grundbegriffe . . . 5
I.2 Analyse eindimensionaler Datensätze . . . 7
I.2.1 Absolute und relative Häufigkeiten . . . 7
I.2.2 Kumulierte Häufigkeitsverteilung . . . 10
I.2.3 Lagemaße . . . 11
I.2.4 Quantile und Box-Plots . . . 14
I.2.5 Streuungsmaße . . . 15
I.2.6 Konzentration von Häufigkeitsverteilungen . . . 17
I.3 Analyse zwei- und mehrdimensionaler Datensätze . . . 19
I.3.1 Kontingenztabelle . . . 19
I.3.2 Ergänzung: Der Kontingenzkoeffizient . . . 22
I.3.3 Streuungsdiagramm und Korrelation . . . 22
I.3.4 Lineare Regression . . . 24
I.3.5 Ergänzung: Nichtlineare Regression . . . 26

II Wahrscheinlichkeitsrechnung **28**
II.1 Zufallsexperimente und Wahrscheinlichkeitsräume . . . 28
II.1.1 Zufällige Ereignisse . . . 28
II.1.2 Wahrscheinlichkeitsmaße . . . 29
II.1.3 Wahrscheinlichkeitsmaße und Wahrscheinlichkeitsfunktionen . . . 30
II.1.4 Laplacescher Wahrscheinlichkeitsraum und Urnenmodelle . . . 31
II.1.5 Bedingte Wahrscheinlichkeiten . . . 33
II.1.6 Unabhängigkeit . . . 36
II.2 Zufallsvariablen und Verteilungen . . . 37
II.2.1 Das Konzept der Zufallsvariablen . . . 37
II.2.2 Die Verteilungsfunktion einer Zufallsvariablen . . . 38
II.2.3 Unabhängigkeit von Zufallsvariablen . . . 38
II.2.4 Spezielle Verteilungen . . . 39
II.2.5 Die wichtigsten diskreten Verteilungen im Überblick . . . 45
II.3 Erwartungswert und Varianz . . . 46
II.3.1 Erwartungswert . . . 46
II.3.2 Varianz . . . 48
II.3.3 Ergänzung: Die Ungleichung von Tschebyschow . . . 50
II.3.4 Kovarianz und Korrelation . . . 51
II.4 Stetige Verteilungen . . . 53
II.4.1 Stetige Verteilungen: Dichte und Verteilungsfunktion . . . 53
II.4.2 Stochastische Unabhängigkeit . . . 54
II.4.3 Erwartungswert, Varianz und Kovarianz . . . 54
II.4.4 Wichtige stetige Verteilungen . . . 56
II.4.5 Weitere Eigenschaften normalverteilter Zufallsvariablen . . . 58
II.4.6 Ergänzung: Normalverteilung: k-σ-Bereiche . . . 59
II.4.7 Aus der Normalverteilung abgeleitete Verteilungen . . . 60
II.5 Grenzwertsätze . . . 63
II.5.1 Das Gesetz der großen Zahlen . . . 63
II.5.2 Der Hauptsatz der Statistik (Satz von Glivenko-Cantelli) . . . 64
II.5.3 Der zentrale Grenzwertsatz . . . 65
II.5.4 Der Satz von de Moivre-Laplace . . . 65

III Induktive Statistik **67**
III.1 Schätzen 67
III.1.1 Punktschätzer 67
III.1.2 Prinzipien zur Konstruktion von Schätzern 71
III.1.3 Intervall-Schätzungen 73
III.2 Testen 77
III.2.1 Grundlagen aus der Testtheorie 77
III.2.2 Ein-Stichproben-Tests 80
III.2.3 Ergänzung: P-Werte und Gütefunktion 81
III.2.4 Ergänzung: Tests basierend auf Häufigkeiten 84
III.2.5 Ergänzung: Mehr-Stichproben-Tests 86
III.2.6 Ergänzung: Bivariate Normalverteilung und Korrelationstest 89
III.2.7 Ergänzung: Nichtparametrische Testverfahren 90

I Deskriptive Statistik

I.1 Grundbegriffe

Die **deskriptive Statistik** oder auch **beschreibende Statistik** beschäftigt sich mit der Aufbereitung von Daten, die im Rahmen von Erhebungen, wie zum Beispiel Volkszählungen und Umfragen, oder bei Messungen gewonnen werden. Erhoben werden **Merkmale** wie zum Beispiel Alter, Geschlecht, Einkommen, Temperatur oder Druck. Die **Merkmalsausprägungen** sind die Gesamtheit der möglichen Werte eines Merkmals.

Unterschieden werden Merkmale nach **qualitativen Merkmalen** (wie Geschlecht, Nationalität oder Beruf) und **quantitativen Merkmalen**, die man ihrerseits nochmals in **diskrete** Merkmale (etwa Alter und Einkommen) und **stetige** Merkmale (etwa Temperatur und Geschwindigkeit) unterteilt.

Beispiele für Merkmalsarten und deren Merkmalsausprägungen:

> Geschlecht: männlich, weiblich, divers.
>
> Alter: $0, 1, 2, 3, \ldots$
>
> Temperatur: die reellen Zahlen $\mathbb{R}$ oder Teilmengen der reellen Zahlen.

Als **Merkmalsträger** bezeichnet man die für die Erhebung der Daten relevanten Objekte. Das sind also zum Beispiel bei einer Umfrage die Menge der relevanten Personen. Die Gesamtheit der für eine statistische Erhebung relevanten Merkmalsträger heißt **Grundgesamtheit**.

Bei Erhebungen unterscheidet man zwischen einer **Vollerhebung**, bei der alle Merkmalsträger der Grundgesamtheit erfasst werden (etwa Volkszählung) und einer **Teilerhebung** oder **Stichprobenerhebung**, bei der nur eine zufällig gewonnene Teilmenge der Grundgesamtheit erfasst wird, wie es bei Umfragen der Fall ist.

Bei der Erhebung statistischer Daten unterscheidet man zwischen

- Befragung (z. B. Umfrage, Volkszählung),
- Beobachtung (z. B. Verkehrszählung, Messung, ...),
- Experiment (Messung im „physikalischen“ Experiment).

Bei der **Teilerhebung** statistischer Daten wird die **Stichprobenauswahl** entscheidend: Von welchen Merkmalsträgern werden die Daten erhoben? Neben **willkürlicher** Auswahl gibt es hierzu Stichprobentechniken.

Beispiel: Quotenauswahl.

Bei der Auswahl achtet man darauf, dass bestimmte Merkmalsausprägungen in der Teilgesamtheit dieselbe relative Häufigkeit besitzen wie in der Grundgesamtheit. Man spricht dann von einer „repräsentativen“ Auswahl, im Zusammenhang mit Umfragen etwa von einer repräsentativen Umfrage.

Merkmalstypen, Skalierung, Klassierung

Wir haben bereits die Unterscheidung zwischen quantitativen und qualitativen Merkmalen angesprochen. Durch **Quantifizierung** kann ein qualitatives Merkmal in ein quantitatives umgewandelt werden, z.B.:

„grün“	$= 23$	oder	„Europa“	$= 3$
„blau“	$= 14$		„Asien“	$= 1$

Skalierung
Bei den Merkmalen spielt die Skalierung eine wichtige Rolle. Man unterscheidet folgende Skalen:

Nominalskala: Die zugeordneten Zahlen dienen lediglich zur Unterscheidung der Merkmalsausprägungen.

Beispiele: Farben, Automarken, Steuerklassen.

Ordinalskala, Rangskala: Die Merkmalsausprägungen werden zueinander in einer Rangfolge in Beziehung gesetzt („natürliche Ordnung“).

Beispiele: Schadstoffklassen, Schulabschlüsse, Nachnamen nach ABC sortiert.

Kardinalskala, Metrische Skala: Zusätzlich zur Rangfolge spielt auch noch die Größe des Abstandes zwischen zwei Merkmalsausprägungen eine Rolle.

Beispiele: Temperatur, Einkommen, Alter, Schulnoten, Gewicht, Geschwindigkeit.

Klassierung
Ein stetig verteiltes Merkmal kann durch die **Aufteilung** der Merkmalsausprägungen **in Teilintervalle (Klassen)** in ein diskretes Merkmal überführt werden (siehe auch Abschnitt I.2.1).

Beispiel:

			$< 160\,\text{cm}$	$180 \ldots 189\,\text{cm}$
„Körpergröße in cm“	$\longrightarrow$	„Klassen“	$160 \ldots 169\,\text{cm}$	$190 \ldots 199\,\text{cm}$
			$170 \ldots 179\,\text{cm}$	$\geq 200\,\text{cm}$

I.2 Analyse eindimensionaler Datensätze

Die Gesamtheit der Daten aus der statistischen Erhebung bezeichnet man als **Urliste**. Wird nur ein Merkmal erhoben, so kann man die erhobenen Merkmalswerte als eindimensionale Folge aufschreiben (**univariate Daten**):

$$x_1, x_2, x_3, \ldots, x_n.$$

Auf diese Weise erhält man eine **Stichprobe der Länge** n. Alternativ spricht man auch von einer **Messreihe**, ferner statt von Merkmalswerten auch von **Messwerten** oder **Beobachtungen**.

Beispiel: Gesamtleistung einer Photovoltaikanlage in einem konkreten Jahr (Monatswerte in kWh):

130.6 344.7 458.9 721.6 739.0 779.7 910.8 797.3 578.9 298.5 138.1 99.7

I.2.1 Absolute und relative Häufigkeiten

Betrachten wir zunächst den Fall, dass es nur endlich viele mögliche Merkmalsausprägungen gibt, diese seien $a_1, a_2, \ldots, a_t$. Die Anzahl der Merkmalswerte $x_1, \ldots x_n$, die mit a_j übereinstimmen, heißt **absolute Häufigkeit** von a_j und wird mit n_j bezeichnet ($j = 1, \ldots, t$).

Der Anteil

$$f_j := \frac{n_j}{n} \qquad \text{für } j = 1, \ldots, t$$

des Merkmalswertes a_j an der Gesamtzahl n der erhobenen Merkmalswerte heißt **relative Häufigkeit**. An den relativen Häufigkeiten kann man insbesondere sofort die Prozentanteile ablesen.

Offenbar gilt:

$$\sum_{j=1}^{t} n_j = n \qquad \text{und} \qquad \sum_{j=1}^{t} f_j = 1.$$

Grafische Darstellungen der Häufigkeitsverteilung

Die gängigen grafischen Darstellungen von Häufigkeitsverteilungen sind

- Tabellen,
- Stabdiagramme und Histogramme,
- Kreisdiagramme.

Beispiel: Stimmenverteilung bei der Bundestagswahl 2021.

Das erhobene Merkmal ist in diesem Falle die mit der Zweitstimme gewählte Partei. Eine Beobachtungseinheit ist ein Stimmzettel. Die Gesamtheit der Merkmalswerte sind die zur Wahl stehenden Parteien, also SPD, CDU, CSU, usw. Um die Darstellung zu vereinfachen, sind die weniger häufig gewählten Parteien in der Klasse „Sonstige“ zusammengefasst. Die Anzahl n der Beobachtungseinheiten ist gleich der Anzahl der gültigen Zweitstimmen, in diesem Falle $n = 46\ 442\ 023$.

Häufigkeitstabelle

In der Häufigkeitstabelle werden die ermittelten absoluten und/oder relativen Häufigkeiten tabellarisch erfasst.

Partei	Zweitstimmen (n_j)	Anteil in Prozent ($f_j \cdot 100\,\%$)
CDU	8 775 471	18.9 %
SPD	11 955 434	25.7 %
AfD	4 803 902	10.3 %
FDP	5 319 952	11.5 %
DIE LINKE	4 297 270	9.24 %
GRÜNE	2 270 906	4.9 %
CSU	2 402 827	5.2 %
Sonstige	4 061 325	8.7 %

Stabdiagramm

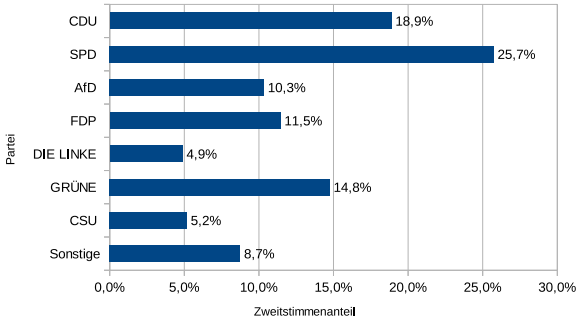

Kreisdiagramm

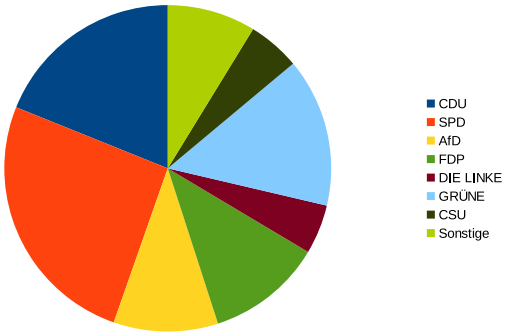

Bei stetigen oder quasistetigen Merkmalen ist die Aufstellung einer Häufigkeitstabelle oder eines Stabdiagramms sinnlos, denn die meisten Werte sind nur einfach oder gar nicht besetzt. Wir erklären im folgenden, wie man stetige Merkmale durch Klassierung („Vergröberung“) in diskrete Merkmale überführen kann.

Beispiel: Erreichte Punkte in den Abgaben der Übungen zur Vorlesung „Einführung in die Stochastik“ (die Matrikelnummern dienen ausschließlich der Illustration):

Matrikelnummer	Punkte in Hausübungen
3406435	65.5
3407234	115
3408908	130
3409043	121.5
$\vdots$	$\vdots$
6373034	0

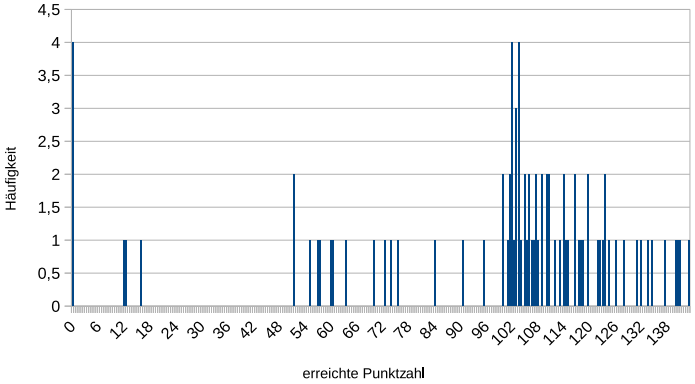

Ein Ausweg liefert hier die **Klassierung**, siehe auch Abschnitt I.1. Wähle Intervalle (Klassen)

$$[z_1; z_2),\ [z_2; z_3),\ [z_3; z_4),\ \ldots,\ [z_r; z_r)$$

und zähle die Häufigkeit des Auftretens von Beobachtungen in der Klasse. Bei der Wahl der Anzahl der Klassen ist allerdings zu beachten, dass

- bei zu großer Klassenanzahl viele Klassen unbesetzt bleiben,
- bei zu geringer Klassenanzahl Information verloren geht.

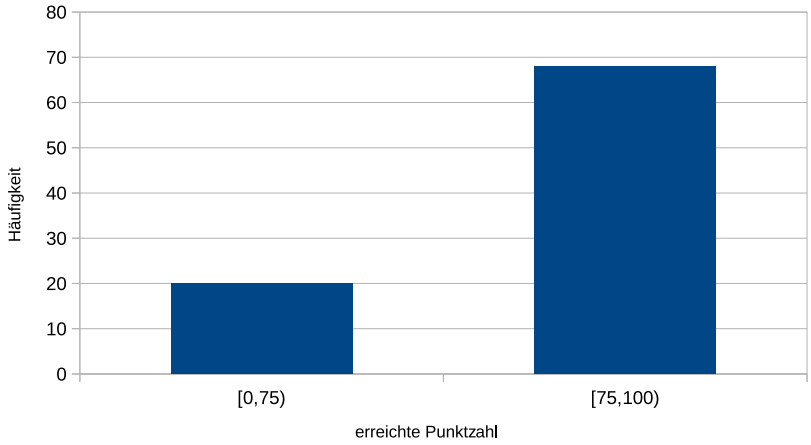

Eine populäre **Faustregel** empfiehlt, dass die Anzahl der Klassen in etwa $\sqrt{n}$ entsprechen sollte, wobei n die Anzahl der Beobachtungen ist.
In obigem Beispiel: $n = 88$, wähle 9 Klassen ($\sqrt{88} \approx 9.3$) der Form

$$[z_1; z_2),\ [z_2; z_3),\ [z_3; z_4),\ \ldots, [z_8; z_9),\ [z_9; z_{10})$$

mit $z_1 = 0$, $z_2 = 16$, $z_3 = 32$, ..., $z_9 = 128$, $z_{10} = 144$.

Dies ergibt die Häufigkeitstabelle:

Punkte	[0,16)	[16,32)	[32,48)	[48,64)	[64,80)	[80,96)	[96,112)	[112,128)	[128,144)
Anzahl	6	1	0	9	5	3	34	20	10

Als Repräsentanten der Klasse $[z_j; z_{j+1})$ wählt man häufig die Klassenmitte $(z_j + z_{j+1})/2$.

Im Falle klassierter Daten bezeichnet man die Anzahl n_j der Beobachtungseinheiten in der Klasse $[z_j; z_{j+1})$ auch als **Klassenhäufigkeit** oder **Besetzungszahl**. Den zugehörigen relativen Anteil

$$f_j := \frac{n_j}{n}$$

bezeichnet man als **relative Klassenhäufigkeit**.

Graphische Darstellung klassierter Daten mit Histogrammen.

Zur grafischen Darstellung klassierter Daten eignen sich (wieder) **Histogramme** (vgl. Stabdiagramme). Die Länge der Klassen $[z_1; z_2), [z_2; z_3), \ldots$ muss nicht notwendig gleich gewählt werden. Dies muss aber in der Darstellung deutlich werden. Errichte über jedem Teilintervall $[z_j; z_{j+1})$ ein Rechteck mit der Fläche f_j, die Höhe d_j des Rechtecks errechnet sich gemäß

$$d_j \cdot (z_{j+1} - z_j) \ = \ f_j.$$

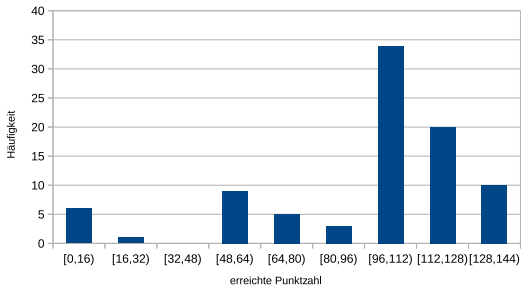

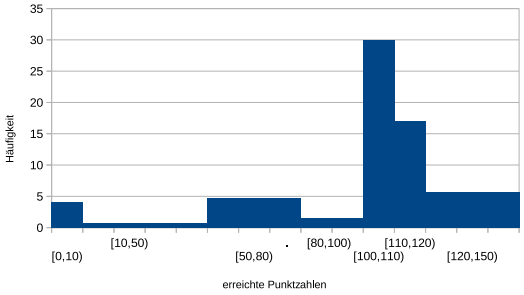

Abbildung: Stabdiagram für die klassierten Daten bzw. Histogramm bei nicht notwendig gleicher Klassenbreite (Bemerkung: Die Höhe der Rechtecke im rechten Bild ist f_j multipliziert mit $n = 88$, um eine aussagekräftigere Skalierung zu erreichen)

Beachte: Bei **gleicher Klassenbreite** ist **auch die Höhe** der Rechtecke proportional zur relativen Klassenhäufigkeit f_j.

I.2.2 Kumulierte Häufigkeitsverteilung

Die Funktion

$$H(x) \;:=\; \sum_{j:a_j \le x} n_j \qquad \text{für } x \in \mathbb{R}$$

heißt **absolute kumulierte Häufigkeitsverteilung**. Sie zählt zu gegebenem $x \in \mathbb{R}$ die Anzahl jener Beobachtungswerte, welche kleiner gleich x sind.
Die Funktion

$$F(x) \;:=\; \frac{1}{n} \cdot H(x) \;=\; \sum_{j:a_j \le x} f_j \qquad \text{für } x \in \mathbb{R}$$

heißt relative kumulierte Häufigkeitsverteilung oder **empirische Verteilungsfunktion**.

Eigenschaften der empirischen Verteilungsfunktion:

- F ist eine monoton wachsende Treppenfunktion;
- $0 \le F \le 1$;
- F besitzt Sprünge an den Merkmalsausprägungen a_j.

Beispiel: Ein Klausurergebnis könnte wie folgt aussehen:

Note	abs. Häuf. (n_j)	Anteil ($f_j \cdot 100\,\%$)	kumulierter Anteil
1.0	17	19.3 %	19.3 %
1.3	5	5.7 %	25.0 %
1.7	5	5.7 %	30.7 %
2.0	5	5.7 %	36.4 %
2.3	2	2.3 %	38.6 %
2.7	8	9.1 %	47.7 %
3.0	4	4.6 %	52.2 %
3.3	7	8.0 %	60.2 %
3.7	5	5.7 %	65.9 %
4.0	1	1.1 %	67.0 %
5.0	29	33.0 %	100 %

Empirische Verteilungsfunktion im Beispiel Klausurergebnis:

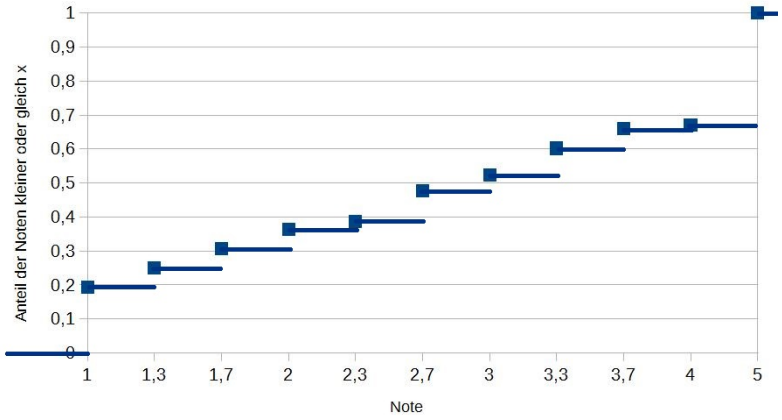

I.2.3 Lagemaße

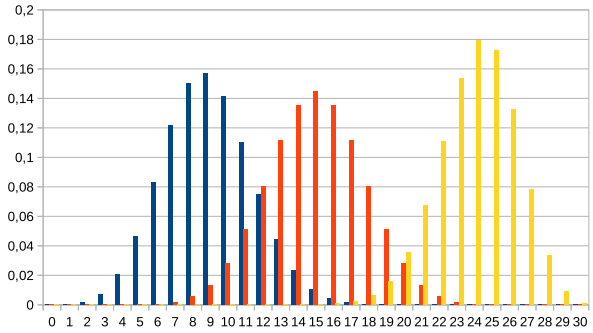

Im Folgenden bezeichne $x_1, \ldots, x_n$ stets die Urliste. Falls stattdessen nur klassierte Daten $a_1, \ldots, a_t$ (Repräsentanten) vorliegen, so bezeichne f_j die zu a_j gehörige relative Häufigkeit.

Modalwert: x_{Mod}.

Diejenigen Ausprägungen a_j mit der größten Häufigkeit werden als **Modalwerte** bezeichnet. Die Verwendung des Modalwertes zur Beschreibung von Datensätzen sollte auf den Fall unimodaler Verteilungen, bei denen es genau einen Modalwert gibt, beschränkt bleiben. Zur Illustration dienen die folgenden Grafiken.

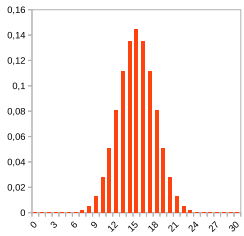

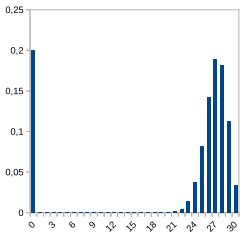

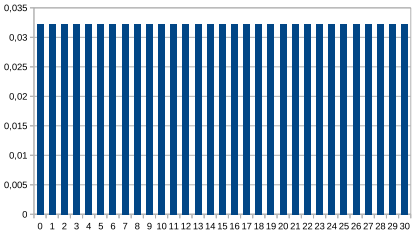

Median: x_{Med}.

Der **Median** (oder auch Zentralwert) ein spezieller Wert x_{Med}, für den mindestens 50 % aller Merkmalswerte kleiner gleich x_{Med} und mindestens 50 % aller Merkmalswerte größer gleich x_{Med} sind. Es kann mehrere Werte mit dieser Eigenschaft geben, der Median ist ein spezieller davon. Er wird wie folgt definiert.

Man ordnet die Urliste $x_1, \ldots, x_n$ zunächst der Größe nach:

$$x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)},$$

und erhält auf diese Weise die sogannte **geordnete Urliste**. Trotz möglicher Inkonsistenz mit der allgemeineren Quantilsdefinition in Abschnitt I.2.4, ist es gängige Praxis, den Median (eindeutig) wie folgt zu definieren:

$$x_{\text{Med}} := \begin{cases} x_{(\frac{n+1}{2})} & \text{falls } n \text{ ungerade,} \\ \frac{1}{2}\left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}\right) & \text{falls } n \text{ gerade.} \end{cases} \tag{I.1}$$

Arithmetisches Mittel (Durchschnittswert)
Der bekannteste Lageparameter ist das arithmetische Mittel

$$\overline{x} := \frac{1}{n}\sum_{i=1}^{n} x_i = \sum_{j=1}^{t} a_j f_j \,.$$

Beispiel. Preise eines bestimmten Produkts in 20 Geschäften der Größe nach geordnet:

16.94	16.99	16.99	17.04	17.14
17.14	17.29	17.29	17.29	17.39
17.44	17.44	17.49	17.49	17.49
17.49	17.54	17.54	17.59	17.64

In diesem Beispiel ist $x_{\text{Mod}} = 17.49$, $x_{\text{Med}} = 17.415$, $\overline{x} = 17.3325$. Würde ein einzelnes Geschäft als besondere Werbemaßnahme den Preis des Produkts von 17.29 auf 9.99 senken, so würde dies den Durchschnittswert $\overline{x}$ von 17.3325 auf 16.9675 senken. Einen Einfluss auf den Median (oder auf den Modalwert) hätte die Senkung dagegen nicht.

Lagemaße, die nicht empfindlich auf Extremwerte oder Ausreißer reagieren heißen **robust**. Der Median ist also ein robustes Lagemaß.

Bemerkung.

(i) Das arithmetische Mittel (oft auch der Median) stimmt i. Allg. nicht mit einer der möglichen Merkmalsausprägungen überein.

Beispiel: Durchschnittliche Anzahl der Kinder pro Familie.

(ii) **Invarianz unter linearer Transformation:** Transformiert man die Daten gemäß einer affin linearen Transformation der Form

$$y_i = a + bx_i \,,$$

so gilt für das arithmetische Mittel

$$\overline{y} = a + b\overline{x}$$

und ebenso

$$y_{\text{Mod}} = a + bx_{\text{Mod}} \,, \quad y_{\text{Med}} = a + bx_{\text{Med}} \,.$$

(iii) **Optimalitätseigenschaften:** Das arithmetische Mittel $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ minimiert die Summe der quadratischen Abstände, d.h. es gilt

$$\sum_{i=1}^{n}(x_i - \overline{x})^2 < \sum_{i=1}^{n}(x_i - r)^2 \text{ für alle } r \in \mathbb{R} \text{ mit } r \neq \overline{x} \,.$$

Beweis:

$$\begin{aligned} \sum_{i=1}^{n}(x_i - r)^2 - \sum_{i=1}^{n}(x_i - \overline{x})^2 &= \sum_{i=1}^{n}\Big(\underbrace{(x_i - r)^2 - (x_i - \overline{x})^2}_{-2x_i r + r^2 + 2x_i\overline{x} - \overline{x}^2}\Big) \\ &= -2n\overline{x}r + nr^2 + 2n\overline{x}^2 - n\overline{x}^2 \\ &= n(r - \overline{x})^2 > 0 \text{ für } r \neq \overline{x} \,. \quad \square \end{aligned}$$

Auch Median und Modalwert erfüllen ähnliche Optimalitätskriterien.

– Der Median x_{Med} minimiert die Summe der Abstände, d.h. es gilt

$$\sum_{i=1}^{n} |x_i - x_{\text{Med}}| \leq \sum_{i=1}^{n} |x_i - r| \text{ für alle } r \in \mathbb{R}.$$

– Der Modalwert minimiert die Summe

$$\sum_{i=1}^{n} \mathbf{1}_{\{x_i \neq r\}} \text{ mit } \mathbf{1}_{\{x_i \neq r\}} = \begin{cases} 1 & \text{falls } x_i \neq r, \\ 0 & \text{falls } x_i = r\,. \end{cases}$$

Weitere Lagemaße

Annahme: $x_1, \ldots, x_n > 0$.

Geometrisches Mittel: $\bar{x}_{\text{geom}}$.

$$\bar{x}_{\text{geom}} := (x_1 \cdots x_n)^{\frac{1}{n}}$$

Findet Verwendung im Zusammenhang mit Wachstums- und Zinsmodellen. Sind etwa $x_1, \ldots, x_n$ die beobachteten Wachstumsfaktoren eines Portfolios mit Anfangsbestand K_0, so ist

$$K_n = K_0 \cdot x_1 \cdots x_n$$

der Bestand am Ende der Periode n. Schreibt man

$$K_n = K_0 \left(\underbrace{(x_1 \cdots x_n)^{\frac{1}{n}}}_{=\bar{x}_{\text{geom}}} \right)^n = K_0 \cdot \bar{x}_{\text{geom}}^n,$$

so lässt sich $\bar{x}_{\text{geom}}$ als **mittlerer Wachstumsfaktor** über die n Perioden $1, \ldots, n$ interpretieren.
Beispiel: Die Zinsen auf Tagesgelder in den Jahren $n = 1, 2, 3$ betragen 1.1%, 1.4% und 0.8%. Das eingesetzte Anfangskapital K_0 wird dann zu $K_3 = K_0(1 + \frac{1.1}{100})(1 + \frac{1.4}{100})(1 + \frac{0.8}{100})$, somit ist hier $\bar{x}_{\text{geom}} \approx 1.011$.

Beziehung zum arithmetischen Mittel:

Logarithmiert man die Messwerte $y_i := \ln x_i$, so folgt

$$\ln \bar{x}_{\text{geom}} = \frac{1}{n} \ln(x_1 \cdots x_n) = \frac{1}{n} \sum_{i=1}^{n} \ln x_i = \frac{1}{n} \sum_{i=1}^{n} y_i,$$

d. h., $\ln \bar{x}_{\text{geom}}$ stimmt mit dem arithmetischen Mittel der logarithmierten Messwerte $y_i = \ln x_i$ überein.

Ergänzung: Harmonisches Mittel: $\bar{x}_{\text{harm}}$.

$$\bar{x}_{\text{harm}} := \frac{1}{\frac{1}{n} \sum_{i=1}^{n} \frac{1}{x_i}}$$

Typische Anwendung: Mittelung von Verhältniszahlen a/b.
Beziehen sich Gewichtungen bzw. Häufigkeiten auf Zählergröße $a \Rightarrow$ harmonisches Mittel.
Beziehen sich Gewichtungen bzw. Häufigkeiten auf Nennergröße $b \Rightarrow$ arithmetisches Mittel.

Beispiel. Der ICE von Frankfurt nach Berlin fährt

- 150 km mit durchschnittlich 100 km pro Stunde,

- 450 km mit durchschnittlich 200 km pro Stunde.

Es sei x_i die Durchschnittsgeschwindigkeit bei Kilometer i, $i = 1, \ldots, 600$. Dann beträgt die Durchschnittsgeschwindigkeit über die gesamte Strecke

$$\frac{1}{\frac{1}{600}\left(\frac{150}{100} + \frac{450}{200}\right)} = 160 \left[\frac{\text{km}}{\text{h}}\right].$$

I.2.4 Quantile und Box-Plots

Lagemaße alleine reichen zur Beschreibung der Daten einer Urliste nicht aus. Vergleicht man etwa eine Einkommenserhebung in zwei Ländern, so können die Durchschnittseinkommen gleich sein, jedoch in einem Land größere Einkommensunterschiede bestehen als im anderen Land. Daher benötigt man zusätzliche Kennzahlen, um die Lage der Daten möglichst effizient erfassen zu können. Eine wichtige Methode sind **Box-Plots**, die mit Hilfe von Quantilen definiert werden.

Definition. Es sei $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$ eine geordnete Urliste und $q \in (0; 1]$. Jeder Wert x_q mit der Eigenschaft

$$\frac{1}{n}(\text{Anzahl der Messwerte } \leq x_q) \geq q$$

und

$$\frac{1}{n}(\text{Anzahl der Messwerte } \geq x_q) \geq 1 - q.$$

heißt q-**Quantil** (genauer: empirisches q-Quantil).

Damit folgt

$$x_q = x_{(\lfloor nq \rfloor + 1)} \text{ falls } nq \text{ nicht ganzzahlig,}$$
$$x_q \in [x_{(nq)};\ x_{(nq+1)}] \text{ falls } nq \text{ ganzahlig.}$$

Der gemäß Abschnitt I.2.3 definierte Median x_{Med} ist also *ein* 0.5-Quantil.

Spezialfälle: Das **untere Quartil** ist definiert durch:

$$x_{0.25} := \begin{cases} x_{(\lfloor n \cdot 0.25 \rfloor + 1)} & \text{falls } n \cdot 0.25 \text{ nicht ganzzahlig,} \\ \frac{1}{2}\left(x_{(n \cdot 0.25)} + x_{(n \cdot 0.25 + 1)}\right) & \text{falls } n \cdot 0.25 \text{ ganzahlig,} \end{cases}$$

und analog für das **obere Quartil** $x_{0.75}$. Dies sind *spezielle* Quantile zu $q = 0.25$ bzw. $q = 0.75$. Die Distanz $d_{\text{Q}} = x_{0.75} - x_{0.25}$ heißt **Quartilsabstand** (engl.: inter quartile range, IQR). Der Quartilsabstand beschreibt die „Breite der mittleren 50 %“ und ist somit ein Streuungsmaß (siehe Abschnitt I.2.5). Man beachte, dass in der Literatur auch andere Definitionen von $x_{0.25}$ bzw. $x_{0.75}$ (und damit von d_Q) verwendet werden.

Aufbau eines zugehörigen **Box-Plots**:

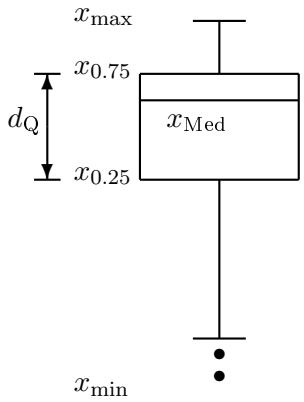

Die Länge der Linien (engl. „whiskers“, Barthaare) ober- bzw. unterhalb der Box können variieren. Eine gängige Variante (vgl. Abbildung) besteht darin, die untere von

$$\max\{x_{0.25} - 1.5 * d_Q,\ x_{\min}\} \text{ bis } x_{0.25}$$

und die obere von

$$x_{0.75} \text{ bis } \min\{x_{0.75} + 1.5 * d_Q,\ x_{\max}\}$$

zu führen. Messwerte, die darunter bzw. darüber liegen, werden als potentielle Ausreißer durch einzelne Punkte explizit kenntlich gemacht.

I.2.5 Streuungsmaße

Neben der absoluten Lage der Messdaten ist auch ihre Streuung von großer Bedeutung. Ein sehr leicht interpretierbares Streuungsmaß ist der **Quartilsabstand**, siehe Abschnitt I.2.4.

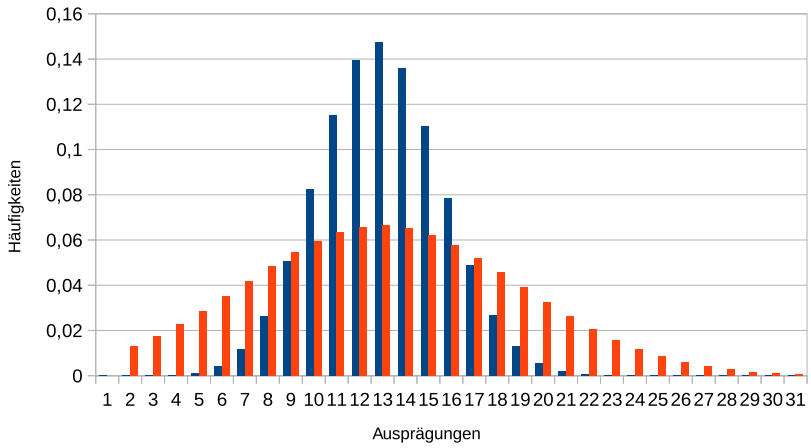

Die bekannteste Maßzahl für die Streuung einer Messreihe ist aber die **empirische Varianz** (oder auch mittlere quadratische Abweichung von $\overline{x}$):

$$s_x^2 := \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2 = \sum_{j=1}^{t}(a_j - \overline{x})^2 f_j. \tag{I.2}$$

Sie ist also definiert als das arithmetische Mittel der quadratischen Abstände der einzelnen Messwerte zu ihrem Mittelwert. Die Wurzel hieraus

$$s_x = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2}$$

heißt **Standardabweichung**.

Der Zusammenhang zwischen der Standardabweichung s_x und der Streuung der Messwerte kann folgendermaßen präzisiert werden:

Für $k \geq 1$ liegen mindestens $100 \cdot \left(1 - \frac{1}{k^2}\right)$ Prozent der Messwerte $x_1, \ldots, x_n$ im Intervall $[\bar{x} - k \cdot s_x;\ \bar{x} + k \cdot s_x]$ („k-σ-Bereich"). Insbesondere gilt:
Im Intervall

- $[\overline{x} - \sqrt{2}s_x;\ \overline{x} + \sqrt{2}s_x]$ liegen mindestens 50 % der Daten,
- $[\overline{x} - 2s_x;\ \overline{x} + 2s_x]$ liegen mindestens 75 % der Daten,
- $[\overline{x} - 3s_x;\ \overline{x} + 3s_x]$ liegen mindestens 88 % der Daten.

Begründung der Abschätzung: Diese beruht auf der empirischen Variante der **Ungleichung von Tschebyschow**, wie wir sie in Abschnitt II.3.3 behandeln werden.

Die obige Abschätzung ist allgemeingültig und daher in vielen Fällen relativ ungenau.

Zur Erinnerung: Mit Hilfe von **Quartilen** und **Quartilsabstand**, siehe Abschnitt I.2.4, kann man stets eine exakte Aussage treffen:
Im Intervall $[x_{0.25}; x_{0.75}]$ liegen 50 % der Daten, seine Breite ist $d_{\mathrm{Q}} = x_{0.75} - x_{0.25}$.

Bemerkung In der induktiven Statistik verwendet man statt (I.2) die modifizierte Form

$$s^2 := \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2.$$

Sie heißt **Stichprobenvarianz** und ist in vielen Statistikprogrammpaketen voreingestellt. Für großen Stichprobenumfang n ist der Unterschied zwischen den beiden Normalisierungsfaktoren $\frac{1}{n}$ und $\frac{1}{n-1}$ vernachlässigbar. Die Normierung mit $\frac{1}{n-1}$ statt mit $\frac{1}{n}$ liegt darin begründet, dass die Stichprobenvarianz ein sog. erwartungstreuer Schätzer für die „wahre" Varianz ist, siehe Abschnitt III.1.1.

Eigenschaften der empirischen Varianz

(i) **Transformationsregel:** Werden die Daten gemäß

$$y_i = a + bx_i$$

linear transformiert, so folgt für die empirische Varianz $s_y^2 = \frac{1}{n}\sum_{i=1}^{n}(y_1 - \overline{y})^2$ der transformierten Daten

$$s_y^2 = b^2 s_x^2\,.$$

Beweis:

$$s_y^2 = \frac{1}{n}\sum_{i=1}^{n} \underbrace{(y_i - \overline{y})^2}_{(a+bx_i)-(a+b\overline{x})} = b^2 \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2. \quad \square$$

Insbesondere folgt für die Standardabweichungen:

$$s_y = |b|\, s_x.$$

(ii) **Verschiebungssatz:**

$$s_x^2 = \frac{1}{n}\left(\sum_{i=1}^{n} x_i^2\right) - \overline{x}^2,$$

denn

$$s_x^2 = \frac{1}{n}\sum_{i=1}^{n} \underbrace{(x_i - \overline{x})^2}_{=x_i^2 - 2x_i\overline{x} + \overline{x}^2} = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - 2\frac{1}{n}\sum_{i=1}^{n} x_i\overline{x} + \overline{x}^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \overline{x}^2\,.$$

I.2.6 Konzentration von Häufigkeitsverteilungen

Als Ausgangspunkt betrachten wir folgende aus [1] entnommene Statistik zu monatlichen Umsätzen der Möbelbranche in 1000 Euro in den drei Städten G, M und V:

Einrichtungshäuser	G	M	V
1	40	180	60
2	40	5	50
3	40	5	40
4	40	5	30
5	40	5	20

In der Stadt G ist der Umsatz unter den 5 Möbelhäusern völlig ausgeglichen, man spricht von einer **Gleichverteilung**. Dagegen besitzt in der Stadt M das Möbelhaus 1 quasi eine Monopolstellung (perfekte **Konzentration** läge vor, wenn die Konkurrenten keinerlei Umsatz erwirtschaften würden). Zur Quantifizierung solcher Konzentrationen gibt es Konzentrationsmaße. Zur Diskussion solcher Maße betrachten wir folgende Ausgangsposition:

Gegeben sei ein kardinalskaliertes Merkmal mit nichtnegativen Merkmalsausprägungen. Weiterhin sei $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$ eine bereits geordnete Stichprobe der Länge n mit positiver Merkmalssumme $x_\bullet := \sum_{i=1}^n x_{(i)} > 0$.

Lorenzkurve

Es sei

$$v_k := \frac{\sum_{i=1}^k x_{(i)}}{x_\bullet}, \qquad k = 0, 1, 2, \ldots, n,$$

der Anteil der k kleinsten Merkmalsträger an der gesamten Merkmalssumme. Trägt man die Punkte

$$\left(\frac{k}{n}, v_k\right), \qquad k = 0, 1, 2, \ldots, n,$$

in das Einheitsquadrat ein und verbindet sie durch einen Streckenzug, so erhält man die zugehörige **Lorenzkurve**.

In obigem Beispiel erhält man:

	Stadt G	Stadt M	Stadt V
k	v_k	v_k	v_k
1	0.2	0.025	0.10
2	0.4	0.050	0.25
3	0.6	0.075	0.45
4	0.8	0.100	0.70
5	1.0	1.0	1.0

Man erhält als zugehörige **Lorenzkurven**:

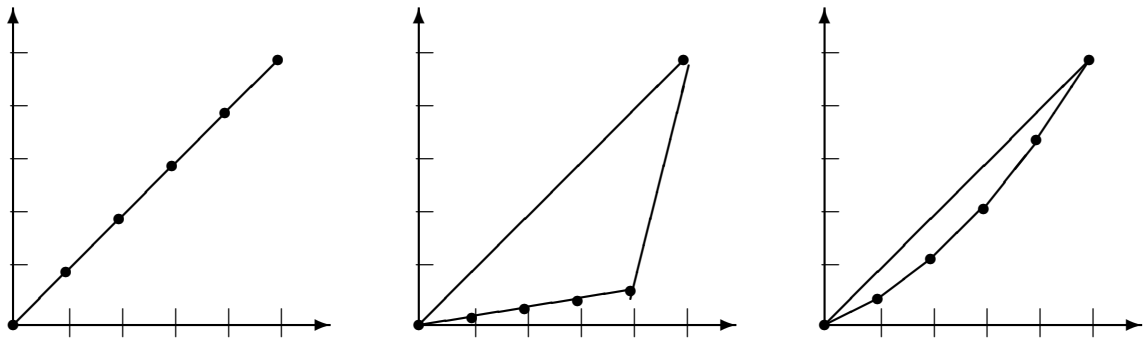

Stadt G Stadt M Stadt V

Eigenschaften der Lorenzkurve:

- Die Lorenzkurve ist monoton wachsend, falls $x_i \geq 0$ für alle i.
- Die Lorenzkurve ist immer konvex (d.h. nach unten gewölbt).
- Die Stärke der Wölbung, also ihre Abweichung von der Winkelhalbierenden, ist ein Maß für Konzentration. Verläuft die Kurve auf der Winkelhalbierenden, so liegt ein ausgewogener Markt (Gleichverteilung) vor.

Der **Gini-Koeffizient** G ist definiert durch

$$\begin{aligned} G &= \frac{\text{Fläche zwischen Diagonale und Lorenzkurve}}{\text{Fläche zwischen Diagonale und horizontaler Achse}} \\ &= 2 \cdot \text{ Fläche zwischen Diagonale und Lorenzkurve.} \end{aligned}$$

Für die Berechnung des Gini-Koeffizienten gilt die folgende Formel (falls $x_i \geq 0$ für alle i):

$$G = \frac{2}{n} \frac{\sum_{i=1}^n i x_{(i)}}{x_\bullet} - \frac{n+1}{n} \qquad \in [0; 1 - \tfrac{1}{n}].$$

$G = 0$ entspricht dem ausgewogenen Markt, und je stärker G von 0 abweicht, desto höher ist die Konzentration. Perfekte Konzentration ergibt $G = 1 - \frac{1}{n}$.

Beweis

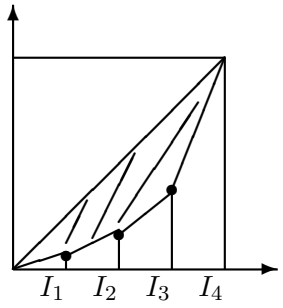

Die Fläche unter der Lorenzkurve im Intervall I_i beträgt gerade

$$I_i = \frac{1}{n} v_{i-1} + \frac{1}{2n}(v_i - v_{i-1}).$$

Also summiert sich die Gesamtfläche *unter* der Lorenzkurve zu

$$\frac{1}{n}\sum_{i=1}^n v_{i-1} + \frac{1}{2n} \underbrace{\sum_{i=1}^n (v_i - v_{i-1})}_{=v_n - v_0 = 1} = \frac{1}{n}\sum_{i=1}^{n-1} v_i + \frac{1}{2n}.$$

Beachtet man noch, dass

$$\begin{aligned} \frac{1}{n}\sum_{i=1}^{n-1} v_i &= \frac{1}{n}\frac{1}{\sum_{j=1}^n x_{(j)}} \left(\sum_{i=1}^{n-1} \sum_{k=1}^{i} x_{(k)} \right) \\ &= \frac{1}{n}\frac{1}{\sum_{j=1}^n x_{(j)}} \sum_{k=1}^n (n-k) x_{(k)} = 1 - \frac{1}{n}\frac{\sum_{k=1}^n k x_{(k)}}{\sum_{j=1}^n x_{(j)}}, \end{aligned}$$

so erhält man nach Einsetzen in die obere Gleichung:

$$G = 2\left(\frac{1}{2} - \left(1 - \frac{1}{n}\frac{\sum_{j=1}^n j x_{(j)}}{\sum_{j=1}^n x_{(j)}} + \frac{1}{2n}\right)\right) = \frac{2}{n}\frac{\sum_{j=1}^n j x_{(j)}}{\sum_{j=1}^n x_{(j)}} - \frac{n+1}{n}. \qquad \square$$

Beispiel: In obigem Beispiel erhält man die Werte 0, 0.7 und 0.2 für die Gini-Koeffizienten der Städte G, M und V.

I.3 Analyse zwei- und mehrdimensionaler Datensätze

Zweidimensionale Datensätze

Werden bei einer Erhebung zwei Merkmale zugleich erhoben, so besteht die Urliste aus **Wertepaaren** (**bivariate Daten**)

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n).$$

Typische Fragestellungen im Zusammenhang zweier Merkmale sind die nach Abhängigkeiten/Unabhängigkeiten zwischen den beiden erhobenen Merkmalen. Zur Darstellung der zweidimensionalen Daten gibt es zunächst zwei Möglichkeiten:

- **Kontingenztabelle:** geeignet für nominalskalierte Merkmale, siehe Abschnitt I.3.1,
- **Streuungsdiagramm:** geeignet für kardinalskalierte Merkmale, siehe Abschnitt I.3.3.

Ausblick auf mehrdimensionale Datensätze

Bei einer statistischen Erhebung von mindestens zwei Merkmalen zugleich entstehen als Urliste Tupel (d.h. geordnete Mengen) von Messwerten (**multivariate Daten**)

$$(x_{11}, \ldots, x_{1m}), (x_{21}, \ldots, x_{2m}), \ldots (x_{n1}, \ldots, x_{nm}),$$

die man in einer **Datenmatrix** zusammenfasst:

$$\begin{bmatrix} x_{11} & \ldots & x_{1m} \\ x_{21} & \ldots & x_{2m} \\ \vdots & & \vdots \\ x_{n1} & \ldots & x_{nm} \end{bmatrix}.$$

Die grafische Darstellung der Urliste als Streuungsdiagramm ist für $m \geq 4$ nicht mehr möglich. Zur Aufklärung von Abhängigkeiten zwischen den erhobenen Merkmalen könnte man zwar für jedes Paar von Merkmalen das zweidimensionale Streuungsdiagramm bzw. die zweidimensionale Kontingenztabelle aufstellen. Da aber die Anzahl der Merkmalspaare mit der Anzahl m der erhobenen Merkmale sehr schnell anwächst, ist dieser Ansatz sehr aufwändig. Effizientere Methoden sind Gegenstand weiterführender Veranstaltungen in der Statistik.

I.3.1 Kontingenztabelle

Bei diesem Verfahren werden die absoluten Häufigkeiten der möglichen Paare von Ausprägungen der Merkmale 1 und 2 tabellarisch aufgelistet:

		Ausprägungen von Merkmal 2:		
		b_1	$\ldots$	b_J
Ausprägungen von Merkmal 1:	a_1	n_{11}	$\ldots$	n_{1J}
	$\vdots$	$\vdots$		$\vdots$
	a_I	n_{I1}	$\ldots$	n_{IJ}

Hierbei steht n_{ij} für die absolute Häufigkeit des Wertepaares (a_i, b_j).

Beispiel. Wir untersuchen die Abhängigkeiten zwischen dem Ergebnis in der Klausur „Einführung in die Stochastik“ (Merkmal 1) und den Gesamtpunkten in den Hausübungen (Merkmal 2). Hier eine Andeutung des Datensatzes (Matrikelnummern ausschließlich zur Illustration):

Matrikelnummer	Note	Punkte in Hausübungen
3406435	2.7	65.5
3407234	1.0	115
3408908	1.3	130
3409043	1.0	121.5
$\vdots$		$\vdots$
6373034	1.3	0

Zuerst vergröbern (klassieren) wir den Datensatz. Merkmal 1 wird reduziert auf die Ausprägungen 1, 2, ..., 5 (gerundete Noten); Merkmal 2 wird reduziert auf die Ausprägungen „fast nichts“ (Punkte zwischen 0 und 20), „aufgegeben“ (Punkte zwischen 20 und 100), „Bonus erreicht“ (Punkte zwischen 100 und 120) und „Streber“ (mehr als 120 Punkte).
Damit erhalten wir folgende Kontingenztabelle:

	Punkte in Hausübungen			
	fast nichts	aufgeben	Bonus	Streber
Note 1	0	3	8	11
Note 2	0	2	7	3
Note 3	1	1	15	2
Note 4	0	2	4	0
Note 5	5	11	11	2

Die Einträge in der Kontigenztabelle heißen **gemeinsame Häufigkeiten**. Statt der absoluten Häufigkeiten lassen sich hier natürlich auch die relativen Häufigkeiten betrachten:

$$f_{ij} = \frac{n_{ij}}{n}.$$

Fragt man nach der absoluten Häufigkeit einer Merkmalsausprägung a_i (bzw. b_j), so hat man die gemeinsamen Häufigkeiten n_{ij} der entsprechenden Zeile (bzw. der entsprechenden Spalte) aufzusummieren:

$$n_{i\bullet} := \sum_{j=1}^{J} n_{ij} \qquad n_{\bullet j} := \sum_{i=1}^{I} n_{ij}$$

Diese Häufigkeiten werden auch als **Randhäufigkeiten** bezeichnet. Die Summe der Randhäufigkeiten wiederum ist jeweils gleich der Größe des Datensatzes, n.

In obigem Beispiel:

	Punkte in Hausübungen				
	fast nichts	aufgeben	Bonus	Streber	$\sum$
Note 1	0	3	8	11	22
Note 2	0	2	7	3	12
Note 3	1	1	15	2	19
Note 4	0	2	4	0	6
Note 5	5	11	11	2	29
$\sum$	6	19	45	18	88

Um nun die beiden Merkmale auf Abhängigkeit/Unabhängigkeit hin zu untersuchen, bildet man die **bedingten relativen Häufigkeiten** (vgl. auch Abschnitt II.1.5)

$$f_1(a_i|b_j) := \frac{n_{ij}}{n_{\bullet j}} \text{ der Ausprägung } a_i \text{ gegeben die Ausprägung } b_j$$

und

$$f_2(b_j|a_i) = \frac{n_{ij}}{n_{i\bullet}} \text{ der Ausprägung } b_j \text{ gegeben die Ausprägung } a_i\,.$$

Die bedingte relative Häufigkeit $f_1(a_i|b_j)$ gibt also die relative Häufigkeit der Ausprägung a_i an unter allen Merkmalsträgern, die bzgl. des anderen Merkmals die Ausprägung b_j besitzen.
In obigem Beispiel:
Wir betrachten die bedingten relativen Häufigkeiten, bedingt auf „Note“ $(f_2(.,.))$:

	Punkte in Hausübungen			
	fast nichts	aufgeben	Bonus	Streber
Note 1	0	0.136	0.364	0.500
Note 2	0	0.167	0.583	0.250
Note 3	0.053	0.053	0.789	0.105
Note 4	0	0.333	0.667	0
Note 5	0.172	0.379	0.379	0.069

Man beachte, dass hierbei die Zeilensummen gleich eins sind. Umgekehrt erhält man auch die bedingten relative Häufigkeiten, bedingt auf „Punkte in den Hausübungen“ $(f_1(.,.))$:

	Punkte in Hausübungen			
	fast nichts	aufgeben	Bonus	Streber
Note 1	0	0.158	0.178	0.611
Note 2	0	0.105	0.155	0.167
Note 3	0.167	0.053	0.333	0.111
Note 4	0	0.105	0.089	0
Note 5	0.833	0.579	0.244	0.111

Hierbei addieren sich also die Spalteneinträge zu eins.

Sind die bedingten relativen Häufigkeiten

$$f_1(a_1|b_j), f_1(a_2|b_j), \ldots, f_1(a_I|b_j)$$

der Ausprägung $a_1, \ldots, a_I$ des ersten Merkmals unabhängig von b_j (also gleich für $j = 1, \ldots, J$), so beeinflussen sich die Merkmale nicht und man sagt, dass sie **unabhängig** sind.

Dieser Fall tritt genau dann ein, wenn auch die umgekehrten bedingten relativen Häufigkeiten

$$f_2(b_1|a_i), f_2(b_2|a_i), \ldots, f_2(b_J|a_i)$$

unabhängig sind von a_i für $i = 1, \ldots, I$, vgl. auch Abschnitt II.1.6.

Im Falle der Unabhängigkeit gilt insbesondere

$$f_1(a_i|b_{j_1}) = f_1(a_i|b_{j_2})$$

und damit

$$n_{ij_1} \cdot n_{\bullet j_2} = n_{ij_2} \cdot n_{\bullet j_1}.$$

Summation über $j_1 = 1, \ldots, J$ ergibt

$$n_{i\bullet} \cdot n_{\bullet j_2} = n_{ij_2} \cdot n,$$

also

$$n_{ij_2} = \frac{n_{i\bullet} \cdot n_{\bullet j_2}}{n}$$

und somit – da j_2 beliebig (siehe auch die analoge Formel (II.11)):

$$n_{ij} = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n}\,. \tag{I.3}$$

Die **gemeinsamen Häufigkeiten** sind in diesem Falle über (I.3) also bereits durch die **Randhäufigkeiten** bestimmt.

Für die bedingten relativen Häufigkeiten folgt hieraus insbesondere

$$f_1(a_i|b_j) = \frac{n_{ij}}{n_{\bullet j}} = \frac{n_{i\bullet}}{n} \qquad \text{bzw. } f_2(b_j|a_i) = \frac{n_{ij}}{n_{i\bullet}} = \frac{n_{\bullet j}}{n}\,,$$

sie sind also unabhängig von der Ausprägung des jeweils anderen Merkmals.

I.3.2 Ergänzung: Der Kontingenzkoeffizient

Um die Abhängigkeit zwischen zwei Merkmalen 1 und 2 quantitativ erfassen zu können, bildet man die folgende, als **Chi-Quadrat Koeffizient** bezeichnete Größe:

$$\chi^2 = \sum_{i=1}^{I} \sum_{j=1}^{J} \frac{(n_{ij} - \tilde{n}_{ij})^2}{\tilde{n}_{ij}}.$$

Hierbei ist $\tilde{n}_{ij} = \frac{n_{i\bullet} n_{\bullet j}}{n}$.

χ^2 ist genau dann 0, wenn die Merkmale unabhängig sind, also wenn $n_{ij} = \tilde{n}_{ij}$ für alle i, j gilt. Je kleiner also der χ^2-Koeffizient, umso stärker spricht dies für die Unabhängigkeit der beiden Merkmale. Allerdings hängt die Größenordnung des χ^2-Koeffizienten von der Dimension der Kontingenztafel ab. Daher geht man vom χ^2-Koeffizienten über zum **Kontingenzkoeffizienten**

$$K = \sqrt{\frac{\chi^2}{n + \chi^2}}.$$

Der Kontingenzkoeffizient K nimmt Werte an zwischen 0 und

$$K_{\max} = \sqrt{\frac{M-1}{M}}, \text{ wobei } M = \min\{I, J\}\,.$$

Durch Normierung mit $K_{\max}$ erhält man hieraus schließlich den **normierten Kontingenzkoeffizienten**

$$K_* = \frac{K}{K_{\max}} \;\in\; [0; 1].$$

Beispiel. Im obigen Beispiel der Merkmale „Klausurnote“ und „Punkte in den Hausübungen“ erhält man $\chi^2 = 34.0$ und mit $n = 88$ berechnet man $K = 0.5278$; und da $I = 5$ und $J = 4$ erhält man $M = 4$ und berechnet $K_* = 0.6094$. Dies spricht für eine gewisse Abhängigkeit der beiden Merkmale.

I.3.3 Streuungsdiagramm und Korrelation

Bei kardinalskalierten Merkmalen kann man die Wertepaare

$$(x_1, y_1), \ldots, (x_n, y_n)$$

der Urliste als Punkte der Ebene auffassen und somit ein zugehöriges **Streuungsdiagramm** (auch: Scatterplot) erstellen:

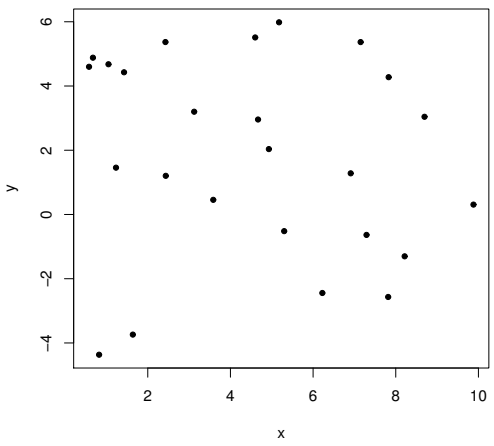

Beispiel.

In einem Krankenhaus wurden von 5 Neugeborenen Körperlänge (Merkmal 1) und Kopfumfang (Merkmal 2), jeweils in cm, gemessen. Es ergab sich folgende nach Köperlänge geordnete Messreihe:

$$(48.6,\, 35.1),\ (49.5,\, 34.1),\ (50.7,\, 36.8),\ (51.1,\, 35.7),\ (52.4,\, 37.4)$$

Zu den jeweiligen Messwerten bildet man zunächst die beiden Mittelwerte

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad \overline{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

Im Beispiel: $\overline{x} = \frac{1}{5}\ 252.3 = 50.46$, $\overline{y} = \frac{1}{5}\ 179.1 = 35.82$.

Liegt bei einem Wertepaar (x_i, y_i) der erste Wert um den Durchschnitt $x_i \sim \overline{x}$, aber der zweite Wert y_i deutlich über oder unter dem Durchschnitt $\overline{y}$, so spricht dies eher für die Unkorreliertheit der beiden Merkmale Körperlänge und Kopfumfang. Liegen jedoch bei diesem Wertepaar bei beiden Merkmalen deutliche Abweichungen vom Durchschnitt vor, so spricht dies für Korrelation. Folglich liefert das Produkt

$$(x_i - \overline{x})(y_i - \overline{y})$$

einen brauchbaren Ansatz für ein Korrelationsmaß.

Aufsummieren über die gesamte Stichprobe und Normierung ergibt die **empirische Kovarianz**

$$s_{xy} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y}) \ = \ldots = \ \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \overline{x}\,\overline{y}.$$

Nach Normierung mit den jeweiligen Standardabweichungen

$$s_x = \left(\frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2\right)^{\frac{1}{2}} \ \text{ und } \ s_y = \left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \overline{y})^2\right)^{\frac{1}{2}}$$

erhält man den **empirischen Korrelationskoeffizienten**

$$r_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2 \sum_{i=1}^{n}(y_i - \overline{y})^2}}\,.$$

Im Beispiel: $s_{xy} \approx 1.24$, $s_x^2 \approx 1.72$, $s_y^2 \approx 1.39$, $r_{xy} \approx 0.80$.

Eigenschaften:

- $-1 \leq r_{xy} \leq 1$.
- $r_{xy} = -1$ (bzw. $r_{xy} = +1$) genau dann wenn die Wertepaare (x_i, y_i) auf einer Geraden mit negativer (bzw. positiver) Steigung liegen.
- $r_{xy} = 0$ spricht für die Unkorreliertheit der beiden Merkmale. In diesem Falle sind die Wertepaare (x_i, y_i) oft „regellos“ verteilt.
- Die Merkmale 1 und 2 heißen
  - **positiv korreliert**, falls $r_{xy} > 0$;
  - **negativ korreliert**, falls $r_{xy} < 0$.

$r_{xy} = 0.9461$ $r_{xy} = -0.1336$ $r_{xy} = -0.9999$

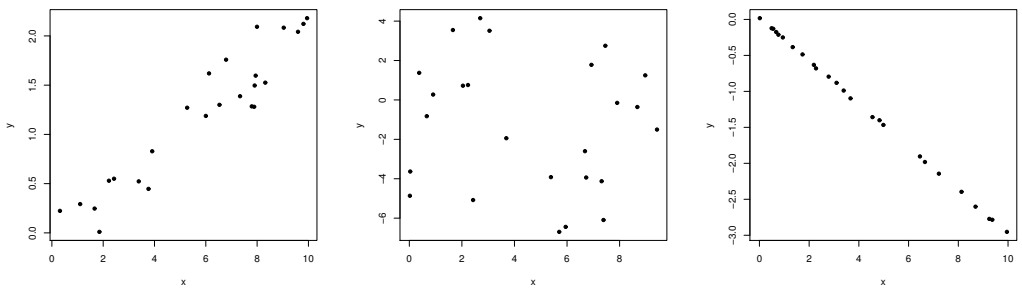

- Eine rechentechnisch günstigere Darstellung für den Korrelationskoeffizienten ist

$$r_{xy} = \frac{\sum_{i=1}^{n} x_i y_i - n\,\overline{x}\,\overline{y}}{\sqrt{(\sum_{i=1}^{n} x_i^2 - n\overline{x}^2)(\sum_{i=1}^{n} y_i^2 - n\overline{y}^2)}}\,.$$

Später in Abschnitt III.2.6 werden wir uns u. a. mit statistischen Testverfahren basierend auf r_{xy} befassen.

Wichtig ist im Kontext dieses Kapitels der Unterschied zwischen Korrelation (hier quantifiziert) und Kausalität (also einem Wirkungszusammenhang). Man wird zum Beispiel bei der Analyse verschiedener Monate des Jahres eine (positive) Korrelation zwischen der Menge an konsumiertem Speiseeis und der Anzahl an klinisch behandelten Sonnenbränden feststellen. Genauso wird die Menge an Speiseeis positiv mit dem sog. Vitamin-D-Spiegel korreliert sein. Dies impliziert aber keinen Kausalzusammenhang: Weder sorgt der Konsum von Eis für Sonnenbrand noch für eine Zufuhr von Vitamin D. Die Größen sind stattdessen nur indirekt über einen dritten Faktor, nämlich die Sonneneinstrahlung, verbunden.

I.3.4 Lineare Regression

Liegen die Wertepaare der n Beobachtungen (x_i, y_i) annähernd auf einer Geraden, so kann man von einem **linearen Zusammenhang** der Form

$$y = a + bx \tag{I.4}$$

sprechen. Die Koeffizienten a und b wählt man dabei so, dass sich die zugehörige Gerade der gegebenen Punktwolke am besten anpasst. „Beste Anpassung“ bedeutet dabei, dass die Summe der quadratischen Abstände

$$Q(a, b) = \sum_{i=1}^{n} [y_i - (a + bx_i)]^2\,,$$

zwischen Messwert y_i und entsprechendem Punkt $a+bx_i$ auf der Geraden $y=a+bx$ minimal wird. („Prinzip der kleinsten Quadrate“ nach C.F. Gauß).

Diejenige Gerade, die sich der Punktwolke dabei am besten anpasst, heißt **Ausgleichsgerade** oder **Regressionsgerade**. Ihre Koeffizienten sind bestimmt durch

$$\hat{b} = \frac{s_{xy}}{s_x^2}\,, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}\,. \tag{I.5}$$

Beispiel. In obigem Beispiel ist

$$s_{xy} = \tfrac{1}{5}(9043.6 - 9037.386) \approx 1.24$$

und damit $r_{xy} \approx 0.80$ (d. h. Körpergröße und Kopfumfang sind (erwartungsgemäß) stark positiv korreliert). Die Koeffizienten der zugehörigen **Regressionsgeraden** sind gegeben durch

$$\hat{b} \approx 0.72 \text{ und } \hat{a} \approx -0.59.$$

Also hat die angepasste Regressionsgerade die Form

$$\hat{y} = -0.59 + 0.72x\,.$$

Mit Hilfe der Regressionsgeraden können wir nun zum Beispiel einen Vorhersagewert („Prognose“) für den Kopfumfang eines Neugeborenen bei einer Körperlänge von 50 cm bestimmen: $\hat{y}(50) = 35.49$.

Zu gegebenem Wertepaar (x_i, y_i) heißt die Differenz

$$u_i := y_i - \hat{y}_i = y_i - (\hat{a} + \hat{b}x_i)$$

zwischen beobachtetem Wert y_i und dem durch die Regressionsgerade erklärten Ausgleichswert $\hat{y}_i = \hat{a} + \hat{b}x_i$ das **Residuum**. Die Summe der quadratischen Residuen

$$\sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} u_i^2$$

ist ein Maß für die Güte der Approximation der Punktewolke des Streuungsdiagramms durch die Regressionsgerade. Den Quotienten

$$R^2 = \frac{\sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^{n} u_i^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2} = r_{xy}^2 \quad \in [0;1] \tag{I.6}$$

bezeichnet man als **Bestimmtheitsmaß**. Er ist eine dimensionslose Größe für die Güte der Approximation, die mit dem Quadrat des Korrelationskoeffizienten übereinstimmt: Je näher R^2 an 1 liegt, desto besser die Approximation.

Die Gleichheit (I.6) ergibt sich unter Beachtung von

$$\sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2 = \sum_{i-1}^{n} \left(\hat{a} + \hat{b}x_i - \left(\hat{a} + \hat{b}\bar{x}\right)\right)^2 = \hat{b}^2 \sum_{i=1}^{n} (x_i - \bar{x})^2 = n\hat{b}^2 s_x^2$$

wegen

$$R^2 = \frac{\sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2} = \frac{\hat{b}^2 s_x^2}{s_y^2} = \left(\frac{s_{xy}}{s_x \cdot s_y}\right)^2 = r_{xy}^2\,.$$

Zur **Optimalität der Regressionsgeraden**:

Satz. Es sei $s_x^2 \neq 0$ und $\hat{a}$, $\hat{b}$ wie in (I.5). Dann gilt:

$$Q(a,b) > Q(\hat{a},\hat{b}) \qquad \text{für alle } (a,b) \neq (\hat{a},\hat{b})\,.$$

Beweis:

$$Q(a,b) = \sum_{i=1}^{n} [y_i - (a + bx_i)]^2$$

ist ein Polynom vom Grad 2 mit Gradient

$$\begin{aligned}\operatorname{grad} Q(a,b) &= \left(\frac{\partial}{\partial a} Q(a,b), \frac{\partial}{\partial b} Q(a,b)\right) \\ &= -2\left(\sum_{i=1}^{n}[y_i - (a+bx_i)], \sum_{i=1}^{n} x_i[y_i - (a+bx_i)]\right)\end{aligned}$$

und Hesse-Matrix

$$H_Q(a,b) = \begin{bmatrix} \frac{\partial^2}{\partial a^2} Q(a,b) & \frac{\partial^2}{\partial a \partial b} Q(a,b) \\ \frac{\partial^2}{\partial a \partial b} Q(a,b) & \frac{\partial^2}{\partial b^2} Q(a,b) \end{bmatrix} = 2 \begin{bmatrix} n & n\overline{x} \\ n\overline{x} & \sum_{i=1}^{n} x_i^2 \end{bmatrix}.$$

Also

$$\det H_Q(a,b) = 4\left(n \sum_{i=1}^{n} x_i^2 - n^2 \bar{x}^2\right) = 4n^2 s_x^2 > 0\,,$$

damit ist H_Q positiv definit und somit Q gleichmäßig strikt konvex.

Folglich besitzt Q genau ein eindeutig bestimmtes Minimum, und dieses wird an der „Nullstelle“ (bzw. der kritischen Stelle) des Gradienten angenommen:

$$\begin{aligned}\operatorname{grad} Q(a,b) = (0,0) &\Leftrightarrow \frac{\partial}{\partial a} Q(a,b) = 0 \text{ und } \frac{\partial}{\partial b} Q(a,b) = 0 \\ &\Leftrightarrow \overline{y} = a + b\overline{x} \text{ und} \\ &\qquad 0 = \sum_{i=1}^{n} x_i(y_i - (a+bx_i)) = \sum_{i=1}^{n} x_i(y_i - bx_i - (\overline{y} - b\overline{x})) \\ &\qquad = \sum_{i=1}^{n} x_i y_i - b\sum_{i=1}^{n} x_i^2 - n\,\overline{x}\,\overline{y} + n\,b\,\overline{x}^2 \\ &\Leftrightarrow a = \overline{y} - b\overline{x} \text{ und} \\ &\qquad b = \frac{\sum_{i=1}^{n} x_i y_i - n\,\overline{x}\,\overline{y}}{\sum_{i=1}^{n} x_i^2 - n\,\overline{x}^2} = \frac{s_{xy}}{s_x^2}. \quad \square\end{aligned}$$

I.3.5 Ergänzung: Nichtlineare Regression

Bei vielen zweidimensionalen Messreihen ist von vorneherein klar, dass kein linearer Zusammenhang zwischen den beobachteten Messwerten erwartet werden kann, sondern ein funktionaler Zusammenhang der Form

$$y = f(x)$$

für eine geeignete **nichtlineare** Funktion f, z.B.

$$y = ae^{bx} \qquad \text{für } b \in \mathbb{R},\ a > 0.$$

Gesucht sind wieder diejenigen Parameter a und b, für die sich der zugehörige Funktionsgraph der gegebenen Punktwolke am besten anpasst. Manchmal kann man durch geeignete Transformation der Daten das Problem auf einen linearen Zusammenhang zurückführen, wie etwa im Beispiel $y = ae^{bx}$ via

$$\ln y = \ln a + bx,$$

und zu bestimmen ist dann die Regressionsgerade zu den transformierten Beobachtungswerten

$$(x_1, \ln y_1), (x_2, \ln y_2), \ldots, (x_n, \ln y_n)\,.$$

Beispiel (sinngemäß entnommen aus [1]).
Gegeben seien folgende Tabelle mit eingesetzter Geldmenge x_i und erzieltem Ertrag y_i (in geeigneten Einheiten) für sechs Werbemaßnahmen zur Ermittlung der Auswirkung von Werbemaßnahmen auf den Produktertrag. Hierbei werden die x_i als zentriert angenommen ($\bar{x} = 0$).

i	1	2	3	4	5	6
x_i	- 5	- 3	- 1	1	3	5
y_i	127	151	379	421	460	426

Nach dem Prinzip vom abnehmenden Grenznutzen sollte eine funktionale Abhängigkeit zwischen den beiden Merkmalen durch einen konkaven Funktionsverlauf beschrieben werden, was auf den Ansatz

$$y = f(x|a,b,c) = a + be^{-cx} \qquad \text{für } a, b \in \mathbb{R}\,, c > 0$$

führt, mit zu schätzenden Parametern a, b und c. Der Parameter a steht dabei für den (asymptotisch für $x \to \infty$ maximal zu erzielenden) Grenzertrag, b für die Differenz zwischen Durchschnittsertrag $y(0)$ und Grenzertrag, und c für die exponentielle Rate der Ertragsminderung.

Gemäß dem „Prinzip der kleinsten Quadrate“ werden die zu schätzenden Parameter für die Regressionskurve durch Minimierung von

$$Q(a,b,c) := \sum_{i=1}^{n} \left(y_i - f(x_i \mid a,b,c)\right)^2$$

ermittelt. Im Unterschied zum Fall der linearen Regression ist in diesem Falle keine explizite Berechnung des Minimums von Q möglich. Man verwendet stattdessen numerische Verfahren zur approximativen Bestimmung des Minimums, die in Statistiksoftwarepaketen enthalten sind. In obigem Beispiel ergibt sich als approximatives Minimum $\hat{a} = 523.3$, $\hat{b} = -156.9$ und $\hat{c} = 0.1997$.

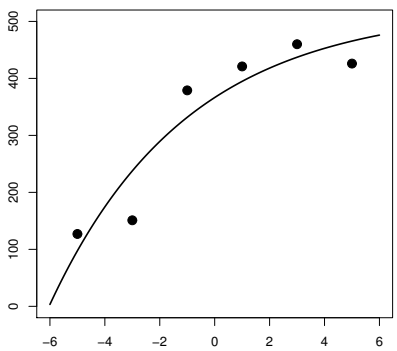

II Wahrscheinlichkeitsrechnung

II.1 Zufallsexperimente und Wahrscheinlichkeitsräume

II.1.1 Zufällige Ereignisse

Unter einem **Zufallsexperiment** versteht man zunächst einmal einen zeitlich wie örtlich fest umrissenen Vorgang mit unbestimmtem Ausgang.

Beispiele:

- Werfen eines Würfels oder Werfen einer Münze;
- Wahlergebnis der nächsten Landtagswahl;
- Temperatur oder Windgeschwindigkeit am Luisenplatz an fixiertem Tag/Uhrzeit;
- Körpergröße oder Kopfumfang eines Neugeborenen.

Die Gesamtheit aller möglichen Ausgänge eines Zufallsexperiments heißt **Ergebnismenge** (oder auch **Stichprobenraum**) und wird mit Ω bezeichnet.
Für ein $\omega \in \Omega$ heißt $\{\omega\}$ **Elementarereignis**. Man beachte $\{\omega\} \subseteq \Omega$. Es stellt einen möglichen Ausgang des zugrundeliegenden Zufallsexperiments dar.

Beispiele:

(i) Einmaliges Würfeln: $\Omega = \{1, 2, \ldots, 6\}$, $|\Omega| = 6$.

(Nebenbemerkung: Hierbei bezeichnet $|\Omega|$ die Mächtigkeit der Menge Ω, also die Anzahl der Elemente in Ω.)

(ii) Zweimaliges Würfeln:

$$\Omega = \{(i; j) \mid i, j \in \{1, \ldots, 6\}\} = \{1, 2, \ldots, 6\} \times \{1, 2, \ldots, 6\} = \{1, 2, \ldots, 6\}^2 ,$$

also $|\Omega| = 36$.

(iii) Münzwurf: $\Omega = \{$„Kopf“, „Zahl“$\}$.

(iv) Autos am Darmstädter Kreuz in vorgegebener Zeitspanne: $\Omega = \{0, 1, 2, 3, \ldots\} = \mathbb{N}_0$.

(v) Temperatur in Grad Celsius am Luisenplatz zu vorgegebenem Tag und Uhrzeit: $\Omega = [-273.15; \infty)$ oder realistischer $[-20; 40]$ ($0°$ C $= 273.15°$ K).

In den ersten vier Fällen sind die Ergebnisräume **endlich** oder **abzählbar unendlich**. Solche Ergebnisräume nennt man auch **diskret**. Im fünften Fall ist der Ergebnisraum nicht mehr abzählbar, sondern eine **kontinuierliche** Menge.
Die Wahrscheinlichkeitstheorie zu kontinuierlichen Ergebnisräumen ist mathematisch anspruchsvoller als die zu diskreten Ergebnisräumen. Daher betrachten wir **zunächst nur diskrete** Ergebnisräume Ω.

Ereignisse

Teilmengen $A \subseteq \Omega$ von Ω heißen **Ereignisse**. Die Gesamtheit aller Ereignisse ist somit nichts weiter als $\mathcal{P}(\Omega)$, also die **Potenzmenge** von Ω. Unter der Potenzmenge von Ω versteht man die Gesamtheit aller Teilmengen von Ω einschließlich der leeren Menge $\emptyset$ und der Menge Ω selber.
Beachten Sie: Ereignisse sind Elemente der Potenzmenge $\mathcal{P}(\Omega)$ von Ω, also Teilmengen von Ω.

Beispiele

(i) $A = \{1, 3, 5\}$ = „Augenzahl ungerade“;

(ii) $A = \{(5; 6), (6; 5), (6; 6)\}$ = „Augensumme größer als 10“;

(iv) $A = \{22.000, 22.001, \ldots\} = \{n \mid n \geq 22.000\}$ = „sehr hohes Verkehrsaufkommen“.

Zwei Ereignisse sind besonders hervorzuheben:

- Ω = das sichere Ereignis;
- $\emptyset$ = das unmögliche Ereignis.

Die bekannten Mengenoperationen lassen sich als **Operationen auf Ereignissen** interpretieren:

$A \cup B$ = „A oder B tritt ein“;

$A_1 \cup A_2 \cup \ldots \cup A_n =: \bigcup_{k=1}^{n} A_k$ = „mindestens eines der A_k tritt ein“;

$A \cap B$ = „A und B treten ein“;

$A_1 \cap A_2 \cap \ldots \cap A_n =: \bigcap_{k=1}^{n} A_k$ = „alle A_k treten ein“;

$A^c := \Omega \backslash A := \{\omega \in \Omega \mid \omega \notin A\}$ = „A tritt nicht ein“.

A^c heißt **Komplement** der Menge A (in Ω). Es gilt:

$$\Omega^c = \emptyset \text{ und } \emptyset^c = \Omega\,.$$

II.1.2 Wahrscheinlichkeitsmaße

Für jedes Ereignis A legen wir im nächsten Schritt eine Wahrscheinlichkeit $P(A)$ zwischen 0 und 1 fest. $P(A)$ soll ein Maß dafür sein, dass das Ereignis A eintritt:

- Tritt A niemals ein, so setzt man $P(A) = 0$. Insbesondere ist $P(\emptyset) = 0$.
- Tritt A sicher ein, so setzt man $P(A) = 1$. Insbesondere ist $P(\Omega) = 1$.

Zusätzlich sollte gelten: Sind A und B disjunkte Ereignisse, d.h. A und B besitzen keine gemeinsamen Elemente, also $A \cap B = \emptyset$, so ist

$$P(A \cup B) = P(A) + P(B)\,. \tag{II.1}$$

Diese Eigenschaft von P bezeichnet man als **Additivität**.
Aus (II.1) folgt unmittelbar: Sind $A_1, \ldots, A_n$ paarweise disjunkte Ereignisse, d.h. $A_k \cap A_l = \emptyset$ für $k \neq l$, so folgt:

$$P(A_1 \cup \ldots \cup A_n) = P(A_1) + \ldots + P(A_n)\,. \tag{II.2}$$

Gilt schließlich auch für jede **unendliche** Folge (A_n) paarweiser disjunkter Ereignisse

$$P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} P(A_k), \tag{II.3}$$

so spricht man von **σ-Additivität**.

Definition.
Ein **diskreter Wahrscheinlichkeitsraum** ist ein Paar (Ω, P), wobei

- Ω eine nichtleere, diskrete (d.h. endliche oder abzählbar unendliche) Menge, und
- P ein **diskretes Wahrscheinlichkeitsmaß auf** Ω ist, d.h. eine Abbildung

$$P : \mathcal{P}(\Omega) \to \mathbb{R}$$

  mit den folgenden Eigenschaften:

  - $P(A) \geq 0$ für alle $A \in \mathcal{P}(\Omega)$; (Nichtnegativität)
  - $P(\Omega) = 1$; (Normiertheit)
  - $P(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} P(A_k)$ für jede Folge (A_k) paarweise disjunkter Ereignisse. (σ-Additivität)

Rechenregeln für P

- P ist insbesondere auch **endlich additiv**, d.h. für $A_1, \ldots, A_n$ paarweise disjunkt, ist

$$P(A_1 \cup \ldots \cup A_n) = P(A_1) + \ldots + P(A_n) = \sum_{k=1}^{n} P(A_k)\,.$$

- Allgemeiner gilt für beliebige Ereignisse A und B (d. h. A und B könnten auch nicht disjunkt sein), dass

$$P(A \cup B) \;=\; P(A) + P(B) - P(A \cap B).$$

- $P(A^c) = 1 - P(A)$, denn A und A^c sind disjunkt, $A \cup A^c = \Omega$, also

$$1 = P(\Omega) = P(A \cup A^c) = P(A) + P(A^c)\,.$$

- $P(\emptyset) = 0$, denn $\emptyset^c = \Omega$, also

$$P(\emptyset) = 1 - P(\Omega) = 1 - 1 = 0\,.$$

- $A \subseteq B$ impliziert $P(A) \leq P(B)$
  denn $B = A \cup (B \cap A^c)$ und A und $B \cap A^c$ sind disjunkt, also

$$P(B) = P(A) + P(B \cap A^c) \geq P(A)\,.$$

II.1.3 Wahrscheinlichkeitsmaße und Wahrscheinlichkeitsfunktionen

Eine **Wahrscheinlichkeitsfunktion (auf Ω)** ist eine Funktion $p : \Omega \to [0; 1]$ mit

$$\sum_{\omega \in \Omega} p(\omega) = 1. \tag{II.4}$$

Bemerkung. Beachten Sie, dass es sich bei (II.4) um eine unendliche Summe handelt, falls Ω unendlich viele Elemente enthält. Gemeint ist mit (II.4) also, dass die (möglicherweise unendliche) Reihe $\sum_{\omega \in \Omega} p(\omega)$ konvergiert und ihr Wert gleich 1 ist. Hierbei kommt es auf die **Reihenfolge**, in der die Wahrscheinlichkeiten $p(\omega)$ aufsummiert werden, **nicht** an, denn die Reihe ist wegen der Nichtnegativität der Summanden $p(\omega)$ absolut konvergent.

Zu gegebener Wahrscheinlichkeitsfunktion p definieren wir die Wahrscheinlichkeit $P(A)$ eines Ereignisses A durch

$$P(A) := \sum_{\omega \in A} p(\omega)\,. \tag{II.5}$$

Die Wahrscheinlichkeit von A ist also gleich der Summe der Wahrscheinlichkeiten all jener Elementarereignisse $\{\omega\}$, mit $\omega \in A$. Die so definierte Abbildung P ist ein diskretes Wahrscheinlichkeitsmaß auf Ω, d.h. nichtnegativ, normiert und σ-additiv.

Umgekehrt können wir zu jedem diskreten Wahrscheinlichkeitsmaß P auf Ω durch

$$p(\omega) := P\left(\{\omega\}\right) \quad \text{für alle } \omega \in \Omega \tag{II.6}$$

eine **Wahrscheinlichkeitsfunktion auf** Ω definieren.

Durch (II.5) und (II.6) ist also eine „1:1"-Beziehung zwischen allen diskreten Wahrscheinlichkeitsmaßen über Ω und allen Wahrscheinlichkeitsfunktionen über Ω gegeben.

Beispiele

(i) Beim Würfeln mit einem fairen Würfel ist jede der sechs möglichen Augenzahlen gleichwahrscheinlich. Man setzt daher

$$p(\omega) = \frac{1}{6} \quad \text{für } \omega \in \Omega = \{1,2,3,4,5,6\}\,.$$

Es folgt z.B.

$$P(\text{„Augenzahl ungerade"}) = P\big(\{1,3,5\}\big) = p(1) + p(3) + p(5) = \frac{3}{6} = \frac{1}{2}\,.$$

(ii) Beim zweimaligen Würfeln mit einem fairen Würfel ist wiederum jedes der 36 Elementarereignisse aus $\Omega = \{1,2,3,4,5,6\}^2$ gleichwahrscheinlich, also $p(\omega) = \frac{1}{36}$ für alle $\omega \in \Omega$. Es folgt z.B.

$$P(\text{„Augensumme"} > 10) = P\big(\{(5;6),(6;5),(6;6)\}\big) = \frac{3}{36} = \frac{1}{12}\,.$$

Beide Beispiele sind Spezialfälle eines Laplaceschen Wahrscheinlichkeitsraumes.

II.1.4 Laplacescher Wahrscheinlichkeitsraum und Urnenmodelle

Ist Ω eine endliche Menge, so definiert

$$p(\omega) := \frac{1}{|\Omega|} \quad \text{für alle } \omega \in \Omega$$

eine Wahrscheinlichkeitsfunktion auf Ω. Für die Wahrscheinlichkeit $P(A)$ eines beliebigen Ereignisses folgt hieraus sofort

$$P(A) = \sum_{\omega \in A} p(\omega) = \sum_{\omega \in A} \frac{1}{|\Omega|} = \frac{|A|}{|\Omega|}\,. \tag{II.7}$$

$P(A)$ heißt **Laplace-Wahrscheinlichkeit von** A. Da jedes Elementarereignis gleichwahrscheinlich ist, spricht man von P auch als der **Gleichverteilung auf** Ω**.**

Die Berechnung der Wahrscheinlichkeit $P(A)$ in (II.7) führt auf das Problem der **Abzählung der Elemente in** A, also auf ein **Abzählproblem**. Die wichtigsten Abzählprobleme sollen im Folgenden anhand einfacher **Urnenmodelle** illustriert werden.

Eine Urne enthalte n unterscheidbare Kugeln $1, 2, \ldots, n$. Wir unterscheiden dann das k-malige Ziehen einer Kugel aus der Urne mit/ohne Zurücklegen, wobei es auf die Reihenfolge der gezogenen Kugeln ankommt/nicht ankommt:

1) **In Reihenfolge und mit Zurücklegen:**

$$\Omega \;=\; \big\{\omega = (x_1, \ldots, x_k) \;\big|\; x_i \in \{1, \ldots, n\}\big\}\,, \qquad |\Omega| = n^k,$$

d.h., ein Element $\omega = (x_1, \ldots, x_k)$ ist ein k-**Tupel**, d.h. eine geordnete Menge der Länge k, wobei x_i für die Nummer der i-ten gezogenen Kugel steht.

2) **In Reihenfolge und ohne Zurücklegen:**

$$\Omega \;=\; \big\{\omega = (x_1, \ldots, x_k) \;\big|\; x_i \in \{1, \ldots n\},\; x_i \neq x_j \text{ für } i \neq j\big\},$$

$$|\Omega| = n \cdot (n-1) \cdot (n-2) \cdot \ldots \cdot (n-k+1) = \frac{n!}{(n-k)!}\,.$$

Zur Erinnerung: Die Fakultätsfunktion ist definiert wie folgt:

$$m! := m(m-1) \cdot (m-2) \cdot \ldots \cdot 2 \cdot 1 = \Pi_{k=1}^{m} k\,, \qquad \text{und } 0! := 1\,.$$

Insbesondere

$$n! = n \cdot (n-1)! = n \cdot (n-1) \cdot (n-2)! = \ldots = n \cdot (n-1) \cdot \ldots \cdot (n-k+1) \cdot (n-k)!\,,$$

also

$$\frac{n!}{(n-k)!} = n \cdot (n-1) \cdot \ldots \cdot (n-k+1)\,.$$

Für $k = n$ erhält man als Spezialfall

$$|\Omega| = \frac{n!}{(n-n)!} = \frac{n!}{0!} = n!\,.$$

$n!$ ist also gleich der Anzahl aller möglichen Anordnungen (oder auch **Permutationen**) der n-elementigen Menge $\{1, \ldots, n\}$.

3) **Ohne Reihenfolge und ohne Zurücklegen:**

$$\Omega \;=\; \big\{\omega = \{x_1, \ldots, x_k\} \;\big|\; x_i \in \{1, 2, \ldots, n\},\; x_i \neq x_j \text{ für } i \neq j\big\}.$$

Im Unterschied zum Ziehen in Reihenfolge werden nun alle k-Tupel $(x_1, \ldots, x_k)$, die zu derselben Menge der gezogenen Kugeln führen, zu einem Element zusammengefasst. Insgesamt gibt es $k!$ solcher Tupel (das entspricht also gerade der Anzahl der Permutationen der Menge der k gezogenen Kugeln). Also erhalten wir insgesamt

$$\frac{n!}{(n-k)!} \cdot \frac{1}{k!} = \binom{n}{k}$$

Elemente. Es gilt also

$$|\Omega| = \binom{n}{k}.$$

Insbesondere: $\binom{n}{k}$ ist gleich der Anzahl aller k-elementigen Teilmengen aus einer n-elementigen Grundmenge.

Alternative Darstellung der Ergebnismenge: Unter allen k-Tupeln, die zur selben Menge $\{x_1, \ldots, x_k\}$ führen, gibt es genau ein Tupel $(x_{(1)}, \ldots, x_{(k)})$, in dem die Elemente ihrer Größe nach angeordnet sind:

$$x_{(1)} < x_{(2)} < \ldots < x_{(k)} \,.$$

Wir können daher auch folgende Ergebnismenge benutzen:

$$\tilde{\Omega} \;=\; \big\{(x_1, \ldots, x_k) \;\big|\; x_i \in \{1, \ldots, n\}\,,\; x_1 < x_2 < \ldots < x_k\big\}\,.$$

4) **Ohne Reihenfolge und mit Zurücklegen:**

Die intuitive Darstellung

$$\Omega \;=\; \big\{\omega = \{x_1, \ldots, x_k\} \;\big|\; x_i \in \{1, 2, \ldots, n\}\big\}.$$

macht keinen Sinn, da ja z.B. gilt $\{3, 3\} = \{3\}$.

Deshalb ordnen wir analog zu 3) die Nummern der gezogenen Kugeln der Größe nach an:

$$x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(k)}\,, \tag{II.8}$$

wobei wegen des Zurücklegens Kugeln mehrfach gezogen werden können.

Durch Übergang von $x_{(i)}$ zu $x_{(i)} + i - 1$ erhält man aus (II.8) eine streng monoton aufsteigende Folge

$$x_{(1)} < x_{(2)} + 1 < x_{(3)} + 2 < \ldots < x_{(k)} + k - 1\,.$$

Wir erhalten als Stichprobenraum in diesem Falle also

$$\tilde{\Omega} \;=\; \big\{(x_1, \ldots, x_k) \;\big|\; x_i \in \{1, \ldots, n, n+1, \ldots, n+k-1\}\,,\; x_1 < x_2 < \ldots < x_k\big\}\,.$$

Für die Mächtigkeit $|\tilde{\Omega}|$ von $\tilde{\Omega}$ ergibt sich nach 3)

$$|\tilde{\Omega}| = \binom{n+k-1}{k}\,.$$

II.1.5 Bedingte Wahrscheinlichkeiten

Ist über den Ausgang eines Zufallsexperiments bereits eine Teilinformation verfügbar, „ändern" sich entsprechend die Wahrscheinlichkeiten der Ereignisse.

Beispiel.

Beim zweimaligen Würfeln eines fairen Würfels ist

$$P(\text{„Augensumme"} > 10) = \frac{1}{12}\,.$$

Wie ändert sich diese Wahrscheinlichkeit, wenn bereits bekannt ist, dass beim ersten Würfeln eine 6 gewürfelt wurde? Unter dieser Annahme bleiben nur noch sechs gleichwahrscheinliche Möglichkeiten für die zweite Augenzahl übrig, von denen die Augenzahlen 5 und 6 insgesamt zu einer Augensumme größer als 10 führen. Für die Wahrscheinlichkeit des Ereignisses „Augenzahl > 10" unter der Bedingung „1. Augenzahl ist 6" ergibt sich somit

$$P(\text{„Augensumme"} > 10 \mid \text{„1. Augenzahl"} = 6) = \frac{2}{6} = \frac{1}{3}\,.$$

Die bedingte Wahrscheinlichkeit ist also viermal höher als die ursprüngliche „a priori"-Wahrscheinlichkeit. Die folgende Definition erfolgt in vollständiger Analogie zu Abschnitt I.3.1.

Definition.
Für Ereignisse A, B mit $P(B) > 0$ heißt

$$P(A \,|\, B) := \frac{P(A \cap B)}{P(B)}$$

die **bedingte Wahrscheinlichkeit von A unter der Bedingung B** (oder auch: **die bedingte Wahrscheinlichkeit von A gegeben B**). Im Falle $P(B) = 0$ setzen wir einfach $P(A \mid B) := 0$ (dies ist in der Literatur nicht üblich, vereinfacht aber die Notation in diesem Skript).

Eigenschaften der bedingten Wahrscheinlichkeit:

- $P(A \,|\, B) \in [0; 1]$.
- $P(\emptyset \,|\, B) = 0$.
- Gilt $P(B) > 0$, so ist $P(\Omega \,|\, B) = 1$ und

  $$P(\cdot \,|\, B) \,:\, \mathcal{P}(\Omega) \to [0; 1]\,,\ A \mapsto P(A \,|\, B)$$

  ist wieder eine diskrete Wahrscheinlichkeitsverteilung auf Ω. $P(\cdot \mid B)$ heißt **bedingte Wahrscheinlichkeitsverteilung unter der Bedingung B**.

Beispiel. (Laplacescher Wahrscheinlichkeitsraum)
Ω sei endlich, $P(A) = \frac{|A|}{|\Omega|}$ sei die Gleichverteilung auf Ω. Dann folgt für $B \neq \emptyset$

$$P(A \,|\, B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{|A \cap B|}{|\Omega|}}{\frac{|B|}{|\Omega|}} = \frac{|A \cap B|}{|B|}\,.$$

Insbesondere: Die bedingte Wahrscheinlichkeitsverteilung ist im Falle des Laplaceschen Wahrscheinlichkeitsraumes gerade die Gleichverteilung auf B.

Beispiel.
Wir betrachten eine Urne mit vier weißen Kugeln und zwei schwarzen Kugeln. Wir ziehen zweimal aus der Urne, ohne Zurücklegen. Was ist die Wahrscheinlichkeit, im zweiten Zug eine schwarze Kugel zu ziehen?
Schritt 1 ist es, relevante Ereignisse bezeichnen. Wir bezeichnen

$$\begin{aligned} W1 &:= \text{„weiß im ersten Zug“} \\ W2 &:= \text{„weiß im zweiten Zug“} \\ S1 &:= \text{„schwarz im ersten Zug“} \\ S2 &:= \text{„schwarz im zweiten Zug“} \end{aligned}$$

Im Schritt 2 können wir nun einige (bedingte) Wahrscheinlichkeiten sehr leicht ablesen. Zum Beispiel: Unter der Bedingung, dass im ersten Zug eine weiße Kugel gezogen wurde, ist die Wahrscheinlichkeit, im zweiten Zug nochmals eine weiße Kugel zu ziehen gerade $\frac{3}{5}$, denn es befinden sich (nach Entnahme der weißen Kugel im ersten Zug) drei weiße und zwei scharze (also insgesamt 5) Kugeln in der Urne. Auf diese Weise erhalten wir:

$$\begin{aligned} P(W2|W1) &= \frac{3}{5} & P(S2|W1) &= \frac{2}{5} \\ P(W2|S1) &= \frac{4}{5} & P(S2|S1) &= \frac{1}{5} \\ P(S1) &= \frac{2}{6} & P(W1) &= \frac{4}{6}. \end{aligned}$$

In einem dritten Schritt identifizieren wir die gesuchten Wahrscheinlichkeiten, gesucht ist in diesem Fall $P(W2)$. Nun rechnen wir

$$\begin{aligned} P(W2) &= P(W2 \cap W1) + P(W2 \cap S1) \\ &= \frac{P(W2 \cap W1)}{P(W1)} \cdot P(W1) + \frac{P(W2 \cap S1)}{P(S1)} \cdot P(S1) \\ &= P(W2|W1) \cdot P(W1) + P(W2|S1) \cdot P(S1) \\ &= \frac{3}{5} \cdot \frac{4}{6} + \frac{4}{5} \cdot \frac{2}{6} = \frac{12+8}{30} = \frac{20}{30} = \frac{2}{3}. \end{aligned}$$

Zusätzlich kann man nun fragen, was z.B. $P(S1|W2)$ ist, also die Wahrscheinlichkeit, dass im ersten Zug eine schwarze Kugel gezogen wurde, wenn wir wissen, dass im zweiten Zug eine weiße Kugel gezogen wurde. Dies kann man wie folgt berechnen:

$$\begin{aligned} P(S1|W2) &= \frac{P(S1 \cap W2)}{P(W2)} = \frac{P(W2 \cap S1)}{P(S1)} \cdot \frac{P(S1)}{P(W2)} \\ &= P(W2|S1) \cdot \frac{P(S1)}{P(W2)} = \frac{4}{5} \cdot \frac{\frac{2}{6}}{\frac{2}{3}} = \frac{2}{5}. \end{aligned}$$

Der folgende Satz fasst die relevanten Rechnungen des letzten Beispiels in allgemeinerer Form zusammen.

Satz.

Es seien $B_1, \ldots, B_n$ disjunkte Teilmengen von Ω und $A \subseteq B_1 \cup \ldots \cup B_n$. Dann folgt:

(i) **(Formel von der totalen Wahrscheinlichkeit)**

$$P(A) = \sum_{k=1}^{n} P(A \,|\, B_k) \cdot P(B_k)\,. \tag{II.9}$$

(ii) **(Formel von Bayes)** Für $P(A) > 0$ gilt

$$P(B_i \,|\, A) = \frac{P(A \,|\, B_i) \cdot P(B_i)}{P(A)} = \frac{P(A \,|\, B_i) \cdot P(B_i)}{\sum_{k=1}^{n} P(A \,|\, B_k) \cdot P(B_k)}\,. \tag{II.10}$$

Mitunter liefert die Formel von Bayes scheinbar überraschende Aussagen wie im Falle des folgenden Tests auf eine seltene Krankheit.

Beispiel. Angenommen, 5 Promille der Bevölkerung haben eine seltene Krankheit K, d.h.

$$P(K) = 0.005\,.$$

Ein medizinischer Test zeigt bei 99% der Erkrankten eine positive Reaktion, d.h.

$$P(\text{„Test positiv“} \,|\, K) = 0.99\,.$$

Allerdings zeigt besagter Test auch bei 2% der Gesunden eine positive Reaktion, d.h.

$$P(\text{„Test positiv“} \,|\, K^c) = 0.02\,.$$

Von besonderem Interesse ist nun offenbar folgende

Frage: Angenommen, der Test ist positiv. Wie groß ist die Wahrscheinlichkeit, dass die getestete Person tatsächlich an K erkrankt ist? Wie groß ist also die bedingte Wahrscheinlichkeit

$$P(K \,|\, \text{„Test positiv“}\,)\,?$$

Die Formel von Bayes liefert

$$\begin{aligned} P(K \,|\, \text{„Test positiv“}\,) &= \frac{P(\text{„Test positiv“} \,|\, K) \cdot P(K)}{P(\text{„Test positiv“} \,|\, K) \cdot P(K) + P(\text{„Test positiv“} \,|\, K^c) \cdot P(K^c)} \\ &= \frac{0.99 \cdot 0.005}{0.99 \cdot 0.005 + 0.02 \cdot 0.995} = \frac{495}{2485} \approx 0.2\,. \end{aligned}$$

Also: Nur in 2 von 10 Fällen mit postivem Testergebnis ist die getestete Person auch wirklich an K erkrankt.

II.1.6 Unabhängigkeit

Ist $P(A) = P(A|B)$, d.h. die Wahrscheinlichkeit von A **unabhängig** davon, ob das Ereignis B eingetreten ist oder nicht, so folgt:

$$P(A) = P(A \,|\, B) = \frac{P(A \cap B)}{P(B)}$$

und damit

$$P(A \cap B) \;=\; P(A) \cdot P(B)\,. \tag{II.11}$$

Zwei Ereignisse A und B mit (II.11) heißen **(stochastisch) unabhängig** (erneut in Analogie zu Abschnitt I.3.1).

Allgemeiner gilt:

Definition.
Die Ereignisse $A_1, \ldots, A_n$ heißen (stochastisch) unabhängig, falls für jede nichtleere Teilmenge $\{i_1, \ldots, i_k\} \subseteq \{1, \ldots, n\}$ gilt:

$$P(A_{i_1} \cap \ldots \cap A_{i_k}) \;=\; P(A_{i_1}) \cdots P(A_{i_k}).$$

Man beachte, dass zum Nachweis der Unabhängigkeit dreier Ereignisse A, B und C, der Nachweis der **paarweisen Unabhängigkeit** je zweier Ereignisse nicht ausreicht. Als Beispiel betrachten wir beim zweimaligen Werfen einer fairen Münze die Ereignisse

$$\begin{aligned} A &= \text{„1. Wurf Zahl“}, \\ B &= \text{„2. Wurf Zahl“}, \\ C &= \text{„1. und 2. Wurf gleich“}\,. \end{aligned}$$

Diese sind paarweise unabhängig, aber nicht vollständig unabhängig, denn $P(A) = P(B) = P(C) = \frac{1}{2}$, $P(A \cap B) = P(A \cap C) = P(B \cap C) = \frac{1}{4}$, aber

$$P(A \cap B \cap C) = \frac{1}{4} \neq P(A) \cdot P(B) \cdot P(C)\,.$$

Beispiel.
Beim zweimaligen Würfeln eines fairen Würfels ist die erste Augenzahl offenbar „unabhängig“ von der zweiten Augenzahl, also jedes Ereignis A, das nur von der ersten Zahl abhängt, unabhängig von jedem Ereignis B, das nur von der zweiten Augenzahl abhängt, etwa:

$$\begin{aligned} A &= \text{„1. Augenzahl gerade“}\,, \qquad P(A) = \frac{1}{2} \\ B &= \text{„2. Augenzahl} \geq 5\text{“}\,, \qquad P(B) = \frac{1}{3}\,. \end{aligned}$$

Dann gilt

$$\begin{aligned} P(A \cap B) &= P\big(\{(2,5),(2,6),(4,5),(4,6),(6,5),(6,6)\}\big) \\ \frac{6}{36} &= \frac{1}{6} = \frac{1}{2} \cdot \frac{1}{3} = P(A) \cdot P(B)\,. \end{aligned}$$

II.2 Zufallsvariablen und Verteilungen

Im ganzen Abschnitt sei (Ω, P) ein diskreter Wahrscheinlichkeitsraum.

II.2.1 Das Konzept der Zufallsvariablen

Eine Funktion

$$X : \Omega \to \mathbb{R}$$

heißt **Zufallsvariable (auf Ω)**. Da Ω abzählbar, ist auch das Bild

$$X(\Omega) = \big\{X(\omega) \mid \omega \in \Omega\big\} \subseteq \mathbb{R}$$

abzählbar.

Für $x \in \mathbb{R}$ betrachten wir insbesondere das Ereignis

$$\{X = x\} := \big\{\omega \in \Omega \mid X(\omega) = x\big\} = \text{„}X \text{ nimmt den Wert } x \text{ an“.}$$

Durch

$$p_X(x) := P(X = x) \qquad \text{für } x \in X(\Omega)$$

wird dann eine neue Wahrscheinlichkeitsfunktion auf $X(\Omega)$ definiert. Das zugehörige diskrete Wahrscheinlichkeitsmaß P_X auf $\mathcal{P}\big(X(\Omega)\big)$ heißt **Verteilung von X (unter P).**

Für beliebige Ereignisse $A \subseteq X(\Omega)$ gilt offenbar

$$\begin{aligned} P_X(A) &= \sum_{x \in A} p_X(x) = \sum_{x \in A} P(X = x) \\ &= P\Big(\underbrace{\bigcup_{x \in A} \{\omega \mid X(\omega) = x\}}_{=\{\omega \mid X(\omega) \in A\}}\Big) = P(X \in A)\,. \end{aligned}$$

Beispiel.
Beim zweimaligen Würfel eines fairen Würfels sei X die Augensumme. X ist eine Zufallsvariable mit Werten in der Menge $\{2, 3, \ldots, 12\}$, von denen aber nicht alle Werte mit gleicher Wahrscheinlichkeit von X angenommen werden. Vielmehr gilt:

$$\begin{aligned} p_X(2) &= P\big(\{(k,l) \in \Omega \mid k + l = 2\}\big) = P\big(\{(1,1)\}\big) = \frac{1}{36}, \\ p_X(12) &= P\big(\{6,6\}\big) = \frac{1}{36}, \end{aligned}$$

und für die übrigen Werte

$$\begin{aligned} p_X(3) = p_X(11) &= \frac{2}{36}\,, \quad p_X(4) = p_X(10) = \frac{3}{36} \\ p_X(5) = p_X(9) &= \frac{4}{36}\,, \quad p_X(6) = p_X(8) = \frac{5}{36} \\ p_X(7) &= \frac{6}{36}\,. \end{aligned}$$

Graphische Veranschaulichung der Wahrscheinlichkeitsfunktion der Verteilung von X mit Hilfe eines Stabdiagramms:

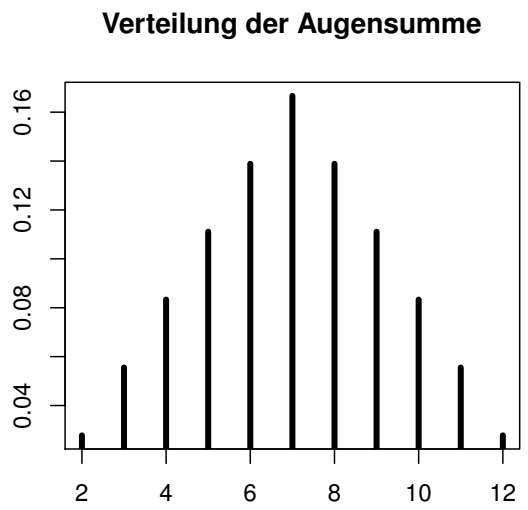

II.2.2 Die Verteilungsfunktion einer Zufallsvariablen

Die Funktion

$$F(x) := P(X \leq x) \qquad \text{für } x \in \mathbb{R}$$

heißt **Verteilungsfunktion** von X. Sie besitzt, genau wie die empirische Verteilungsfunktion (siehe Abschnitt I.2.2), folgende Eigenschaften:

- F ist monoton wachsend;
- $0 \leq F \leq 1$, $\lim_{x\to-\infty} F(x) = 0$, $\lim_{x\to\infty} F(x) = 1$;
- F ist rechtsseitig stetig.

In Analogie zu Abschnitt I.2.4 nennen wir jeden Wert x_q mit $q \in (0;1)$ und

$$P(X \leq x_q) = F(x_q) \geq q \qquad \text{sowie} \qquad P(X \geq x_q) \geq 1 - q$$

ein q-**Quantil** der diskreten Zufallsvariable X mit Verteilungsfunktion F.

II.2.3 Unabhängigkeit von Zufallsvariablen

Definition.
Es seien $X_1, X_2, \ldots, X_n$ Zufallsvariablen auf dem Wahrscheinlichkeitsraum (Ω, P). $X_1, \ldots, X_n$ heißen **(stochastisch) unabhängig**, falls für alle Teilmengen $B_1, \ldots, B_n$ von $\mathbb{R}$ gilt:

$$P(X_1 \in B_1, \ldots, X_n \in B_n) \;=\; P(X_1 \in B_1) \cdots P(X_n \in B_n)\,. \tag{II.12}$$

Die Zufallsvariablen $X_1, \ldots, X_n$ sind also genau dann (stochastisch) unabhängig, wenn für beliebige Teilmengen $B_1, \ldots, B_n$ die Ereignisse

$$\{X_1 \in B_1\}, \ldots, \{X_n \in B_n\}$$

(stochastisch) unabhängig sind.

Äquivalent zu (II.12) ist folgende, in der Praxis einfacher zu überprüfende Bedingung: Für alle $x_1, \ldots, x_n \in \mathbb{R}$ ist

$$P(X_1 = x_1, \ldots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n) . \tag{II.13}$$

Beachten Sie, dass $P(X_k = x_k) = 0$ für die weitaus meisten Werte $x_k \in \mathbb{R}$ gilt, nämlich mindestens für alle $x_k \in \mathbb{R} \setminus X_k(\Omega)$.
Die Unabhängigkeit bleibt unter Transformationen erhalten, d.h., sind $f_1, \ldots, f_n : \mathbb{R} \to \mathbb{R}$ Abbildungen, so sind auch die Zufallsvariablen

$$f_1(X_1), \ldots, f_n(X_n)$$

unabhängig. Um dies einzusehen beachte man, dass $\{f_i(X_i) = x_i\} = \{X_i \in f_i^{-1}(x_i)\}$ und somit

$$\begin{aligned} P\big(f_1(X_1) = x_1, \ldots, f_n(X_n) = x_n\big) &= P\big(X_1 \in f_1^{-1}(x_1), \ldots, X_n \in f_n^{-1}(x_n)\big) \\ &= P\big(X_1 \in f_1^{-1}(x_1)\big) \cdots P\big(X_n \in f_n^{-1}(x_n)\big) \\ &= P\big(f_1(X_1) = x_1\big) \cdots P\big(f_n(X_n) = x_n\big) . \end{aligned}$$

Aufgrund des Kriteriums (II.13) folgt die Unabhängigkeit von $f_1(X_1), \ldots, f_n(X_n)$.

Ein weiteres, zu (II.12) äquivalentes Kriterium ergibt sich auf Basis der Verteilungsfunktionen, siehe Abschnitt II.2.2: Für alle $x_1, \ldots, x_n \in \mathbb{R}$ ist

$$P(X_1 \le x_1, \ldots, X_n \le x_n) = P(X_1 \le x_1) \cdots P(X_n \le x_n) . \tag{II.14}$$

(II.14) folgt aus (II.12), indem man $B_i := (-\infty; x_i]$ setzt.

Beispiel.
Beim zweimaligen Würfeln sei X_1 die erste Augenzahl und X_2 die zweite. Mit (II.13) ist dann einfach zu sehen, dass X_1 und X_2 unabhängig sind. Ebenso sind auch die Zufallsvariablen $\sin(X_1)$ und X_2^2 unabhängig.

II.2.4 Spezielle Verteilungen

Bernoulli-Verteilung

Wir fixieren eine Teilmenge $A \subseteq \Omega$, und definieren die **binäre Zufallsvariable**

$$X(\omega) := \begin{cases} 1 & \text{für } \omega \in A, \\ 0 & \text{für } \omega \in A^c . \end{cases}$$

X heißt **Bernoulli-Zufallsvariable**. Wir interpretieren das Ereignis $\{X = 1\} = A$ als „Erfolg“. Dementsprechend bezeichnen wir

$$\pi := P(X = 1) = P(A)$$

als **Erfolgswahrscheinlichkeit**. Entsprechend gilt für die Wahrscheinlichkeit eines Misserfolges

$$P(X = 0) = P(A^c) = 1 - P(A) = 1 - \pi .$$

Definition.
Es sei $\pi \in [0; 1]$. Das durch die Wahrscheinlichkeitsfunktion $p : \{0, 1\} \to [0; 1]$ mit

$$p(1) = \pi \quad \text{und} \quad p(0) = 1 - \pi$$

definierte Wahrscheinlichkeitsmaß auf $\{0, 1\}$ heißt **Bernoulli-Verteilung zu** π. Zufallsexperimente, die nur zwei mögliche Ausgänge kennen, nennt man entsprechend **Bernoulli-Experimente**.

Beispiele für Bernoulli-Experimente:

- Werfen einer fairen Münze: $P(\text{„Kopf“}) = P(\text{„Zahl“}) = \frac{1}{2}$.
- Geschlecht eines Neugeborenen: $P(\text{„weiblich“}) = 0.47$, $P(\text{„männlich“}) = 0.53$.
- Ziehen einer Kugel aus einer Urne mit s schwarzen und w weißen Kugeln:
$$P(\text{„gezogene Kugel schwarz“}) = \frac{s}{s+w}.$$
- Meinungsumfrage, Konfrontation mit Aussage (z. B. Atomausstieg, Präimplantationsdiagnostik, ...): Zustimmung ja/nein.
- Funktionsfähigkeit eines Produkts: ja/nein.

Binomialverteilung

Es seien $X_1, \ldots, X_n$ unabhängige Zufallsvariablen, die alle Bernoulli-verteilt sind zu π; man spricht von einer **Bernoulli-Kette**. Wir können X_i als Ausgang eines Bernoulli-Experiments mit Erfolgswahrscheinlichkeit π interpretieren, wobei die Folge der n Experimente unabhängig ist (Beispiel: Meinungsumfrage, befrage n Personen). Dann zählt die Zufallsvariable

$$S_n := X_1 + \ldots + X_n \quad \in \{0, \ldots, n\}$$

die **Gesamtanzahl der Erfolge**.

Für die Verteilung P_{S_n} der Summe S_n gilt dann

$$p_{S_n}(k) = P(S_n = k) = \binom{n}{k} \pi^k (1-\pi)^{n-k} =: b(k; n, \pi), \qquad k \in \{0, 1, \ldots, n\}.$$

Begründung: $\binom{n}{k}$ ist gerade die Anzahl der n-Tupel mit genau k Einsen (und $n-k$ Nullen), siehe das dritte Urnenmodell in Abschnitt II.1.4, d. h. die Anzahl an Möglichkeiten, die k benötigten Einsen auf die n Positionen unserer Bernoulli-Kette $X_1, \ldots, X_n$ zu vergeben. Die Wahrscheinlichkeit für jede derartige Kombination von k Einsen und $n-k$ Nullen ergibt sich aufgrund der Unabhängigkeitsannahme als Produkt aus π^k, der Wahrscheinlichkeit für k Erfolge, und $(1-\pi)^{n-k}$, der Wahrscheinlichkeit für $n-k$ Misserfolge.

Definition. Es sei $n \in \mathbb{N}$ und $\pi \in [0; 1]$. Das durch die Wahrscheinlichkeitsfunktion

$$\begin{aligned} b(\cdot; n, \pi) \,:\, \{0, \ldots, n\} &\to [0; 1] \\ k &\mapsto \binom{n}{k} \pi^k (1-\pi)^{n-k} \end{aligned}$$

definierte Wahrscheinlichkeitsmaß auf $\{0, \ldots, n\}$ heißt **Binominalverteilung zu n und** π und wird mit $\mathrm{Bin}(n, \pi)$ bezeichnet. Die Verteilung $\mathrm{Bin}(1, \pi)$ entspricht dabei gerade der Bernoulli-Verteilung.

Wir haben insbesondere gesehen: Bei einer Folge von n unabhängigen Bernoulli-Experimenten mit Erfolgswahrscheinlichkeit π ist die Summe der Erfolge binominalverteilt mit Parametern n und π.

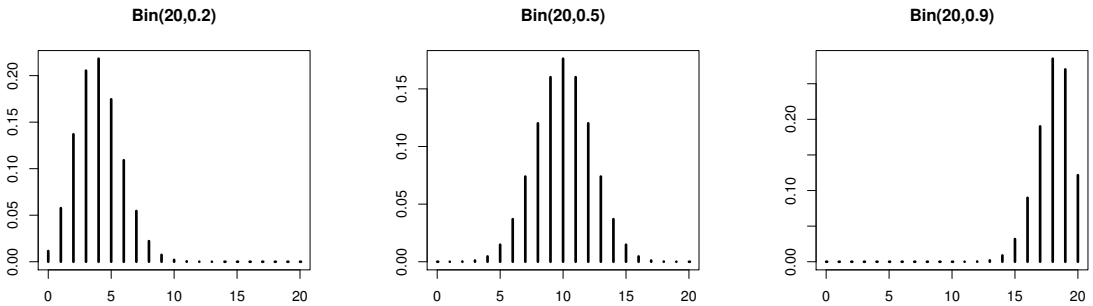

Bemerkung.
Für den Fall, dass die Erfolgswahrscheinlichkeit π eine rationale Zahl ist, können wir die Binomialverteilung durch die Stichprobenziehung aus einer Urne mit zwei Arten von Kugeln (z. B. weiß oder schwarz) repräsentieren. Die Gesamtzahl N von Kugeln (weiß oder schwarz) und die Anzahl K weißer Kugeln ist dabei so zu wählen, dass $\pi = \frac{K}{N}$ ist, d. h. die Erfolgswahrscheinlichkeit π wird in der Urne durch den Anteil weißer Kugeln repräsentiert. Aus dieser Urne gilt es nun n Kugeln zufällig zu ziehen, und wir zählen die zufällige Zahl X von weißen Kugeln unter den n gezogenen Kugeln.

Damit, wie von der Bernoulli-Kette gefordert, bei jedem Ziehen einer Kugel die Erfolgswahrscheinlichkeit gleich π ist, muss nach jedem Ziehen einer Kugel (und dem Notieren des Ergebnisses) diese Kugel wieder in die Urne zurückgelegt werden. Das **Ziehen mit Zurücklegen** führt also gerade zur Binomialverteilung. Würden wir aus unserer Urne dagegen die Stichprobe durch **Ziehen ohne Zurücklegen** gewinnen, so würde dies zur **hypergeometrischen Verteilung** führen. Diese besprechen wir zum Ende dieses Abschnitts.

Geometrische Verteilung

Wie groß ist die Wahrscheinlichkeit, dass man mit einem fairen Würfel genau k Versuche benötigt, bis zum ersten Mal eine 6 gewürfelt wird?

Für $k = 1$ ist die gesuchte Wahrscheinlichkeit offensichtlich $\frac{1}{6}$, für $k = 2$ ist sie gleich $\frac{5}{6} \cdot \frac{1}{6}$, denn die gesuchte Wahrscheinlichkeit ist aufgrund der Unabhängigkeit der beiden Würfe gleich dem Produkt aus der Wahrscheinlichkeit, beim ersten Würfeln keine 6 zu würfeln ($= \frac{5}{6}$), und der Wahrscheinlichkeit, beim zweiten Würfeln eine 6 zu würfeln ($= \frac{1}{6}$).

Für allgemeines k können wir wie folgt vorgehen: Wir definieren eine Folge von Zufallsvariablen $X_1, X_2, X_3, \ldots$ durch

$$X_k := 1 \text{ falls beim } k\text{-ten Wurf eine 6 gewürfelt wird}$$

und $X_k := 0$ sonst. Offenbar sind die Zufallsvariablen $X_1, X_2, X_3, \ldots$ unabhängig Bernoulliverteilt mit Erfolgswahrscheinlichkeit $\pi = \frac{1}{6}$. Das Ereignis A_k, im k-ten Wurf zum ersten Mal eine 6 zu würfeln, kann mit Hilfe dieser Zufallsvariablen nun wie folgt beschrieben werden:

$$A_k = \{X_1 = 0, X_2 = 0, \ldots, X_{k-1} = 0, X_k = 1\}\,.$$

Aufgrund der Unabhängigkeit der Zufallsvariablen ergibt sich für die gesuchte Wahrscheinlichkeit

$$\begin{aligned} P(A_k) &= P(X_1 = 0, X_2 = 0, \ldots, X_{k-1} = 0, X_k = 1) \\ &= P(X_1 = 0) \cdot P(X_2 = 0) \cdot \ldots \cdot P(X_{k-1} = 0) \cdot P(X_k = 1) \\ &= \frac{5}{6} \cdot \frac{5}{6} \cdot \ldots \cdot \frac{5}{6} \cdot \frac{1}{6} = \left(\frac{5}{6}\right)^{k-1} \frac{1}{6}\,. \end{aligned}$$

Allgemeiner:
Gegeben sei eine Folge von unabhängigen Zufallsvariablen $X_1, X_2, X_3, \ldots$, die alle Bernoulliverteilt sind zu $\pi > 0$. Definiere die **Wartezeit auf den ersten Erfolg** als

$$T := \min\{k \geq 1 \,|\, X_k = 1\}\,.$$

Wie in obigem Fall der Wartezeit auf die erste 6 beim Würfeln mit einem fairen Würfel, erhalten wir für die Verteilung von T

$$\begin{aligned} P(T = k) &= P(X_1 = 0, X_2 = 0, \ldots, X_{k-1} = 0, X_k = 1) \\ &= P(X_1 = 0) \cdot P(X_2 = 0) \cdot \ldots \cdot P(X_{k-1} = 0) \cdot P(X_k = 1) \\ &= (1 - \pi)^{k-1} \cdot \pi \qquad \text{für } k = 1, 2, 3, \ldots \end{aligned}$$

Definition.
Es sei $\pi \in (0;1]$. Das durch die Wahrscheinlichkeitsfunktion

$$\begin{aligned} g_\pi \,:\, \mathbb{N} &\mapsto [0;1] \\ k &\mapsto (1-\pi)^{k-1}\pi \end{aligned}$$

definierte Wahrscheinlichkeitsmaß auf $\mathbb{N}$ heißt **geometrische Verteilung zu** π und wird mit $\mathrm{Geom}(\pi)$ bezeichnet.

Poisson-Verteilung

Für $\lambda > 0$ definiert

$$p_\lambda(k) := e^{-\lambda}\frac{\lambda^k}{k!} \qquad \text{für } k \in \mathbb{N}_0$$

eine Wahrscheinlichkeitsfunktion auf $\mathbb{N}_0$, denn aus der Reihenentwicklung der Exponentialfunktion

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!} \qquad \text{für } x \in \mathbb{R}$$

folgt

$$\sum_{k=0}^{\infty} p_\lambda(k) = e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = e^{-\lambda}\cdot e^{\lambda} = e^0 = 1\,.$$

Definition.
Es sei $\lambda > 0$. Das durch die Wahrscheinlichkeitsfunktion

$$\begin{aligned} p_\lambda \,:\, \mathbb{N}_0 &\to [0;1] \\ k &\mapsto e^{-\lambda}\frac{\lambda^k}{k!} \end{aligned}$$

definierte Wahrscheinlichkeitsmaß auf $\mathbb{N}_0$ heißt **Poisson-Verteilung zu** λ und wird mit $\mathrm{Poi}(\lambda)$ bezeichnet.

Die Poisson-Verteilung empfiehlt sich als Näherung der Binomialverteilung $\mathrm{Bin}(n,\pi)$ für große n und kleine π. Die Approximation ist umso besser, je kleiner der Wert $n\pi^2$ ist. Diese Näherung wird gerechtfertigt durch die folgende Beobachtung.

Ergänzung: Poissonscher Grenzwertsatz

Es sei $(\pi_n) \subseteq [0;1]$ eine Folge von Erfolgsparametern mit $\lim_{n\to\infty} n\pi_n = \lambda > 0$. Dann folgt

$$\lim_{n\to\infty} b(k;n,\pi_n) = p_\lambda(k) \qquad \text{für alle } k \in \mathbb{N}_0\,.$$

Mit anderen Worten: Die Wahrscheinlichkeitsfunktion der Binomialverteilung $\mathrm{Bin}(n,\pi_n)$ konvergiert punktweise gegen die Wahrscheinlichkeitsfunktion der Poisson-Verteilung $\mathrm{Poi}(\lambda)$. Im Folgenden eine Illustration dieser Konvergenz für $\lambda = 2.5$.

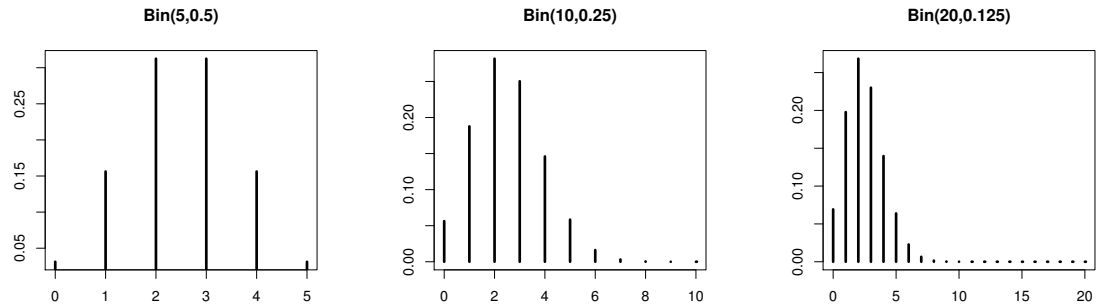

Zum Beweis des Poissonschen Grenzwertsatzes beachte man, dass unter der Annahme $\lim_{n\to\infty} n\pi_n = \lambda$ folgt

$$\begin{aligned}
\lim_{n\to\infty} b(k;n,\pi_n) &= \lim_{n\to\infty} \binom{n}{k} \pi_n^k (1-\pi_n)^{n-k} \\
&= \lim_{n\to\infty} \frac{1}{k!} \underbrace{\frac{n}{n}}_{\longrightarrow 1} \underbrace{\frac{(n-1)}{n}}_{\longrightarrow 1} \cdot \ldots \cdot \underbrace{\frac{(n-k+1)}{n}}_{\longrightarrow 1} \underbrace{(n\pi_n)^k}_{\longrightarrow \lambda^k} \underbrace{\left(1-\frac{n\pi_n}{n}\right)^{n-k}}_{\sim\left(1-\frac{\lambda}{n}\right)^n \longrightarrow e^{-\lambda}} \\
&= \frac{1}{k!}\lambda^k e^{-\lambda} = p_\lambda(k)\,.
\end{aligned}$$

Eine näherungsweise Berechnung von Wahrscheinlichkeiten gewisser Ereignisse mit Hilfe einer Poisson-Verteilung ist immer dann gerechtfertigt, wenn es sich um **seltene Ereignisse** handelt.

Beispiel.
Bei der Herstellung von Bauteilen ist ein Anteil von $\pi = 0.002$ bereits bei der Produktion defekt. Wie groß ist die Wahrscheinlichkeit, dass in einem Warenposten mit $n = 1.000$ Bauteilen mindestens fünf Schreiben defekt sind?
Zur Beantwortung dieser Frage sei X die Anzahl der defekten Bauteile. Da es sich bei der Produktion eines defekten Bauteils (eher) um ein seltenes Ereignis handelt, empfiehlt sich eine Näherung der Verteilung von X mit Hilfe einer Poisson-Verteilung. Den Parameter λ wählt man gemäß der Regel

$$\lambda = n\pi = 1000 \cdot 0.002 = 2\,.$$

Damit folgt für die gesuchte Wahrscheinlichkeit

$$\begin{aligned}
P(X \geq 5) = 1 - P(X \leq 4) &= 1 - e^{-2}\left(\frac{2^0}{0!} + \frac{2^1}{1!} + \frac{2^2}{2!} + \frac{2^3}{3!} + \frac{2^4}{4!}\right) \\
&= 1 - e^{-2}\left(1 + 2 + 2 + \frac{4}{3} + \frac{2}{3}\right) \approx 0.05\,.
\end{aligned}$$

Hypergeometrische Verteilung

Es sei eine Grundgesamtheit mit N Elementen gegeben, von denen K Elemente die Eigenschaft E besitzen. Aus dieser Grundgesamtheit werde n-mal **ohne** Zurücklegen gezogen. Wir sind interessiert an der Anzahl k der gezogenen Elemente, die die Eigenschaft E besitzen. Hierzu definieren wir

$$X = \text{Anzahl der gezogenen Elemente mit Eigenschaft } E.$$

Beispiel. (Hochrechnungen)
Ein See enthalte eine (unbekannte) Anzahl N von Fischen. Um N zu schätzen, markiere man zunächst K Fische mit rot. Danach ziehe man n ($n \leq N$) Fische aus dem See. Dann ist X die Anzahl der markierten Fische aus dieser Stichprobe und

$$\hat{N} := \frac{n}{X}K$$

ist eine natürliche Schätzung für die unbekannte Gesamtanzahl N. Zur Begründung beachte man, dass der Anteil $\frac{X}{n}$ an rot markierten Fischen in der Stichprobe dem Anteil $\frac{K}{N}$ aller rot markierten Fische an der Gesamtpopulation entsprechen sollte, d.h.

$$\frac{X}{n} \approx \frac{K}{N} \qquad \text{und damit } N \approx \frac{n}{X}K = \hat{N}\,.$$

Ist $\frac{n}{N}$ klein, so gibt es keinen großen Unterschied zwischen dem Ziehen **ohne** Zurücklegen und dem Ziehen **mit** Zurücklegen. Daher empfiehlt sich in diesem Falle eine Approximation der Verteilung von X durch die Binomialverteilung $\mathrm{Bin}(n, \pi)$ mit $\pi = \frac{K}{N}$, also

$$P(X = k) \approx b(k; n, \frac{K}{N}) \,. \tag{II.15}$$

Ist $\frac{n}{N}$ jedoch vergleichsweise groß, so muss die gesuchte Verteilung exakt berechnet werden:

$$P(X = k) = \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}} \qquad \text{für } k = 0, \ldots, n \,. \tag{II.16}$$

Zur Herleitung der Formel (II.16) für die gesuchte Wahrscheinlichkeit beachte man, dass $\binom{K}{k}$ (bzw. $\binom{N-K}{n-k}$) gerade die Anzahl der k (bzw. $n-k$)-elementigen Teilmengen einer K (bzw. $N-K$)-elementigen Grundmenge ist, wogegen $\binom{N}{n}$ die Anzahl aller n-elementigen Teilmengen der Grundgesamtheit aus N Elementen ist, siehe Abschnitt II.1.4.

Definition.
Es sei $K \leq N$, $n \leq N$. Das durch die Wahrscheinlichkeitsfunktion

$$\begin{aligned} h(\cdot; n, N, K) \,:\, \{0, \ldots, n\} &\to [0; 1] \\ k &\mapsto \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}} \end{aligned}$$

definierte Wahrscheinlichkeitsmaß auf $\{0, \ldots, n\}$ heißt **hypergeometrische Verteilung zu** n, N **und** K und wird mit $\mathrm{H}(n, N, K)$ bezeichnet.

Begründung von (II.15)**:**
Für $N, K \to \infty$ mit $\pi := \frac{K}{N}$ konstant, gilt

$$\begin{aligned} P(X = k) &= \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}} \\ &= \binom{n}{k} \frac{K!}{(K-k)!} \frac{(N-K)!}{((N-K)-(n-k))!} \frac{(N-n)!}{N!} \\ &= \binom{n}{k} \frac{K}{N} \frac{K-1}{N} \cdots \frac{K-k+1}{N} \frac{N-K}{N} \frac{N-K-1}{N} \cdots \frac{N-K-(n-k)+1}{N} \\ &\qquad \frac{N}{N} \frac{N}{N-1} \cdots \frac{N}{N-n+1} \quad \to \binom{n}{k} \pi^k (1-\pi)^{n-k} \,. \end{aligned}$$

II.2.5 Die wichtigsten diskreten Verteilungen im Überblick

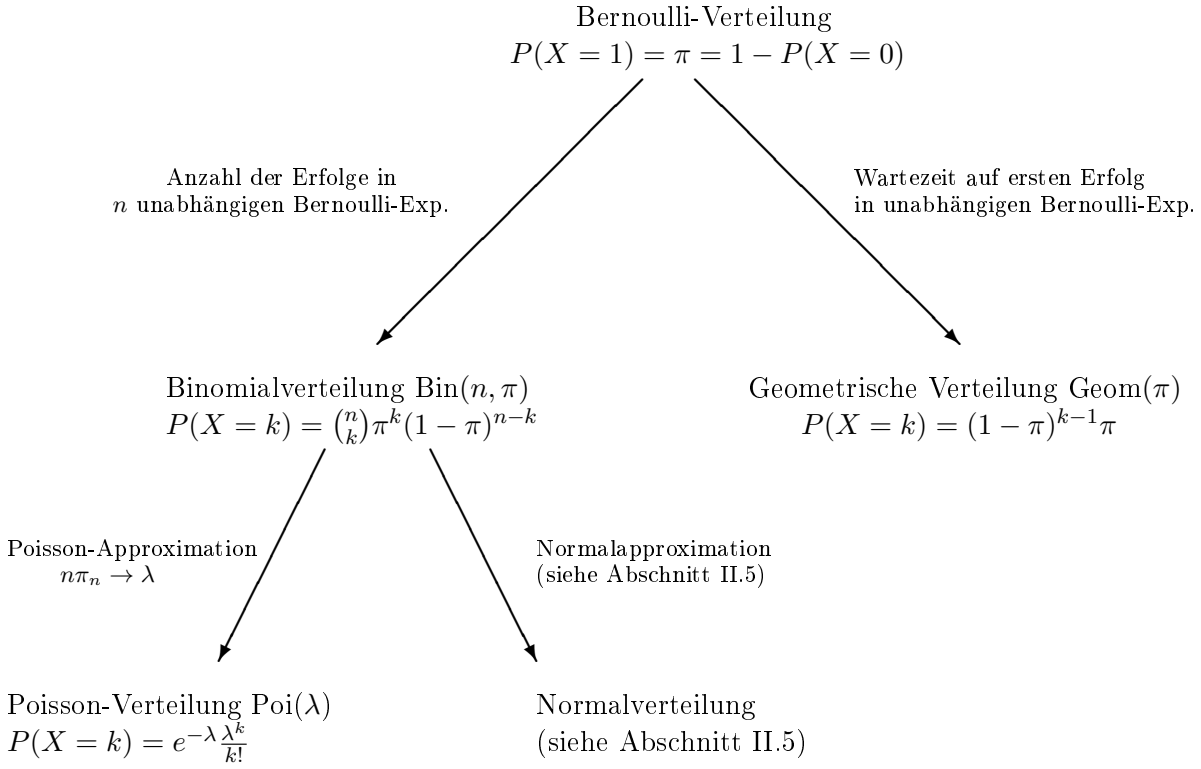

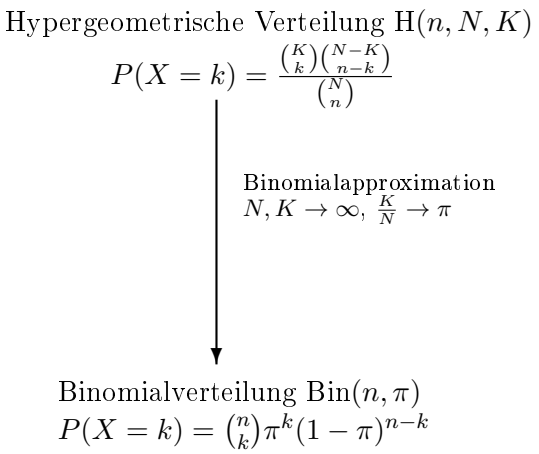

II.3 Erwartungswert und Varianz

Erwartungswert und Varianz sind die beiden wichtigsten Kennzahlen einer Zufallsvariablen. Im ganzen Abschnitt sei (Ω, P) ein diskreter Wahrscheinlichkeitsraum, p die zugehörige Wahrscheinlichkeitsfunktion.

II.3.1 Erwartungswert

Der **Erwartungswert** $E[X]$ einer Zufallsvariablen X wird definiert als der Mittelwert

$$E[X] := \sum_{\omega \in \Omega} X(\omega) p(\omega) \tag{II.17}$$

der Funktionswerte $X(\omega)$ gewichtet mit den Einzelwahrscheinlichkeiten $p(\omega)$.

Bemerkung. Ist Ω endlich, so bereitet diese Definition keine Probleme. Im Falle Ω unendlich muss man noch Sorge tragen, dass die Reihe (II.17) absolut konvergiert. Dies ist dann der Fall, wenn die Reihe

$$\sum_{\omega \in \Omega} |X(\omega)| p(\omega)$$

konvergiert, und man sagt in diesem Fall, dass der Erwartungswert $E[X]$ von X existiert.

Beispiel.
X sei die Augenzahl beim Würfeln eines fairen Würfels. Dann gilt

$$E[X] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{7}{2}\,.$$

Der Erwartungswert stimmt also in diesem Falle mit dem arithmetischen Mittel der Funktionswerte überein.

Es sei X eine Zufallsvariable, deren Erwartungswert existiert. Ist $x_1, x_2, \ldots$ eine Aufzählung des Bildes $X(\Omega)$ von X, so folgt

$$\begin{aligned} E[X] &= \sum_{\omega \in \Omega} X(\omega) p(\omega) = \sum_k \sum_{\omega \in \Omega \,:\, X(\omega) = x_k} X(\omega) p(\omega) \\ &= \sum_k x_k P\left(X = x_k\right) = \sum_k x_k p_X(x_k)\,. \end{aligned}$$

Insbesondere gilt also, dass der Erwartungswert einer Zufallsvariablen X **nur von ihrer Verteilung p_X abhängt**!

Rechenregeln für Erwartungswerte

Es seien X, Y Zufallsvariablen, deren Erwartungswerte existieren. Dann gilt:

- **Linearität:** $E[aX + bY] = aE[X] + bE[Y]$ für alle $a, b \in \mathbb{R}$.
- **Nichtnegativität:** $X \geq 0$ (d.h. $X(\omega) \geq 0$ für alle $\omega \in \Omega$)

$$\Longrightarrow \qquad E[X] \geq 0\,.$$

- **Monotonie:** $X \leq Y$ (d.h. $Y - X \geq 0$)

$$\Longrightarrow \qquad E[X] \leq E[Y]\,.$$

- Ist X konstant, also $X = c$ für eine Konstante c (d.h. $X(\omega) = c$ für alle $\omega \in \Omega$), so folgt

$$E[X] = c\,.$$

- **Transformationssatz:** Ist $h : \mathbb{R} \to \mathbb{R}$ und ist $x_1, x_2, x_3, \ldots$ eine Aufzählung des Bildes $X(\Omega)$, so gilt: Der Erwartungswert der Zufallsvariablen $h(X)$ existiert genau dann, wenn die Summe $\sum_k |h(x_k)| p_X(x_k) < \infty$ konvergiert, und in diesem Fall ist

$$E\left[h(X)\right] = \sum_k h(x_k) p_X(x_k). \tag{II.18}$$

- Sind X,Y **unabhängig**, so existiert auch der Erwartungswert von XY, und es gilt

$$E[XY] = E[X]\, E[Y]\,.$$

Beispiel: Bernoulli-Verteilung und Binomialverteilung.
Sind $X_1, \ldots, X_n$ unabhängig Bernoulli-verteilt mit Erfolgswahrscheinlichkeit π, so folgt

$$E[X_k] = 0 \cdot P(X_k = 0) + 1 \cdot P(X_k = 1) = \pi\,.$$

Insbesondere gilt für den Erwartungswert der Summe $S_n = X_1 + \ldots + X_n$, dass

$$E[S_n] = E[X_1] + \ldots + E[X_n] = \pi + \ldots + \pi = n\pi\,.$$

Da S_n binomialverteilt ist mit Parameter n und π, folgt insbesondere: Für den Erwartungswert einer binomialverteilten Zufallsvariablen S_n mit Parametern n und π gilt:

$$E[S_n] = n\pi\,.$$

Beispiel: Berechnung der sog. Momenterzeugenden Funktion der Binomialverteilung.
Die Anwendung des Transformationssatzes ergibt, dass für $\alpha \in \mathbb{R}$

$$\begin{aligned} E\left[e^{\alpha X_i}\right] &= e^{\alpha 0} P(X_i = 0) + e^{\alpha 1} P(X_i = 1) \\ &= e^0 (1-\pi) + e^{\alpha 1}\pi = (1-\pi) + \pi e^{\alpha}\,, \end{aligned}$$

also

$$E\left[e^{\alpha X_i}\right] = (1-\pi) + \pi e^{\alpha} \qquad \text{für } i = 1, \ldots, n$$

ist. Damit folgt wegen der Unabhängigkeitsannahme, dass

$$\begin{aligned} E\left[e^{\alpha S_n}\right] &= E\left[e^{\alpha \sum_{i=1}^n X_i}\right] = E\left[e^{\alpha X_1} e^{\alpha X_2} \ldots e^{\alpha X_n}\right] \\ &= E\left[e^{\alpha X_1}\right] E\left[e^{\alpha X_2}\right] \cdots E\left[e^{\alpha X_n}\right] = (1 - \pi + \pi e^{\alpha})^n\,. \end{aligned}$$

Beispiel: Poisson-Verteilung.
Ist X Poi(λ)-verteilt, so folgt

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k P(X = k) = \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \sum_{k=1}^{\infty} e^{-\lambda} \frac{\lambda\, \lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = \lambda\,. \end{aligned}$$

Für die momenterzeugende Funktion folgt mit dem Transformationssatz:

$$\begin{aligned} E\left[e^{\alpha X}\right] &= \sum_{k=0}^{\infty} e^{\alpha k} P(X = k) = \sum_{k=0}^{\infty} e^{\alpha k} e^{-\lambda} \frac{\lambda^k}{k!} \\ &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{(e^{\alpha}\lambda)^k}{k!} = e^{-\lambda} e^{e^{\alpha}\lambda} = e^{-\lambda(1-e^{\alpha})}\,. \end{aligned}$$

II.3.2 Varianz

Ein Maß für die Streuung der Funktionswerte $X(\omega)$ um ihren Erwartungswert $E[X]$ ist die mittlere quadratische Abweichung

$$V[X] := E\left[(X - E[X])^2\right] = \sum_{\omega\in\Omega} (X(\omega) - E[X])^2\, p(\omega)\,. \tag{II.19}$$

Sie heißt **Varianz** von X. Gängige Kurzschreibweisen: $\mu_X := E[X]$, $\sigma_X^2 := V[X]$.

Bemerkung. Damit der Ausdruck (II.19) wohldefiniert ist, müssen die Erwartungswerte $E[X]$ und $E\left[(X - E[X])^2\right]$ existieren. Man kann zeigen, dass beide existieren, falls der Erwartungswert $E[X^2]$ von X^2 existiert.

Unter der **Standardabweichung** von X versteht man die Größe

$$\sigma_X := \sqrt{V[X]}\,.$$

Wie der Erwartungswert, so hängt auch die Varianz (und damit auch die Standardabweichung) nur von der Verteilung P_X von X unter P ab. Ist nämlich $x_1, x_2, x_3 \ldots$ eine Aufzählung der Werte von X, so folgt aus dem Transformationssatz

$$V[X] = E\left[(X - E[X])^2\right] = \sum_k (x_k - E[X])^2\, p_X(x_k)\,.$$

Beispiel: X sei die Augenzahl beim Würfeln eines fairen Würfels. Dann folgt

$$V[X] = \left(1 - \frac{7}{2}\right)^2 \cdot \frac{1}{6} + \left(2 - \frac{7}{2}\right)^2 \cdot \frac{1}{6} + \ldots + \left(6 - \frac{7}{2}\right)^2 \cdot \frac{1}{6} = \frac{35}{12}\,.$$

Rechenregeln für Varianzen

Es seien $X, Y, X_1, \ldots, X_n$ Zufallsvariablen, für die die Erwartungswerte $E[X^2]$ und $E[Y^2]$, $E[X_1^2], \ldots, E[X_n^2]$ existieren. Dann gilt:

- $V[aX + b] = a^2 V[X]$ für alle $a, b \in \mathbb{R}$.

  Begründung: Aus $E[aX + b] = aE[X] + b$ folgt

  $$V[aX + b] = E\left[(aX + b - E[aX + b])^2\right] = E\left[(aX - aE[X])^2\right] = a^2\, V[X]\,.$$

- **Verschiebungssatz:** $V[X] = E[X^2] - (E[X])^2$.

  Begründung:

  $$\begin{aligned} V[X] &= E\left[(X - E[X])^2\right] = E\left[X^2 - 2X \cdot E[X] + (E[X])^2\right] \\ &= E[X^2] - 2(E[X])^2 + (E[X])^2 = E[X^2] - (E[X])^2\,. \end{aligned}$$

- X, Y unabhängig $\Rightarrow V[X + Y] = V[X] + V[Y]$.

  Begründung:

  $$\begin{aligned} V[X+Y] &= E\left[(X+Y)^2\right] - (E[X+Y])^2 \\ &= E[X^2 + 2XY + Y^2] - (E[X] + E[Y])^2 \\ &= E[X^2] + 2E[XY] + E[Y^2] - \left((E[X])^2 + 2E[X]E[Y] + (E[Y])^2\right) \\ &= E[X^2] - (E[X])^2 + E[Y^2] - (E[Y])^2 + 2\left(E[XY] - E[X]E[Y]\right) \\ &= V[X] + V[Y] + 2\left(E[XY] - E[X]E[Y]\right)\,. \end{aligned}$$

  Da X und Y unabhängig, folgt $E[XY] = E[X]E[Y]$, und damit verschwindet der dritte Term auf der rechten Seite.

Allgemeiner gilt die **Identität von Bienaymé:**

Sind $X_1 \ldots, X_n$ unabhängig, so folgt

$$V[X_1 + \ldots + X_n] = V[X_1] + \ldots + V[X_n]\,.$$

Beispiel: Bernoulli-Verteilung und Binomialverteilung.

Sind $X_1, \ldots, X_n$ unabhängig Bernoulli-verteilt mit Erfolgswahrscheinlichkeit π, so folgt für die Varianz der Summe $S_n = X_1 + \ldots + X_n$, dass

$$V[S_n] = V[X_1 + \ldots + X_n] = V[X_1] + \ldots + V[X_n]\,.$$

Für die Varianz der Bernoulli-verteilten Zufallsvariablen X_k errechnet man sofort

$$V[X_k] = E[X_k^2] - (E[X_k])^2 = 0^2 \cdot P(X_k = 0) + 1^2 \cdot P(X_k = 1) - (\pi)^2 = \pi - \pi^2 = \pi(1-\pi)\,,$$

so dass

$$V[S_n] = n\pi(1-\pi)\,.$$

Da S_n binomialverteilt ist mit Parameter n und π, folgt insbesondere: Für die Varianz einer binomialverteilten Zufallsvariablen S_n mit Parameter n und π gilt

$$V[S_n] = n\pi(1-\pi)\,.$$

Beispiel: Poisson-Verteilung.

Ist X Poi(λ)-verteilt, so folgt

$$\begin{aligned}
E[X^2] &= \sum_{k=0}^{\infty} k^2 P(X = k) = \sum_{k=1}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!} \\
&= \sum_{k=1}^{\infty} (k-1+1) e^{-\lambda} \frac{\lambda \cdot \lambda^{k-1}}{(k-1)!} \\
&= \lambda \sum_{k=1}^{\infty} (k-1) e^{-\lambda} \frac{\lambda^{k-1}}{(k-1)!} + \lambda \sum_{k=1}^{\infty} e^{-\lambda} \frac{\lambda^{k-1}}{(k-1)!} \\
&= \lambda \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} + \lambda = \lambda^2 + \lambda\,,
\end{aligned}$$

also

$$V[X] = E[X^2] - (E[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda\,.$$

Tabelle: Erwartungswerte und Varianzen diskreter Verteilungen.

	$E[X]$	$V[X]$
$X \sim$ Bernoulli(π)	π	$\pi(1-\pi)$
$X \sim$ Bin(n, π)	$n\pi$	$n\pi(1-\pi)$
$X \sim$ Geom(π)	$\frac{1}{\pi}$	$\frac{1-\pi}{\pi^2}$
$X \sim$ Poi(λ)	λ	λ
$X \sim$ H(n, N, K)	$n\frac{K}{N}$	$n\frac{K}{N}(1-\frac{K}{N})\frac{N-n}{N-1}$

II.3.3 Ergänzung: Die Ungleichung von Tschebyschow

In Abschnitt II.3.1 hatten wir den Erwartungswert μ einer Zufallsvariablen X als ein mit Wahrscheinlichkeiten gewichtetes Mittel definiert, welches die **Lage einer Verteilung** charakterisiert. Die Varianz σ^2, als mittlere quadratische Abweichung um den Erwartungswert, haben wir in Abschnitt II.3.2 als ein **Streuungsmaß** kennengelernt, welches im genannten Sinne quantifiziert, wie stark die Realisationen einer Zufallsvariable vom Erwartungswert abweichen können. Wir fragen uns nun: Bei gegebenen Wert σ^2, mit welcher Wahrscheinlichkeit wird man ein gewisses Ausmaß von Abweichung vom Erwartungswert μ beobachten? In der Praxis betrachtet man im Zusammenhang mit dieser Frage gerne sog. „k-σ-Bereiche", siehe etwa folgendes Beispiel eines 2-σ-Bereichs ($\mu = 5$ und $\sigma = 3$):

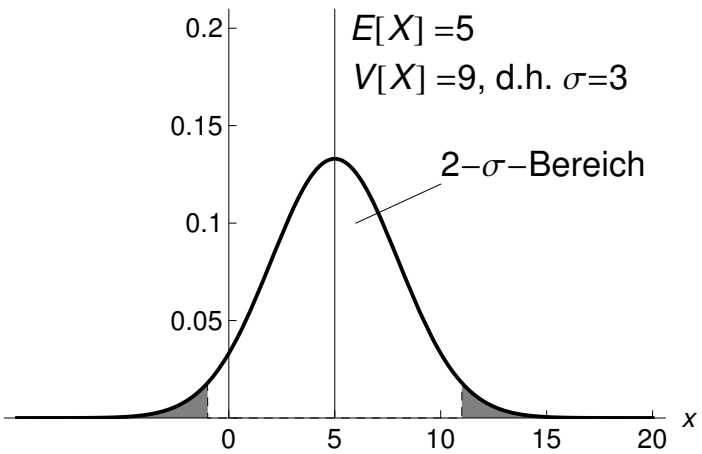

Mit welcher Wahrscheinlichkeit wird man Beobachtungen erhalten, die um mindestens das k-fache der Standardabweichung σ von μ abweichen (oben grau markiert), d. h.

$$P\big(|X-\mu| \geq k\cdot\sigma\big) \;=\; ? \tag{II.20}$$

Satz (Tschebyschowsche Ungleichung)[1]

Es sei X eine Zufallsvariable, für die der Erwartungswert von X^2 existiert, es sei $E[X] = \mu$ und $V[X] = \sigma^2$. Dann gilt für alle $k > 0$, dass

$$P\big(|X-\mu| \geq k\cdot\sigma\big) \;\leq\; \frac{1}{k^2}. \tag{II.21}$$

Beweis: Wir definieren die „Hilfszufallsvariable"

$$Y \;:=\; \begin{cases} 0, & \text{falls } |X-\mu| < k\cdot\sigma, \\ k^2\sigma^2, & \text{falls } |X-\mu| \geq k\cdot\sigma. \end{cases}$$

Y ist eine diskrete Zufallsvariable mit den zwei möglichen Werten 0 und $k^2\sigma^2$. Ihren Erwartungswert errechnen wir somit gemäß Abschnitt II.3.1 zu

$$E[Y] \;=\; 0\cdot P(Y=0) \;+\; k^2\sigma^2\cdot P(Y=k^2\sigma^2) \;=\; 0 \;+\; k^2\sigma^2\cdot P\big(|X-\mu| \geq k\cdot\sigma\big).$$

Ferner wurde Y so definiert, dass stets $Y \leq (X-\mu)^2$ ist, vgl. folgende Abbildung:

[1] Die Ungleichung ist nach dem russischen Mathematiker Pafnuti Tschebyschow benannt. Dessen Nachname wird oft auch als Tschebyschew, Tschebyscheff, Tschebyshev oder Chebyshev (Letzteres vor allem im Englischen) transkribiert.

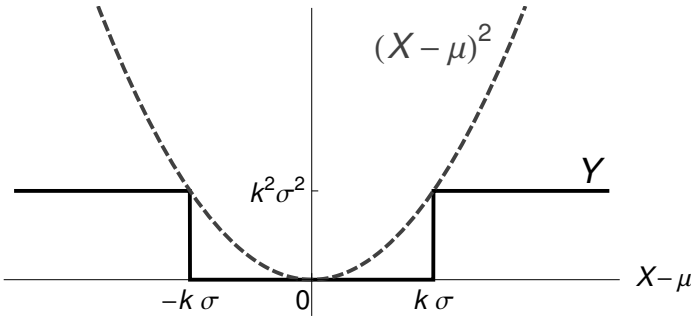

Entsprechend ist auch

$$E[Y] \;\le\; E\big[(X-\mu)^2\big] = V[X] = \sigma^2.$$

Wir erhalten also insgesamt die Ungleichung

$$k^2\sigma^2 \cdot P\big(|X-\mu| \ge k\cdot\sigma\big) \;\le\; \sigma^2,$$

woraus nach Division durch $k^2\sigma^2$ die Behauptung folgt. □

Analog zur empirischen Tschebyschow-Ungleichung (siehe Abschnitt I.2.5) quantifizert die Tschebyschow-Ungleichung (II.21) die Streuung der Funktionswerte von X um ihren Erwartungswert, insbesondere:

- $P\left(\mu-\sqrt{2}\sigma \le X \le \mu+\sqrt{2}\sigma\right) \ge \frac{1}{2} = 0,5,$
- $P\left(\mu-2\sigma \le X \le \mu+2\sigma\right) \ge \frac{3}{4} = 0,75,$
- $P\left(\mu-3\sigma \le X \le \mu+3\sigma\right) \ge \frac{8}{9} = 0,889$ (gerundet).

Begründung: Aus der Tschebyschowschen Ungleichung (II.21) folgt

$$\begin{aligned} P\left(\mu-k\sigma \le X \le \mu+k\sigma\right) &= P\left(|X-\mu| \le k\sigma\right) \\ &\ge P\left(|X-\mu| < k\sigma\right) \\ &= 1-P\left(|X-\mu| \ge k\sigma\right) \\ &\ge 1-\frac{1}{k^2}\,. \end{aligned}$$

Bemerkung. Abgesehen von der Forderung nach Existenz von Erwartungswert und Varianz stellt die Ungleichung von Tschebyschow keinerlei weitere Bedingungen an die Verteilung von X, d. h. sie ist eine in diesem Sinne allgemeingültige Gesetzmäßigkeit! Andererseits liefert sie auf Grund ihrer Allgemeingültigkeit auch nur eine grobe Abschätzung der Wahrscheinlichkeit (II.20). Kennt man neben Erwartungswert und Varianz sogar die komplette Verteilung von X, dann kann man die Wahrscheinlichkeit (II.20) natürlich exakt berechnen, siehe etwa Abschnitt II.4.6 für den Fall einer normalverteilten Zufallsvariable.

II.3.4 Kovarianz und Korrelation

Sind X und Y zwei Zufallsvariablen, deren Varianzen existieren, so ist die **Kovarianz**

$$Cov[X,Y] := E\left[\big(X-E[X]\big)\big(Y-E[Y]\big)\right]$$

wohldefiniert. Sie ist das Analogon zur empirischen Kovarianz einer zweidimensionalen Messreihe, siehe Abschnitt I.3.3. Die Größe

$$\rho_{XY} := Corr[X,Y] := \frac{Cov[X,Y]}{\sqrt{V[X]}\sqrt{V[Y]}}$$

heißt dementsprechend der **Korrelationskoeffizient** von X und Y. Ist $\rho_{XY} = 0$, so heißen X und Y **unkorreliert**.

Die Kovarianz hängt nur von der **gemeinsamen Verteilung** p_{XY} der Zufallsvariablen X und Y unter P ab. Hierunter versteht man die diskrete Wahrscheinlichkeitsverteilung zur Wahrscheinlichkeitsfunktion

$$p_{XY}(x,y) := P(X = x, Y = y) \qquad \text{für } x \in X(\Omega) \text{ und } y \in Y(\Omega)$$

auf dem Produktraum $X(\Omega) \times Y(\Omega) := \{(x,y) \mid x \in X(\Omega), y \in Y(\Omega)\} \subseteq \mathbb{R}^2$.

Ist nämlich $x_1, x_2, x_3, \ldots$ eine Aufzählung der Werte von X und $y_1, y_2, y_3, \ldots$ eine Aufzählung der Werte von Y, so folgt

$$\begin{aligned} Cov[X,Y] &= \sum_{\omega \in \Omega} (X(\omega) - E[X])\,(Y(\omega) - E[Y]) \cdot p(\omega) \\ &= \sum_k \sum_l \sum_{\omega \in \Omega\,:\, X(\omega) = x_k, Y(\omega) = y_l} (x_k - E[X])\,(y_l - E[Y])\, p(\omega) \\ &= \sum_k \sum_l (x_k - E[X])\,(y_l - E[Y])\, p_{XY}(x_k, y_l)\,. \end{aligned}$$

Rechenregeln für Kovarianzen:

- $Cov[aX + b,\ cY + d] = ac \cdot Cov[X,Y]$ für alle $a, b, c, d \in \mathbb{R}$.

  Begründung:

  $$\begin{aligned} Cov[aX + b,\ cY + d] &= E\left[(aX + b - E[aX + b])(cY + d - E[cY + d])\right] \\ &= E\left[a(X - E[X])c(Y - E[Y])\right] = ac \cdot Cov[X,Y]\,. \end{aligned}$$

- **Verschiebungssatz:** $Cov[X,Y] = E[XY] - E[X]E[Y]$.

  Begründung:

  $$\begin{aligned} Cov[X,Y] &= E\big[(X - E[X])(Y - E[Y])\big] \\ &= E\big[XY - X \cdot E[Y] - E[X] \cdot Y + E[X]E[Y]\big] \\ &= E[XY] - 2E[X]E[Y] + E[X]E[Y] = E[XY] - E[X]E[Y]. \end{aligned}$$

- Insbesondere: X, Y unabhängig $\Rightarrow Cov[X,Y] = 0$. Die Umkehrung gilt im Allgemeinen nicht.

II.4 Stetige Verteilungen

In vielen Fällen ist der Wertebereich einer Zufallsvariablen X nicht diskret (z.B. Wartezeiten, Laufzeiten, Körpergröße, Lufttemperatur, ...), sondern muss als Intervall $[a;b]$ oder gleich ganz $\mathbb{R}$ gewählt werden. Eine solche Zufallsvariable kann natürlich nicht auf einem diskreten Wahrscheinlichkeitsraum (Ω, P) definiert sein. Es bedarf hierzu also einer Erweiterung des Begriffes des Wahrscheinlichkeitsraumes auf überabzählbare Ergebnismengen Ω. Die mathematische Theorie zur rigorosen Durchführung dieser Erweiterung sprengt eindeutig den Rahmen dieser Vorlesung, man findet sie in Büchern zur Wahrscheinlichkeitstheorie.

Im Folgenden betrachten wir nur den für die Anwendungen enorm wichtigen Fall stetig verteilter Zufallsvariablen X.

II.4.1 Stetige Verteilungen: Dichte und Verteilungsfunktion

Wir nennen X **stetig verteilt mit Dichte** f, falls gilt

$$P(X \leq b) = \int_{-\infty}^{b} f(x)\,dx \qquad \text{für alle } b \in \mathbb{R}\,. \tag{II.22}$$

Hierbei ist $f : \mathbb{R} \to \mathbb{R}$ eine uneigentlich Riemann-integrierbare Funktion mit

- $f(x) \geq 0$ für alle $x \in \mathbb{R}$,
- $\int_{-\infty}^{+\infty} f(x)\,dx = 1$.

Für eine mit Dichte f stetig verteilte Zufallsvariable X wird also die Wahrscheinlichkeit der Ereignisse

$$\{\omega \,|\, X(\omega) \leq b\}$$

durch die folgende, schraffierte Fläche angegeben:

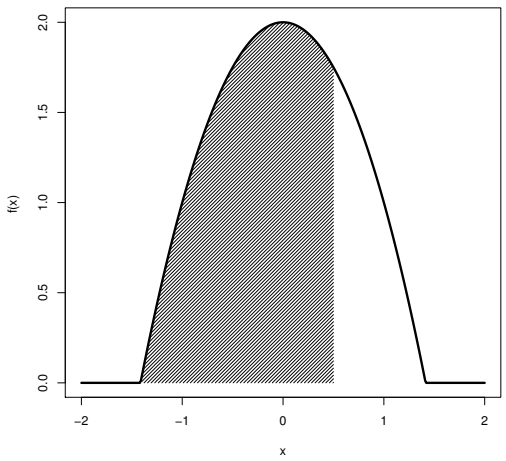

Wie im Falle diskreter Zufallsvariablen heißt die Funktion

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\,dt \qquad \text{für } x \in \mathbb{R}$$

die **Verteilungsfunktion** von X, vgl. Abschnitt II.2.2. Sie besitzt genau dieselben Eigenschaften wie im diskreten Fall, d.h.

- F ist monoton wachsend;
- $0 \leq F \leq 1$, $\lim_{x\to-\infty} F(x) = 0$, $\lim_{x\to\infty} F(x) = 1$;

- F ist (rechtsseitig) stetig.

Ist X stetig verteilt mit Verteilungsfunktion F und ist $q \in (0;1)$, so heißt jede Zahl $x_q \in \mathbb{R}$ mit

$$F(x_q) = q$$

q-Quantil der Verteilung von X, vgl. Abschnitt I.2.4. Ist F streng monoton steigend, d.h., $F(x) < F(y)$ für alle $x < y$, so ist $x_q = F^{-1}(q)$ eindeutig bestimmt durch den Wert der Umkehrfunktion F^{-1} von F in q.

Mit Hilfe von (II.22) können wir dann auch sofort die Wahrscheinlichkeit des Ereignisses $\{\omega \,|\, a < X(\omega) \leq b\}$ berechnen, denn

$$\begin{aligned} P(a < X \leq b) &= P(X \leq b) - P(X \leq a) = F(b) - F(a) \\ &= \int_{-\infty}^{b} f(x)\,dx - \int_{-\infty}^{a} f(x)\,dx = \int_{a}^{b} f(x)\,dx\,. \end{aligned} \tag{II.23}$$

Für eine stetig verteilte Zufallsvariable X gilt

$$P(X = x) = 0 \qquad \text{für alle } x \in \mathbb{R}\,,$$

d.h. X nimmt einen **bestimmten** Wert x nur mit Wahrscheinlichkeit 0 an. Dies ist ein fundamentaler Unterschied zu diskreten Zufallsvariablen. Damit gilt insbesondere

$$P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b) \qquad \text{für alle } a, b \in \mathbb{R}\,. \tag{II.24}$$

II.4.2 Stochastische Unabhängigkeit

Der Begriff der stochastischen Unabhängigkeit aus Abschnitt II.2.3 lässt sich unmittelbar auf stetig verteilte Zufallsvariablen übertragen. Zwei (stetig verteilte) Zufallsvariablen X und Y heißen **stochastisch unabhängig**, falls

$$P(X \leq x\,, Y \leq y) = P(X \leq x) \cdot P(Y \leq y) \qquad \text{für alle } x, y \in \mathbb{R}\,,$$

in Analogie zu Formel (II.14).

Allgemeiner: Die (stetig verteilten) Zufallsvariablen $X_1, \ldots, X_n$ heißen **stochastisch unabhängig**, falls

$$P(X_1 \leq x_1, X_2 \leq x_2, \ldots, X_n \leq x_n) = P(X_1 \leq x_1) \cdot P(X_2 \leq x_2) \cdots P(X_n \leq x_n) \tag{II.25}$$

für alle $x_1, x_2, \ldots, x_n \in \mathbb{R}$.

II.4.3 Erwartungswert, Varianz und Kovarianz

Ist X stetig verteilt mit Dichte f, so sagen wir, dass der **Erwartungswert** $E[X]$ von X existiert, falls die Funktion $|x|f(x)$ uneigentlich Riemann-integrierbar ist (dann ist auch $xf(x)$ uneigentlich Riemann-integrierbar). Man setzt in diesem Falle

$$E[X] := \int_{-\infty}^{+\infty} x f(x)\,dx\,.$$

Ist zusätzlich auch die Funktion $(x - E[X])^2 f(x)$ uneigentlich Riemann-integrierbar, so definiert man die **Varianz** $V[X]$ durch

$$V[X] := \int_{-\infty}^{+\infty} (x - E[X])^2 f(x)\, dx,$$

und die **Standardabweichung** wie im diskreten Fall durch

$$\sigma_X := \sqrt{V[X]}\,.$$

Die Rechenregeln für Erwartungswerte und Varianz diskret verteilter Zufallsvariablen (siehe Abschnitt II.3) übertragen sich unmittelbar auf den Fall stetig verteilter Zufallsvariablen. Der **Transformationssatz** überträgt sich dabei wie folgt:

Ist $h : \mathbb{R} \to \mathbb{R}$ eine stückweise stetige Funktion, so gilt: Der Erwartungswert der Zufallsvariablen $h(X)$ existiert genau dann, wenn die Funktion $|h(x)|f(x)$ uneigentlich Riemann-integrierbar ist, und in diesem Fall ist

$$E\left[h(X)\right] = \int_{-\infty}^{+\infty} h(x) f(x)\, dx\,. \tag{II.26}$$

Tabelle: Gegenüberstellung: diskret und stetig verteilte Zufallsvariablen.

diskrete Zufallsvariable X	stetige Zufallsvariable X
diskreter Wertebereich $\{x_1, x_2, \ldots\}$	stetiger Wertebereich $\subseteq \mathbb{R}$
Wahrscheinlichkeitsfunktion $0 \le p_X(x_k) \le 1$ $\sum_k p_X(x_k) = 1$	Dichte $f : \mathbb{R} \to \mathbb{R}_+$ $f(x) \ge 0$ $\int_{-\infty}^{+\infty} f(x)\, dx = 1$
Verteilungsfunktion $F(x) = P(X \le x)$	
$F(x) = \sum_{k: x_k \le x} p_X(x_k)$	$F(x) = \int_{-\infty}^{x} f(t)\, dt$
Wahrscheinlichkeiten	
$P(a \le X \le b) = \sum_{k: a \le x_k \le b} p_X(x_k)$	$P(a \le X \le b) = \int_a^b f(x)\, dx$
Erwartungswert	
$E[X] = \sum_k x_k p_X(x_k)$	$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x)\, dx$
Varianz	
$V[X] = \sum_k (x_k - E[X])^2 p_X(x_k)$	$V[X] = \int_{-\infty}^{+\infty} (x - E[X])^2 f(x)\, dx$

Ergänzung: Gemeinsame stetige Verteilung und Kovarianz.
Zwei Zufallsvariablen X und Y heißen **gemeinsam stetig verteilt** mit **gemeinsamer stetiger Dichte** f_{XY}, falls gilt:

$$P(X \le a, Y \le b) = \int_{-\infty}^{a} \int_{-\infty}^{b} f_{XY}(x, y)\, dy\, dx \qquad \text{für alle } a, b \in \mathbb{R},$$

wobei $f_{XY} : \mathbb{R}^2 \to \mathbb{R}$ eine integrierbare Funktion ist mit

- $f_{XY}(x, y) \ge 0$ für alle $x, y \in \mathbb{R}$, und
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{XY}(x, y)\, dx\, dy = 1$.

Die Berechnung der **Kovarianz** $Cov[X, Y]$ erfolgt dann über die gemeinsame Dichte mit Hilfe der Formel

$$Cov[X, Y] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - E[X])(y - E[Y]) f_{XY}(x, y)\, dx\, dy\,.$$

Die Rechenregeln für die Kovarianzen für diskret verteilte Zufallsvariablen übertragen sich Wort für Wort auf den gemeinsam stetig verteilten Fall.

II.4.4 Wichtige stetige Verteilungen

Gleichverteilung

Für $a < b$ heißt eine Zufallsvariable mit Dichte

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in [a;b], \\ 0 & \text{sonst}, \end{cases}$$

(stetig) gleichverteilt auf $[a;b]$. Die zugehörige Verteilungsfunktion ist

$$F(x) = \begin{cases} 0 & \text{für } x < a, \\ \frac{x-a}{b-a} & \text{für } x \in [a;b], \\ 1 & \text{für } x > b\,. \end{cases}$$

Für alle Teilintervalle $[c;d]$ folgt aus (II.23) und (II.24)

$$P(c \le X \le d) = F(d) - F(c) = \frac{d-a}{b-a} - \frac{c-a}{b-a} = \frac{d-c}{b-a}\,.$$

Mit anderen Worten: X überdeckt Teilintervalle derselben Länge $d-c$ mit jeweils derselben Wahrscheinlichkeit. Dies erklärt die Bezeichnung Gleichverteilung.

X nimmt mit Wahrscheinlichkeit 1 nur Werte in $[a;b]$ an, denn

$$P(X \in [a;b]) = P(a \le X \le b) = \frac{b-a}{b-a} = 1\,.$$

Für Erwartungswert und Varianz einer auf $[a;b]$ gleichverteilten Zufallsvariablen gilt

$$\begin{aligned} E[X] &= \int_{-\infty}^{+\infty} x f(x)\,dx = \int_a^b x \frac{1}{b-a}\,dx = \frac{1}{2}\frac{x^2}{b-a}\Big|_a^b = \frac{1}{2}(a+b), \\ V[X] &= \int_{-\infty}^{+\infty} \left(x - \frac{1}{2}(a+b)\right)^2 f(x)\,dx = \int_a^b \left(x - \frac{1}{2}(a+b)\right)^2 \frac{1}{b-a}\,dx = \frac{1}{12}(b-a)^2\,. \end{aligned}$$

Exponentialverteilung

Für $\lambda > 0$ ist

$$f_\lambda(x) = \begin{cases} \lambda e^{-\lambda x} & \text{für } x \ge 0, \\ 0 & \text{sonst}, \end{cases}$$

eine Dichte. Die zugehörige Verteilung heißt **Exponentialverteilung** zum Parameter λ. Sie wird mit $\mathrm{Exp}(\lambda)$ bezeichnet.

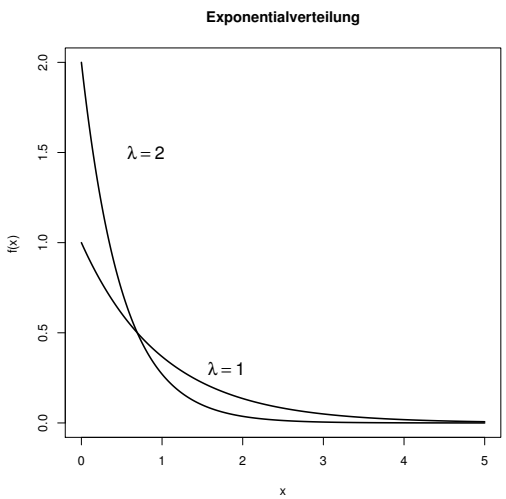

Die zugehörige Verteilungsfunktion ist

$$F(x) = \begin{cases} 0 & \text{für } x < 0, \\ 1 - e^{-\lambda x} & \text{für } x \geq 0\,. \end{cases}$$

Die Exponentialverteilung ist das stetige Analogon der geometrischen Verteilung, die ja die Verteilung von Wartezeiten auf den ersten Erfolg in einer Folge von unabhängigen Bernoulli Experimenten beschreibt. Dementsprechend verwendet man die Exponentialverteilung zur Modellierung von stetig verteilten Wartezeiten (Lebensdauern).

Ist X verteilt gemäß $\mathrm{Exp}(\lambda)$, so gilt

$$E[X] = \lambda \int_0^{+\infty} x e^{-\lambda x}\, dx = \frac{1}{\lambda},$$
$$V[X] = \lambda \int_0^{+\infty} \left(x - \frac{1}{\lambda}\right)^2 e^{-\lambda x}\, dx = \frac{1}{\lambda^2}\,.$$

Normalverteilung

Für $\mu \in \mathbb{R}$ und $\sigma > 0$ ist

$$f_{\mu,\sigma^2}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}}$$

eine Dichte. Die zugehörige Verteilung heißt **Normalverteilung** mit Erwartungswert μ und Varianz σ^2. Sie wird mit $\mathrm{N}(\mu, \sigma^2)$ bezeichnet. Im Falle $\mu = 0$ und $\sigma^2 = 1$ spricht man von der **Standardnormalverteilung**.

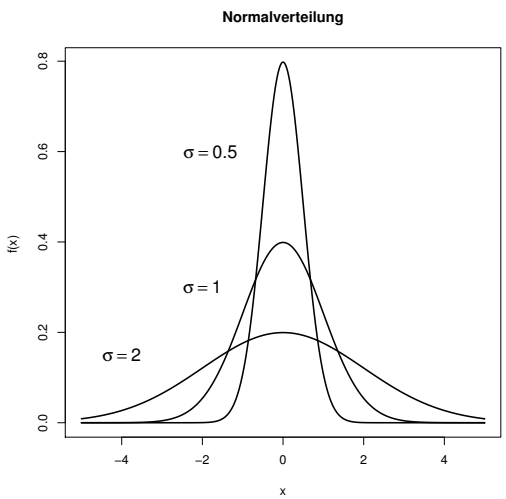

f_{μ,σ^2} besitzt ein absolutes Maximum in $x = \mu$ und Wendepunkte in $\mu \pm \sigma$. Wegen ihrer Form wird f auch als **Gaußsche Glockenkurve** bezeichnet. σ bestimmt **Breite** und **Höhe** der Glockenkurve.

Eine Zufallsvariable X mit Dichte f_{μ,σ^2} heißt normalverteilt mit Erwartungswert μ und Varianz σ^2, denn es gilt

$$E[X] = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} x e^{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}}\, dx = \mu,$$
$$V[X] = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} (x-\mu)^2 e^{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}}\, dx = \sigma^2\,.$$

Aufgrund der Symmetrie der Dichte f_{μ,σ^2} bzgl. μ stimmt der Median von $\mathrm{N}(\mu, \sigma^2)$ mit dem Erwartungswert μ überein.

II.4.5 Weitere Eigenschaften normalverteilter Zufallsvariablen

Standardnormalverteilung

Die Werte der Verteilungsfunktion der Standardnormalverteilung,

$$\Phi(x) := P(Y \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-\frac{t^2}{2}}\, dt \qquad \text{für } x \geq 0,$$

findet man tabelliert in Formelsammlungen und in jeder guten Programmbibliothek. Da die Dichte $f_{0,1}$ der Standardnormalverteilung eine gerade Funktion ist (also $f_{0,1}(-x) = f_{0,1}(x)$), ergibt sich

$$\Phi(-x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{-x} e^{-\frac{t^2}{2}}\, dt = \frac{1}{\sqrt{2\pi}} \int_{x}^{\infty} e^{-\frac{t^2}{2}}\, dt = 1 - \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-\frac{t^2}{2}}\, dt = 1 - \Phi(x)\,,$$

also

$$\Phi(-x) = 1 - \Phi(x) \qquad \text{für alle } x \in \mathbb{R}\,, \tag{II.27}$$

woraus sich dann auch die Werte $\Phi(x)$ für $x \leq 0$ berechnen lassen.

Für die q-Quantile z_q der Standardnormalverteilung gilt wegen (II.27)

$$z_q = -z_{1-q}\,.$$

Ist X eine $\mathrm{N}(\mu, \sigma^2)$-verteilte Zufallsvariable, so ist

$$Y = \frac{X - \mu}{\sigma}$$

eine $\mathrm{N}(0,1)$-verteilte, also standardnormalverteilte, Zufallsvariable. Man kann also die Berechnung der Wahrscheinlichkeiten $P(X \leq b)$ zurückführen auf die Berechnung entsprechender Wahrscheinlichkeiten einer standardnormalverteilten Zufallsvariablen

$$P(X \leq b) = P\left(\frac{X-\mu}{\sigma} \leq \frac{b-\mu}{\sigma}\right) = P\left(Y \leq \frac{b-\mu}{\sigma}\right). \tag{II.28}$$

Mit Hilfe der Verteilungsfunktion Φ der Standardnormalverteilung berechnet man dann

$$\begin{aligned} P(a \leq X \leq b) &= P\left(\frac{a-\mu}{\sigma} \leq Y \leq \frac{b-\mu}{\sigma}\right) \\ &= \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right). \end{aligned} \tag{II.29}$$

Insbesondere erhält man das q-Quantil der Verteilung $\mathrm{N}(\mu, \sigma^2)$ aus dem q-Quantil der Standardnormalverteilung, z_q, als $\mu + \sigma \cdot z_q$.

Linearität

Ist X $\mathrm{N}(\mu, \sigma^2)$-verteilt, und sind $a, b \in \mathbb{R}$ mit $a \neq 0$, so ist $a \cdot X + b$ gemäß $\mathrm{N}(a \cdot \mu + b, a^2\sigma^2)$ verteilt.

Additivität

Sind X_i, $i = 1, \ldots, n$, unabhängig normalverteilt mit Erwartungswert μ_i und Varianz σ_i^2, so ist die Summe $S_n = X_1 + \ldots + X_n$ wieder normalverteilt mit Erwartungswert $\sum_{i=1}^n \mu_i$ und Varianz $\sum_{i=1}^n \sigma_i^2$.

II.4.6 Ergänzung: Normalverteilung: k-σ-Bereiche

Anwendung: k-σ-Bereiche.

In Abschnitt II.3.3 hatten wir die Ungleichung von Tschebychev kennengelernt, um Wahrscheinlichkeiten der Form $P(\mu - k\sigma \leq X \leq \mu + k\sigma)$ abzuschätzen. Für normalverteilte Zufallsvariablen erhält man präzisere Abschätzungen für die k-σ-Bereiche: Ist $X \sim \mathrm{N}(\mu, \sigma^2)$-verteilt, so folgt

$$P(\mu - k\sigma \leq X \leq \mu + k\sigma) = P\left(\left|\frac{X-\mu}{\sigma}\right| \leq k\right) = 2\Phi(k) - 1,$$

und damit insbesondere

- $P\left(\mu - \sqrt{2}\sigma \leq X \leq \mu + \sqrt{2}\sigma\right) \approx 0.8427$,
- $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0.9545$,
- $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0.9973$.

Eine weitere wichtige Anwendung der Normalverteilung in der Statistik werden wir in Abschnitt III.1.3 diskutieren: Konfidenzintervalle.

II.4.7 Aus der Normalverteilung abgeleitete Verteilungen

Zum Abschluss dieses Abschnitts werden noch einige weitere stetige Verteilungen eingeführt, welche für die induktive Statistik wichtig sind.

χ^2-Verteilung

Es seien $X_1, \ldots, X_n$ unabhängig $\mathrm{N}(0,1)$-verteilte Zufallsvariablen. Dann heißt die Verteilung der Zufallsvariablen

$$Z_n = X_1^2 + \ldots + X_n^2$$

χ_n^2-Verteilung (oder **χ^2-Verteilung mit n Freiheitsgraden**).

Aus den Rechenregeln für Erwartungswert und Varianz folgt sofort

$$E[Z_n] = n\,, \qquad V[Z_n] = \underbrace{V[X_1^2]}_{=2} + \ldots + \underbrace{V[X_n^2]}_{=2} = 2n\,.$$

Die Dichte g_n der χ_n^2-Verteilung hat die Form

$$g_n(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}}\Gamma\left(\frac{n}{2}\right)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} & \text{für } x > 0, \\ 0 & \text{sonst.} \end{cases}$$

Hier ist Γ die sogenannte Gamma-Funktion (eine Verallgemeinerung der Fakultätsfunktion). Für wachsendes n nähern sich die Dichten g_n der Gaußschen Glockenkurve an, siehe Abschnitt II.5.3, weshalb man ab $n > 30$ eine Normalapproximation wählt.

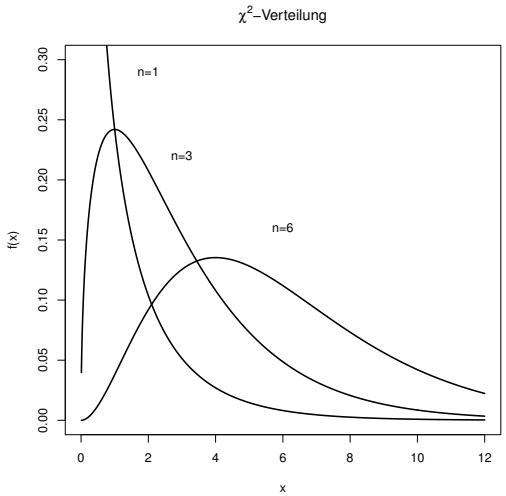

Hinweis zur Normalapproximation für $n > 30$:
Die naheliegende Approximation der χ_n^2-Verteilung durch $\mathrm{N}(n, 2n)$ impliziert eine Approximation der q-Quantile $\chi_{n;q}^2$ der χ_n^2-Verteilung durch die entsprechenden q-Quantile der Normalverteilung $\mathrm{N}(n, 2n)$, d.h. durch $n + \sqrt{2n} \cdot z_q$. Eine bessere Approximation ist aber

$$\chi_{n;q}^2 \approx \frac{1}{2}\left(z_q + \sqrt{2n-1}\right)^2,$$

siehe [1] (Seite 303).

n	$\chi_{n;0.95}^2$	$n + \sqrt{2n} \cdot z_{0.95}$	$\frac{1}{2}\left(z_{0.95} + \sqrt{2n-1}\right)^2$
5	11.07050	10.20148	10.78733
15	24.99579	24.00923	24.71058
30	43.77297	42.74098	43.48713
40	55.75848	54.71202	55.47255
50	67.50481	66.44854	67.21886
100	124.3421	123.2617	124.0563

t-Verteilung

Es seien X und Z_n unabhängige Zufallsvariablen, X sei $\mathrm{N}(0,1)$-verteilt und Z_n sei χ^2_n-verteilt. Dann heißt die Verteilung der Zufallsvariablen

$$T_n := \frac{X}{\sqrt{Z_n/n}}$$

t_n-Verteilung (oder **t-Verteilung mit n Freiheitsgraden**).
Es gilt

$$E[T_n] = 0\,, \qquad V[T_n] = \frac{n}{n-2} \text{ für } n \geq 3\,.$$

Die Dichte h_n der t_n-Verteilung ist gegeben durch

$$h_n(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{1}{2}\right)} \frac{1}{\sqrt{n}} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}\,.$$

Die Dichte h_n hat eine ähnliche Form wie die Gaußsche Glockenkurve, jedoch für kleine n breitere Enden („heavy tails“) als die Standardnormalverteilung. Für $n \geq 30$ ist jedoch eine Approximation durch die Standardnormalverteilung bereits sehr gut.

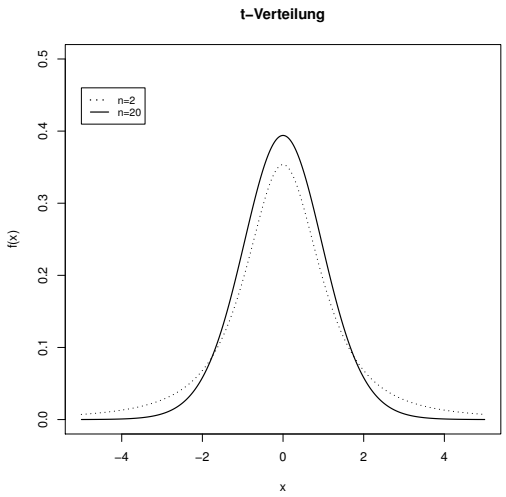

Wie für die Quantile der Standardnormalverteilung gilt auch für die Quantile $t_{n;q}$ der t_n-Verteilung

$$t_{n;q} = -t_{n;1-q}\,.$$

Wichtige Anwendung: (vgl. Abschnitte III.1.3 und III.2.2)
Seien $X_1, \ldots, X_n$ unabhängige Zufallsvariablen, jeweils verteilt gemäß $\mathrm{N}(\mu, \sigma^2)$. Sei $\overline{X} := \frac{1}{n}\sum_{i=1}^n X_i$ das empirische Mittel, sei $S_X^2 := \frac{1}{n-1}\sum_{i=1}^n \left(X_i - \overline{X}\right)^2$ die Stichprobenvarianz. Dann gilt (siehe [7]):

- $\overline{X}$ und S_X^2 sind unabhängig voneinander;
- $\overline{X}$ ist $\mathrm{N}(\mu, \sigma^2/n)$-verteilt;
- $(n-1) \cdot S_X^2/\sigma^2$ ist χ^2_{n-1}-verteilt;
- $\sqrt{n} \cdot (\overline{X} - \mu)/S_X$ ist t_{n-1}-verteilt.

Ergänzung: F-Verteilung (Fisher-Verteilung)

Es seien Z_m und $\tilde{Z}_n$ unabhängig, Z_m χ^2_m-verteilt, $\tilde{Z}_n$ χ^2_n-verteilt. Dann heißt die Verteilung der Zufallsvariablen

$$Z_{m,n} := (Z_m/m) \,/\, \left(\tilde{Z}_n/n\right)$$

$F_{m,n}$**-Verteilung** (oder F**-Verteilung mit** m **und** n **Freiheitsgraden**).

Es gilt

$$E[Z_{m,n}] = \frac{n}{n-2} \qquad \text{für } n \geq 3,$$
$$V[Z_{m,n}] = \frac{2n^2(n+m-2)}{m(n-4)(n-2)^2} \qquad \text{für } n \geq 5\,.$$

Die Dichte $f_{m,n}$ der $F_{m,n}$-Verteilung ist gegeben durch

$$f_{m,n}(x) = \begin{cases} \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)}\; m^{m/2} n^{n/2} x^{m/2-1} (n+mx)^{-(m+n)/2} & \text{für } x > 0, \\ 0 & \text{sonst.} \end{cases}$$

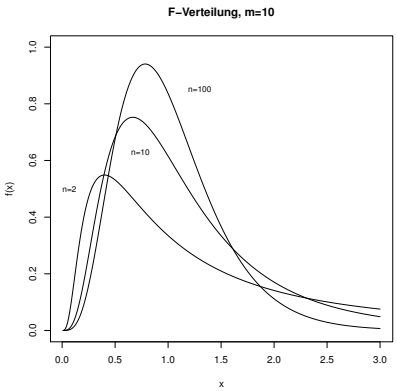

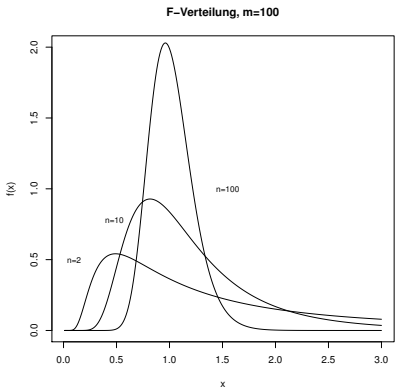

Für die Quantile $F_{m,n;q}$ der $F_{m,n}$-Verteilung gilt

$$F_{m,n;q} = \frac{1}{F_{n,m;1-q}}\,,$$

denn

$$q = P\left(Z_{m,n} \leq F_{m,n;q}\right) = P\left(\frac{Z_m}{m} \Big/ \frac{\tilde{Z}_n}{n} \leq F_{m,n;q}\right)$$
$$= P\left(\frac{\tilde{Z}_n}{n} \Big/ \frac{Z_m}{m} \geq \frac{1}{F_{m,n;q}}\right) = 1 - P\left(\frac{\tilde{Z}_n}{n} \Big/ \frac{Z_m}{m} \leq \frac{1}{F_{m,n;q}}\right).$$

Tabelle: Erwartungswerte und Varianzen stetiger Verteilungen.

	$E[X]$	$V[X]$
X gleichverteilt auf $[a;b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
$X \sim \mathrm{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$X \sim \mathrm{N}(\mu, \sigma^2)$	μ	σ^2
$X \sim \chi^2_n$	n	$2n$
$X \sim t_n$	0	$\frac{n}{n-2}$ für $n \geq 3$
$X \sim F_{m,n}$	$\frac{n}{n-2}$ für $n \geq 3$	$\frac{2n^2(n+m-2)}{m(n-4)(n-2)^2}$ für $n \geq 5$

II.5 Grenzwertsätze

II.5.1 Das Gesetz der großen Zahlen

Werfen wir eine faire Münze n mal und setzen wir $X_k = 1$ (bzw. $X_k = 0$) falls beim k-ten Münzwurf Kopf (bzw. Zahl) oben liegt, so nähert sich die relative Häufigkeit für Kopf,

$$\frac{1}{n}\sum_{k=1}^{n} X_k,$$

für wachsendes n immer stärker der Wahrscheinlichkeit für Kopf, nämlich $\frac{1}{2}$. Man bezeichnet $\frac{1}{n}\sum_{k=1}^{n} X_k$ auch als empirisches Mittel. In der folgenden Grafik ist als Illustration die Folge der empirischen Mittel für insgesamt 1000 (simulierte) Münzwürfe aufgetragen.

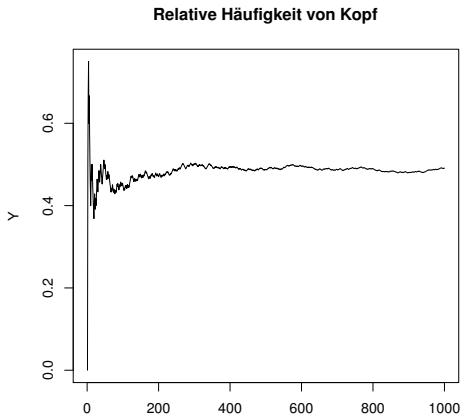

Diese Beobachtung gilt ganz allgemein für die relativen Häufigkeiten eines beliebigen Ereignisses bzw. das empirische Mittel in einer unabhängigen Wiederholung ein und desselben Zufallsexperimentes. Sie wird als **Gesetz der großen Zahlen** bezeichnet.

Satz (schwaches Gesetz der großen Zahlen)
Es sei $X_1, X_2, \ldots$ eine Folge unabhängiger Zufallsvariablen mit gemeinsamem Erwartungswert $E[X_k] = \mu < \infty$ und gemeinsamer Varianz $V[X_k] = \sigma^2 < \infty$. Sei $\overline{X}_n := \frac{1}{n}\sum_{k=1}^{n} X_k$ das empirische Mittel zu Stichprobengröße n.

Dann folgt für alle $\varepsilon > 0$:

$$\lim_{n\to\infty} P\left(\left|\overline{X}_n - \mu\right| \geq \varepsilon\right) = 0\,.$$

Bemerkung:
Die obige Aussage zur Asymptotik der relativen Häufigkeiten eines Ereignisses A leitet sich aus dem Satz wie folgt ab: Es sei

$$X_k := \begin{cases} 1 & \text{falls } A \text{ in der } k\text{-ten Wiederholung eintritt,} \\ 0 & \text{sonst.} \end{cases}$$

Dann sind die $X_1, X_2, \ldots$ eine Folge unabhängig Bernoulli-verteilter Zufallsvariablen mit Parameter $\pi := P(A) = E[X_k]$. Für die relativen Häufigkeiten $r_n(A) := \frac{1}{n}\sum_{k=1}^{n} X_k$ des Ereignisses A in n Wiederholungen gilt dann die Aussage des Gesetzes der großen Zahlen:

$$\lim_{n\to\infty} P\left(|r_n(A) - \pi| \geq \varepsilon\right) = 0 \qquad \text{für alle } \varepsilon > 0\,.$$

Ergänzung: Beweis des Gesetzes der großen Zahlen:

Es sei n fest gewählt. Wir definieren die Zufallsvariable

$$\overline{X}_n := \frac{1}{n}\sum_{k=1}^{n} X_k\,.$$

Da $E[X_k] = \mu$ für alle k, folgt aus der Linearität des Erwartungswertes (vgl. Abschnitt II.3.1), dass

$$E[\overline{X}_n] = E\left[\frac{1}{n}\sum_{k=1}^{n} X_k\right] = \frac{1}{n}\sum_{k=1}^{n} E[X_k] = \mu\,.$$

Die Zufallsvariablen $X_1, \ldots, X_n$ sind nach Annahme unabhängig, also besagt die Identität von Bienaymé (vgl. Abschnitt II.3.2), dass

$$V[\overline{X}_n] = V\left[\frac{1}{n}\sum_{k=1}^{n} X_k\right] = \frac{1}{n^2}\sum_{k=1}^{n} V[X_k] = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}\,.$$

Die Tschebyschowsche Ungleichung aus Abschnitt II.3.3, angewandt auf $\overline{X}_n$, ergibt die Abschätzung

$$P\left(\left|\overline{X}_n - \mu\right| \geq \varepsilon\right) \;=\; P\left(\left|\overline{X}_n - E[\overline{X}_n]\right| \geq \varepsilon\right) \;\leq\; \frac{V[\overline{X}_n]}{\varepsilon^2} \;=\; \frac{\sigma^2}{\varepsilon^2 n}\,.$$

Da $\frac{\sigma^2}{\varepsilon^2 n} \to 0$ für $n \to \infty$, folgt schließlich auch

$$\lim_{n\to\infty} P\left(\left|\overline{X}_n - \mu\right| \geq \varepsilon\right) = 0\,. \quad \square$$

II.5.2 Der Hauptsatz der Statistik (Satz von Glivenko-Cantelli)

Es sei X eine Zufallsvariable mit Verteilungsfunktion F und es bilden $X_1, X_2, \ldots$ eine Folge von unabhängig und identisch verteilten Zufallsvariablen mit derselben Verteilungsfunktion F. Dann gilt für die Folge der zugehörigen **empirischen Verteilungsfunktionen** (vgl. Abschnitt I.2.2)

$$\begin{aligned} F_n(x) &:= \frac{1}{n}\cdot\left|\left\{i \in \{1,\ldots,n\} \,|\, X_i \leq x\right\}\right| \\ &= \text{„relative Häufigkeit } r_n(A) \text{ des Ereignisses } A = \{X \leq x\}\text{“}, \end{aligned}$$

der ersten n Realisierungen $X_1, \ldots, X_n$, dass

$$\lim_{n\to\infty} P\left(\sup_{x\in\mathbb{R}} |F_n(x) - F(x)| \geq \varepsilon\right) = 0 \qquad \text{für alle } \varepsilon > 0\,,$$

d.h. die maximale Abweichung zwischen empirischer Verteilungsfunktion r_n und Verteilungsfunktion F konvergiert mit wachsendem n in Wahrscheinlichkeit gegen 0.

II.5.3 Der zentrale Grenzwertsatz

Es sei $X_1, X_2, \ldots$ eine Folge unabhängiger und identisch verteilter Zufallsvariablen mit $E[X_k] = \mu < \infty$ und Varianz $V[X_k] = \sigma^2 < \infty$. Sei $\overline{X}_n := \frac{1}{n}\sum_{k=1}^n X_k$ das empirische Mittel zu Stichprobengröße n. Betrachtet man die **standardisierten Summen**

$$S_n^* := \frac{S_n - E[S_n]}{\sqrt{V[S_n]}} = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n\sigma^2}} = \sqrt{n}\,\frac{\overline{X}_n - \mu}{\sigma},$$

so kann man beweisen, dass die zugehörigen Verteilungsfunktionen

$$F_{S_n^*}(x) := P\left(S_n^* \leq x\right) = P\left(\sqrt{n}\,\frac{\overline{X}_n - \mu}{\sigma} \leq x\right)$$

punktweise für alle x gegen die Verteilungsfunktion der Standardnormalverteilung konvergieren, d.h. es gilt:

$$\lim_{n\to\infty} F_{S_n^*}(x) \;=\; \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{x} e^{-\frac{t^2}{2}}\,dt = \Phi(x) \qquad \text{für alle } x \in \mathbb{R}\,.$$

Man sagt auch, dass die standardisierten Summen **asymptotisch normalverteilt** sind und bezeichnet die Aussage als **zentralen Grenzwertsatz** .

Die Bedeutung des zentralen Grenzwertsatzes für die induktive Statistik besteht vor allem darin, dass man aufgrund der Aussage dieses Satzes die Verteilung einer standardisierten Summe S_n^* von unabhängig und identisch verteilten Zufallsvariablen (in der induktiven Statistik: die Stichprobenvariablen) mit wachsendem n (in der induktiven Statistik: mit wachsender Stichprobenlänge) zunehmend besser durch eine Standardnormalverteilung approximieren kann. Diese Approximation heißt **Normalapproximation**. Insbesondere impliziert dies, dass die in Abschnitt II.4.6 getroffenen Aussagen zu Konfidenzintervallen, welche ja exakt nur für normalverteilte Stichproben gelten, in guter Näherung auch ganz allgemein gelten, wenn n ausreichend groß ist (gängige Faustregel: $n \geq 30$, siehe etwa [10]).

II.5.4 Der Satz von de Moivre-Laplace

Man kann den zentralen Grenzwertsatz insbesondere auf die n-fache unabhängige Wiederholung ein und desselben Bernoulli-Experimentes anwenden. Ist A ein Ereignis mit Wahrscheinlichkeit $\pi := P(A)$ und

$$X_k := \begin{cases} 1 & \text{falls } A \text{ in der } k\text{-ten Wiederholung eintritt,} \\ 0 & \text{sonst,} \end{cases}$$

so sind $X_1, X_2, \ldots$ unabhängig Bernoulli-verteilt (Bernoulli-Kette) mit $\mu = E[X_k] = \pi$ und $\sigma^2 = V[X_k] = \pi(1-\pi)$, siehe die Abschnitte II.2.4 und II.3. Die Stichprobensumme $S_n = X_1 + \ldots + X_n$ ist dann binominalverteilt gemäß $\mathrm{Bin}(n, \pi)$.

Für die standardisierten Häufigkeiten

$$S_n^* = \frac{S_n - n\pi}{\sqrt{n\pi(1-\pi)}} = \sqrt{n}\frac{\overline{X}_n - \pi}{\sqrt{\pi(1-\pi)}}$$

folgt dann aus dem zentralen Grenzwertsatz, dass diese asymptotisch normalverteilt sind, d.h.

$$\lim_{n\to\infty} P\left(S_n^* \leq x\right) = \Phi(x) \qquad \text{für alle } x \in \mathbb{R}\,.$$

Diese Aussage wird als **Satz von de Moivre-Laplace** bezeichnet, und er impliziert, dass man die Binomialverteilung $\mathrm{Bin}(n, \pi)$ für große n durch die Normalverteilung approximieren kann (**Normal(en)approximation**). Eine gängige Faustregel besagt, dass diese Normalapproximation dann ausreichend gut ist, wenn $V[S_n] = n\pi(1-\pi) > 9$ erfüllt ist.

Bemerkung: In der Literatur wird häufig eine „Stetigkeitskorrektur“ zur Verbesserung der Normalapproximation der Binomialverteilung vorgeschlagen, d. h. statt

$$P(S_n \leq k) \;\approx\; \Phi\left(\frac{k - n\pi}{\sqrt{n\pi(1-\pi)}}\right)$$

approximiert man

$$P(S_n \leq k) \;\approx\; \Phi\left(\frac{k - n\pi + 0.5}{\sqrt{n\pi(1-\pi)}}\right).$$

Zum Abschluss des Kapitels die beiden Approximationen der Binomialverteilung im Überblick:

$$\begin{tikzcd}
 & \text{Binomialverteilung } \mathrm{Bin}(n,\pi) \\
 & P(X=k) = \binom{n}{k}\pi^k(1-\pi)^{n-k} \arrow[dl, "\text{Poisson-Approximation}"', "n\pi_n \to \lambda"] \arrow[dr, "\text{Normalapproximation für}", "\frac{S_n - n\pi}{\sqrt{n\pi(1-\pi)}},\ \pi \text{ konstant},\ n \to \infty"'] & \\
\text{Poisson-Verteilung } \mathrm{Poi}(\lambda) \arrow[dr, phantom, "P(X=k) = e^{-\lambda}\frac{\lambda^k}{k!}"] & & \text{Normalverteilung } \mathrm{N}(0,1) \arrow[dl, phantom, "P(X \leq x) = \Phi(x)"]
\end{tikzcd}$$

III Induktive Statistik

Im Gegensatz zur deskriptiven Statistik, die sich auf die Beschreibung von Daten anhand von Kennzahlen und Grafiken beschränkt, versucht die induktive (d.h. die schließende) Statistik, von beobachteten Daten auf deren Verteilungen (oder Eigenschaften ihrer Verteilungen) zu schließen. Dies kann zum Beispiel dann notwendig sein, wenn eine vollständige Datenerhebung unmöglich, zu zeitaufwändig oder zu kostspielig ist, wie es etwa bei Umfragen der Fall ist.

In der schließenden Statistik gibt es im Wesentlichen drei zu bearbeitende Problemstellungen:

1. Konstruktion eines **Schätzers** für einen Parameter der unbekannten Verteilung;
2. Berechnung von **Konfidenzintervallen**, d.h. von Schranken, die einen unbekannten Parameter mit vorgegebener Wahrscheinlichkeit einfangen;
3. Entwicklung **statistischer Tests**, mit denen vorgegebene Parameter auf Verträglichkeit mit Beobachtungen überprüft werden können.

III.1 Schätzen

III.1.1 Punktschätzer

Ausgangspunkt ist eine Grundgesamtheit G von Merkmalsträgern. Unter einer **Stichprobenerhebung** versteht man eine zufällige Entnahme von endlich vielen Objekten aus G. Dabei bedeutet zufällig, dass für jedes Objekt die Wahrscheinlichkeit der Entnahme gleich ist.
In der Sprache der Wahrscheinlichkeitstheorie handelt es sich bei der Stichprobenerhebung um Zufallsexperimente, deren Ausgang man durch Zufallsvariablen

$$X_1, X_2, \ldots, X_n$$

beschreiben kann. In diesem Zusammenhang nennt man die X_i auch **Stichprobenvariablen**. In der Regel betrachtet man nur unabhängige Wiederholungen desselben Zufallsexperiments, d.h. die Stichprobenvariablen $X_1, \ldots, X_n$ sind stochastisch **unabhängig und identisch verteilt („i.i.d.“)**.

Unter dem **Stichprobenergebnis** oder der **Stichprobenrealisation** versteht man dann das n-Tupel $(x_1, \ldots, x_n)$ der Realisierung von $(X_1, \ldots, X_n)$.
Eine **Punktschätzung** ist eine Funktion $g : \mathbb{R}^n \to \mathbb{R}$. Sie ordnet der Stichprobenrealisation $x_1, \ldots, x_n$ den **Schätz<u>wert</u>** $g(x_1, \ldots, x_n)$ zu.
Der zugehörige **Schätz<u>er</u>** (auch: **Schätzfunktion**, **Statistik**) $g(X_1, \ldots, X_n)$ ist diejenige Zufallsvariable, die man durch Einsetzen der Stichprobenvariablen X_i für x_i in die Funktion g erhält.

Beispiele: $X_1, \ldots, X_n$ seien i.i.d. mit Erwartungswert μ und Varianz σ^2.

Schätzfunktion	Bezeichnung	Erwartungswert	Varianz
$\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$	Stichprobenmittel	μ	$\frac{\sigma^2}{n}$
$\sqrt{n} \cdot \frac{\overline{X}-\mu}{\sigma}$	Gauß-Statistik	0	1
$\frac{1}{n}\sum_{i=1}^n (X_i - \overline{X})^2$	mittlere quadratische Abweichung	$\frac{n-1}{n} \cdot \sigma^2$	
$S^2 = \frac{1}{n-1}\sum_{i=1}^n (X_i - \overline{X})^2$	Stichprobenvarianz	σ^2	

für die Stichprobenstandardabweichung $S = \sqrt{S^2}$ und die t-Statistik $\sqrt{n} \cdot \frac{\overline{X}-\mu}{S}$ liegen keine einfachen, geschlossenen Ausdrücke für Erwartungswert und Varianz vor.

Im Folgenden wollen wir annehmen, dass die (unbekannte) Verteilung der **Stichprobenvariablen** aus einer Menge möglicher Verteilungen stammt, die über einen Parameter $\boldsymbol{\theta} \in \boldsymbol{\Theta}$ parametrisiert sind.

Beispiel: Die X_i seien $\mathrm{N}(\mu, \sigma^2)$-verteilt mit unbekanntem Erwartungswert μ und unbekannter Varianz σ^2. In diesem Falle ist also $\boldsymbol{\theta} = (\mu, \sigma^2)^\top$ aus $\boldsymbol{\Theta} = \mathbb{R} \times (0; \infty)$ eine (mögliche) Parametrisierung der zugrundeliegenden Verteilungen.

Ist nun $T = g(X_1, \ldots X_n)$ ein Schätzer, so wird der Erwartungswert $E[T]$ abhängen von der Verteilung der Zufallsvariablen X_i. Um diese Abhängigkeit im Folgenden kenntlich zu machen, schreiben wir $E_{\boldsymbol{\theta}}[T]$ für $E[T]$, wenn die zu $\boldsymbol{\theta}$ gehörende Verteilung die tatsächliche Verteilung der X_i ist.

Ein einzelner, zu Schätzender Parameter aus der Menge der zugrundeliegenden Verteilungen kann nun realisiert werden als Abbildung

$$\tau : \quad \boldsymbol{\Theta} \to \mathbb{R},$$

d.h. $\tau(\boldsymbol{\theta})$ ist der wahre Parameterwert, falls die zugrundeliegende Verteilung durch den Wert $\boldsymbol{\theta}$ bestimmt ist.

Eigenschaften von Schätzern

Erwartungstreue

Ein Schätzer $T = g(X_1, \ldots, X_n)$ heißt **erwartungstreu** für den Parameter τ, falls

$$E_{\boldsymbol{\theta}}[T] = E_{\boldsymbol{\theta}}\left[g(X_1, \ldots, X_n)\right] = \tau(\boldsymbol{\theta})$$

für jedes $\boldsymbol{\theta} \in \boldsymbol{\Theta}$.

Mit anderen Worten: Bestimmt man den Erwartungswert von T unter der Voraussetzung, dass der Parameter $\boldsymbol{\theta}$ zugrundeliegt, ergibt sich $\tau(\boldsymbol{\theta})$ als Erwartungswert.

Beispiele: $X_1, \ldots, X_n$ seien i.i.d. Wiederholungen von X.

(i) Das Stichprobenmittel $\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$ ist ein erwartungstreuer Schätzer für den Erwartungswert $\mu = E_{\boldsymbol{\theta}}[X]$, denn

$$E_{\boldsymbol{\theta}}[\overline{X}] = \frac{1}{n}\sum_{i=1}^n E_{\boldsymbol{\theta}}[X_i] = \mu\,.$$

(ii) Die mittlere quadratische Abweichung

$$T = \frac{1}{n}\sum_{i=1}^n \left(X_i - \overline{X}\right)^2$$

ist kein erwartungstreuer Schätzer für die Varianz $\sigma^2 = V_{\boldsymbol{\theta}}[X] = E_{\boldsymbol{\theta}}\left[(X - E_{\boldsymbol{\theta}}[X])^2\right]$, denn

$$E_{\boldsymbol{\theta}}[T] = \frac{1}{n}\sum_{i=1}^n \left(E_{\boldsymbol{\theta}}[X_i^2] - 2E_{\boldsymbol{\theta}}[X_i\overline{X}] + E_{\boldsymbol{\theta}}[\overline{X}^2]\right) = E_{\boldsymbol{\theta}}[X_1^2] - E_{\boldsymbol{\theta}}\left[\overline{X}^2\right] = \frac{n-1}{n}\cdot\sigma^2\,,$$

denn

$$E_{\boldsymbol{\theta}}\left[\overline{X}^2\right] = \frac{1}{n^2}\sum_{i,j=1}^n E_{\boldsymbol{\theta}}[X_iX_j] = \frac{n-1}{n}\cdot E_{\boldsymbol{\theta}}[X]^2 + \frac{1}{n}\cdot E_{\boldsymbol{\theta}}[X^2]\,.$$

Im Gegensatz hierzu ist die Stichprobenvarianz $S^2 = \frac{n}{n-1}\cdot T$ ein erwartungstreuer Schätzer für σ^2, denn

$$E_{\boldsymbol{\theta}}\left[S^2\right] = \frac{n}{n-1}\cdot E_{\boldsymbol{\theta}}[T] = \sigma^2\,.$$

Als Abschwächung der Erwartungstreue betrachtet man **asymptotische Erwartungstreue** bei wachsender Stichprobenlänge. Dazu nimmt man an, dass zu jeder Stichprobenlänge n ein Schätzer $T_n = g_n(X_1, \ldots, X_n)$ für $\tau(\boldsymbol{\theta})$ gegeben ist. Die Folge $T_1, T_2 \ldots$ heißt **asymptotisch erwartungstreu** (für τ), falls

$$\lim_{n\to\infty} E_{\boldsymbol{\theta}}[T_n] = \tau(\boldsymbol{\theta})$$

für jedes $\boldsymbol{\theta} \in \boldsymbol{\Theta}$.

Beispiel: Die mittlere quadratische Abweichung

$$T_n = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

ist asymptotisch erwartungstreu für die Varianz, denn

$$E_{\boldsymbol{\theta}}[T_n] = \left(1 - \frac{1}{n}\right) \cdot V_{\boldsymbol{\theta}}[X] \underset{n\to\infty}{\longrightarrow} V_{\boldsymbol{\theta}}[X]\,.$$

für einen nicht erwartungstreuen Schätzer T bezeichnet man die Abweichung

$$Bias_{\boldsymbol{\theta}}[T] := E_{\boldsymbol{\theta}}[T] - \tau(\boldsymbol{\theta})$$

als **Verzerrung** (oder **Bias**), ein erwartungstreuer Schätzer heißt auch **unverzerrt**.

Der **mittlere quadratische Fehler**

$$MSE[T] := E_{\boldsymbol{\theta}}\left[(T - \tau(\boldsymbol{\theta}))^2\right]$$

ist ein Maß für die Schätzgüte. MSE steht dabei für **mean squared error**.

Struktur des mittleren quadratischen Fehlers:

$$MSE[T] = E_{\boldsymbol{\theta}}\left[(T - \tau(\boldsymbol{\theta}))^2\right] \;=\; V_{\boldsymbol{\theta}}[T] \;+\; (Bias_{\boldsymbol{\theta}}[T])^2,$$

d.h. der MSE kann als eine Art „übergeordnetes“ Gütemaß verstanden werden, welches Auskunft gibt sowohl über die Streuung des Schätzers als auch über dessen Verzerrung.

Beweis:

$$\begin{aligned} E_{\boldsymbol{\theta}}[(T - \tau(\boldsymbol{\theta}))^2] &= E_{\boldsymbol{\theta}}[T^2] - 2E_{\boldsymbol{\theta}}[T] \cdot \tau(\boldsymbol{\theta}) + \tau(\boldsymbol{\theta})^2 \\ &= E_{\boldsymbol{\theta}}[T^2] - (E_{\boldsymbol{\theta}}[T])^2 + (E_{\boldsymbol{\theta}}[T])^2 - 2E_{\boldsymbol{\theta}}[T] \cdot \tau(\boldsymbol{\theta}) + \tau(\boldsymbol{\theta})^2 \\ &= V_{\boldsymbol{\theta}}[T] + (E_{\boldsymbol{\theta}}[T] - \tau(\boldsymbol{\theta}))^2\,. \end{aligned}$$

Es sei $T_1, T_2, \ldots$ wieder eine Folge von Schätzern für $\tau(\boldsymbol{\theta})$. Dann heißt diese Folge

- **konsistent im quadratischen Mittel**, falls

$$\lim_{n\to\infty} MSE[T_n] = \lim_{n\to\infty} E_{\boldsymbol{\theta}}\left[(T_n - \tau(\boldsymbol{\theta}))^2\right] = 0;$$

- **schwach konsistent**, falls

$$\lim_{n\to\infty} P_{\boldsymbol{\theta}}\left(|T_n - \tau(\boldsymbol{\theta})| \geq \varepsilon\right) = 0 \qquad \text{für alle } \varepsilon > 0\,.$$

Aufgrund der Ungleichung von Tschebyschow aus Abschnitt II.3.3 ist klar, dass aus Konsistenz im quadratischen Mittel immer schwache Konsistenz folgt. Im Fall $E_{\boldsymbol{\theta}}[T_n] = \tau(\theta)$ sieht man das sofort, da

$$P_{\boldsymbol{\theta}}\left(|T_n - \tau(\boldsymbol{\theta})| \geq \varepsilon\right) \;\leq\; \frac{1}{\varepsilon^2} \cdot E_{\boldsymbol{\theta}}\left[(T_n - \tau(\boldsymbol{\theta}))^2\right] \to 0 \qquad \text{für } n \to \infty\,.$$

Beispiel: Das Stichprobenmittel $\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$ ist konsistent im quadratischen Mittel für den Erwartungswert $\mu = E_{\boldsymbol{\theta}}[X]$ (und damit auch schwach konsistent), denn

$$E_{\boldsymbol{\theta}}[(\overline{X} - \mu)^2] = \frac{1}{n} \cdot V_{\boldsymbol{\theta}}[X] \to 0 \qquad \text{für } n \to \infty\,.$$

Analog ist die Stichprobenvarianz S^2 schwach konsistent für die Varianz σ^2.

Effizienz von Schätzern

Der mittlere quadratische Fehler eines Schätzers liefert ein Vergleichskriterium zwischen den verschiedenen Schätzern für τ. Von zwei Schätzern T_1, T_2 mit

$$MSE[T_1] \leq MSE[T_2]$$

nennen wir den Schätzer T_1 mit dem kleineren mittleren quadratischen Fehler **wirksamer** für die Schätzung von $\tau(\boldsymbol{\theta})$ als T_2.

Beschränkt man sich beim Vergleich zweier Schätzer auf erwartungstreue Schätzer, also Schätzer mit

$$Bias[T_i] = 0 \quad \text{und damit} \quad MSE[T_i] = V[T_i]\,,$$

so reduziert sich der Vergleich der mittleren quadratischen Fehler auf den Vergleich der Varianzen.

Sind T_1, T_2 zwei erwartungstreue Schätzer für $\tau(\boldsymbol{\theta})$, so heißt T_1 **effizienter** (bzw. **wirksamer**) als T_2, falls

$$V[T_1] \leq V[T_2].$$

Bemerkung. (Cramér-Rao Schranke)
Die Varianz eines erwartungstreuen Schätzers kann nicht beliebig klein werden, sondern wird nach unten beschränkt durch die sog. „Cramér-Rao Schranke“. Wir wollen diese Schranke hier nicht angeben, sondern nur bemerken, dass sie von der Variation der Verteilungen in Abhängigkeit von $\boldsymbol{\theta}$ abhängt. Ein erwartungstreuer Schätzer, dessen Varianz diese untere Schranke annimmt, heißt **effizient** (oder **wirksamst**).

Beispiel:

$\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$ ist ein effizienter Schätzer für den Erwartungswert, wenn man

- alle Verteilungen mit endlicher Varianz zulässt;
- alle Normalverteilungen zulässt.

III.1.2 Prinzipien zur Konstruktion von Schätzern

Maximum-Likelihood-Schätzer

Es seien $X_1, \ldots, X_n$ zunächst diskret verteilt und

$$f(x_1, \ldots, x_n \mid \boldsymbol{\theta}) = P_{\boldsymbol{\theta}}(X_1 = x_1, \ldots, X_n = x_n)$$

die Wahrscheinlichkeitsfunktion zur gemeinsamen Verteilung der Stichprobenvariablen bei zugrundeliegender Verteilung zum Parameter $\boldsymbol{\theta}$. Zu gegebener Stichprobe $x_1, \ldots, x_n$ heißt die Funktion

$$L : \boldsymbol{\theta} \longmapsto f(x_1, \ldots, x_n \mid \boldsymbol{\theta}), \quad \boldsymbol{\theta} \in \boldsymbol{\Theta},$$

die **Likelihood-Funktion**, denn sie gibt an, wie wahrscheinlich die gewonnene Stichprobe $x_1, \ldots, x_n$ bei angenommener zugrundeliegender Verteilung zum Parameter $\boldsymbol{\theta}$ ist.

Die Grundidee der **Maximum-Likelihood-Schätzung** (kurz: ML-Schätzung) besteht darin, als Schätzer für $\boldsymbol{\theta}$ gerade denjenigen Wert $\hat{\boldsymbol{\theta}}$ zu wählen, für den die gewonnene Stichprobe am **wahrscheinlichsten** ist, also $\hat{\boldsymbol{\theta}}$ mit

$$L(\hat{\boldsymbol{\theta}}) = \max_{\boldsymbol{\theta} \in \boldsymbol{\Theta}} L(\boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \boldsymbol{\Theta}} f(x_1, \ldots, x_n \mid \boldsymbol{\theta}).$$

Der Einfachheit halber betrachten wir im Folgenden nur unabhängig und identisch verteilte Stichprobenvariablen. Dann bekommt die Likelihood-Funktion die Produktgestalt

$$L(\boldsymbol{\theta}) = f(x_1, \ldots, x_n \mid \boldsymbol{\theta}) = f(x_1 \mid \boldsymbol{\theta}) \cdots f(x_n \mid \boldsymbol{\theta}) \tag{III.1}$$

mit $f(x_i \mid \boldsymbol{\theta}) = P_{\boldsymbol{\theta}}(X_i = x_i)$.

Sind die Stichprobenvariablen zu $\boldsymbol{\theta} \in \boldsymbol{\Theta}$ stetig verteilt mit Dichte $f(x \mid \boldsymbol{\theta})$, so ersetzt man in der Likelihood-Funktion (III.1) die Wahrscheinlichkeitsfunktion der Verteilung durch die entsprechende Dichte.

Bemerkung: über Existenz (und Eindeutigkeit) des Maximums der Likelihood-Funktion wird hier keine Aussage gemacht! Insbesondere muss i. Allg. der Maximum-Likelihood-Schätzer nicht existieren, oder er muss nicht eindeutig bestimmt sein.

Die Bestimmung der Maximum-Likelihood-Schätzung erfolgt in der Regel durch Nullsetzen der Ableitung der Likelihood-Funktion L. Wegen der Produktgestalt von L in (III.1) ist es zweckmäßig, L zunächst zu logarithmieren ($\ln(\cdot)$ ist streng monoton wachsend),

$$\ell(\boldsymbol{\theta}) := \ln L(\boldsymbol{\theta}) = \sum_{i=1}^{n} \ln f(x_i \mid \boldsymbol{\theta}), \tag{III.2}$$

und dann zu maximieren. ℓ heißt **Log-Likelihood-Funktion**.

Beispiel: Bernoulli-Kette.

$X_1, \ldots, X_n$ sei eine Bernoulli-Kette mit unbekannter Erfolgswahrscheinlichkeit $\pi \in (0; 1)$.

$$s_n = x_1 + \ldots + x_n$$

sei die beobachtete Anzahl der Erfolge. Die (Log-)Likelihood-Funktion hat die Form

$$L(\pi) = \pi^{s_n} \cdot (1 - \pi)^{n - s_n} \qquad \text{bzw.} \qquad \ell(\pi) = s_n \cdot \ln(\pi) + (n - s_n) \cdot \ln(1 - \pi).$$

In diesem Falle ist $\hat{\pi} = \frac{s_n}{n}$ das eindeutig bestimmte Maximum, also die (eindeutig bestimmte) Maximum-Likelihood-Schätzung für π.

Insbesondere: Die Maximum-Likelihood-Schätzung $\hat{\pi} = \frac{s_n}{n} = \frac{1}{n}(x_1 + \ldots + x_n)$ ist gerade das Stichprobenmittel!

Beispiel: Normalverteilung.

$X_1, \ldots, X_n$ seien unabhängig $\mathrm{N}(\mu, \sigma^2)$-verteilt, also $\boldsymbol{\theta} = (\mu, \sigma)^\top$. Die zugehörige Likelihood-Funktion hat dann die Gestalt

$$L(\mu, \sigma) = \Pi_{i=1}^n f_{\mu,\sigma^2}(x_i) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left(-\frac{1}{2}\sum_{i=1}^n \frac{(x_i-\mu)^2}{\sigma^2}\right).$$

Logarithmieren ergibt

$$\ell(\mu, \sigma) = \ln L(\mu, \sigma) = -n \ln\left(\sqrt{2\pi}\sigma\right) - \frac{1}{2}\sum_{i=1}^n \frac{(x_i-\mu)^2}{\sigma^2},$$

mit den partiellen Ableitungen

$$\frac{\partial}{\partial\mu}\ell(\mu, \sigma) = \sum_{i=1}^n \frac{x_i - \mu}{\sigma^2}, \qquad \frac{\partial}{\partial\sigma}\ell(\mu, \sigma) = -\frac{n}{\sigma} + \sum_{i=1}^n \frac{(x_i-\mu)^2}{\sigma^3}.$$

Nullsetzen der partiellen Ableitungen liefert die Maximum-Likelihood-Schätzung

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^n x_i = \bar{x} \quad \text{und} \quad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^n (x_i - \hat{\mu})^2. \tag{III.3}$$

Hier hat man schließlich noch zu überprüfen, dass (III.3) tatsächlich (eindeutig bestimmtes) Maximum der Likelihood-Funktion ist.

Insbesondere: Die Maximum-Likelihood-Schätzung $\hat{\mu}$ für μ entspricht dem Stichprobenmittel, diejenige für σ^2 der mittleren quadratischen Abweichung der Beobachtungswerte von $\hat{\mu}$.

Tabelle: Maximum-Likelihood-Schätzer.

- $X_1, \ldots, X_n$ seien stochastisch unabhängig und identisch verteilt,
- $x_1, \ldots, x_n$ die zugehörigen Realisierungen,
- $\bar{x} = \frac{1}{n}\sum_{i=1}^n x_i$ sei Stichprobenmittel, $s_n := \sum_{i=1}^n x_i$ die Stichprobensumme.

	Likelihood-Funktion	ML-Schätzer
$X_i \sim \mathrm{Bernoulli}(\pi)$ $\pi \in [0;1]$ unbekannt	$L(\pi) = \pi^{s_n} \cdot (1-\pi)^{n-s_n}$	$\hat{\pi} = \bar{X}$
$X_i \sim \mathrm{Geom}(\pi)$ $\pi \in (0;1]$ unbekannt	$L(\pi) = (1-\pi)^{s_n-n} \cdot \pi^n$	$\hat{\pi} = \frac{1}{\bar{X}}$
$X_i \sim \mathrm{Poi}(\lambda)$ $\lambda > 0$ unbekannt	$L(\lambda) = e^{-n\lambda}\lambda^{s_n}\prod_{i=1}^n \frac{1}{x_i!}$	$\hat{\lambda} = \bar{X}$
$X_i \sim \mathrm{N}(\mu, \sigma^2)$ $\mu \in \mathbb{R}$, $\sigma^2 > 0$ unbek.	$L(\mu, \sigma) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left(-\frac{1}{2}\sum_{i=1}^n \frac{(x_i-\mu)^2}{\sigma^2}\right)$	$\hat{\mu} = \bar{X}$ $\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^n (X_i - \bar{X})^2$
$X_i \sim \mathrm{Exp}(\lambda)$ $\lambda > 0$ unbekannt	$L(\lambda) = \lambda^n e^{-\lambda s_n}$	$\hat{\lambda} = \frac{1}{\bar{X}}$

Kleinste-Quadrate-Schätzung

Ein weiteres Prinzip der ParameterSchätzung besteht in der Minimierung der Summe der quadratischen Abweichungen zwischen Beobachtungswerten und zu Schätzendem Wert. Dieses Prinzip haben wir bereits bei der Regression in Abschnitt I.3.4 kennengelernt.

Beispiel: Arithmetisches Mittel.

Minimierung der quadratischen Abweichung $Q(\mu)$ vom Erwartungswert μ,

$$\min_{\mu\in\mathbb{R}} Q(\mu) = \min_{\mu\in\mathbb{R}} \sum_{i=1}^{n}(x_i-\mu)^2,$$

führt wieder auf das Stichprobenmittel $\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i$,

$$\text{denn } Q'(\mu) = -2\cdot\left(\sum_{i=1}^{n}(x_i-\mu)\right) = -2\cdot\left(\sum_{i=1}^{n} x_i \;-n\mu\right) \text{ und } Q''(\mu) = 2n > 0.$$

III.1.3 Intervall-Schätzungen

Die bisher konstruierten Schätzer liefern zu gegebenen Beobachtungen $x_1,\ldots,x_n$ eine Schätzung $g(x_1,\ldots,x_n)$ für den unbekannten Parameter $\tau(\boldsymbol{\theta})$. Daher spricht man auch von *Punkt*-Schätzungen. In den seltensten Fällen wird die Schätzung exakt mit $\tau(\boldsymbol{\theta})$ übereinstimmen, sondern bestenfalls „in der Nähe“ liegen. Daher ist es zweckmäßiger, zu gegebener Beobachtung ein Intervall

$$I(x_1,\ldots,x_n) = [U(x_1,\ldots,x_n)\,;\, O(x_1,\ldots,x_n)]$$

anzugeben, in dem der wahre Parameter $\tau(\boldsymbol{\theta})$ mit einer vorgegebenen „Sicherheit“ $1-\alpha$ (**Konfidenzniveau**) liegt. Dies erreicht man durch folgende Konstruktion:

Es liege noch keine Realisation vor, die *Zufalls*variablen $X_1,\ldots,X_n$ seien noch nicht beobachtet. Dann definieren wir ein Intervall so, dass der wahre Parameter $\tau(\boldsymbol{\theta})$ mit *Wahrscheinlichkeit* $1-\alpha$ darin liegen wird, also:

$$P_{\boldsymbol{\theta}}\Big(\tau(\boldsymbol{\theta}) \in [U(X_1,\ldots,X_n);\, O(X_1,\ldots,X_n)]\Big) \geq 1-\alpha \qquad \text{für alle } \boldsymbol{\theta}\in\boldsymbol{\Theta}\,.$$

$1-\alpha$ heißt **Konfidenzniveau** (Konfidenzwahrscheinlichkeit), das Intervall $I(X_1,\ldots,X_n)$ **Konfidenzintervall** für $\tau(\boldsymbol{\theta})$ zum Konfidenzniveau $1-\alpha$.

Wurde eine konkrete Stichprobe $x_1,\ldots,x_n$ realisiert und das zug. Intervall $I(x_1,\ldots,x_n)$ ausgerechnet, so können wir gemäß Konstruktionsprinzip „mit einer *Sicherheit* von $1-\alpha$ darauf vertrauen, dass der wahre Parameterwert von $\tau(\boldsymbol{\theta})$ im berechneten Intervall $I(x_1,\ldots,x_n)$ liegt.“

Beispiel: für 100 simulierte Datensätze der Größe 40, wobei alle Stichprobenvariablen unabhängig und $\mathrm{N}(1,1)$-verteilt sind, wurde jeweils ein Konfidenzintervall für den „unbekannten“ Erwartungswert μ gemäß Formel (III.5) (siehe unten) zum Konfidenzniveau 95 % berechnet. Die grafische Darstellung,

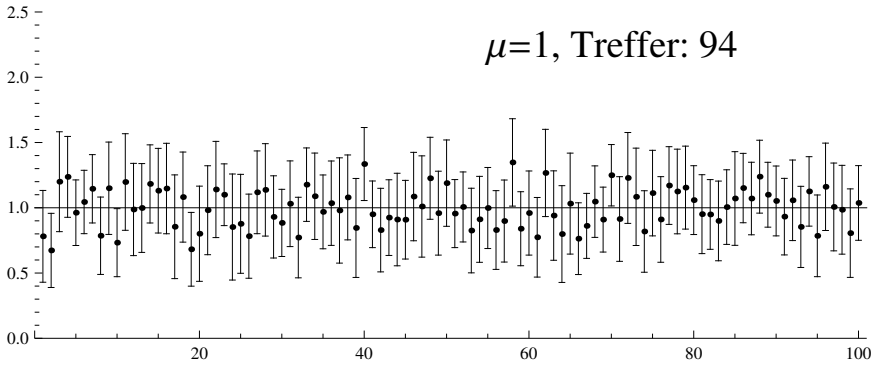

zeigt, dass im konkreten Fall 94 % der Konfidenzintervalle den wahren Wert $\mu = 1$ überdecken.

Konfidenzintervalle für unabhängige normalverteilte Stichprobenvariablen

Es seien $X_1, \ldots, X_n$ unabhängig $\mathrm{N}(\mu, \sigma^2)$-verteilt.

(i) **Konfidenzintervall für μ bei bekannter Varianz $\sigma^2 = \sigma_0^2$.**

$$\boldsymbol{\Theta} = \{(\mu, \sigma_0)^\top \mid \mu \in \mathbb{R}\}, \qquad \tau(\mu, \sigma_0) = \mu\,.$$

Eine Punktschätzung für τ ist das Stichprobenmittel

$$\overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i\,.$$

Der zugehörige Schätzer,

$$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i,$$

ist bei zugrundeliegendem Parameter $\boldsymbol{\theta} = (\mu, \sigma_0)^\top$ gemäß Abschnitt II.4.7 $\mathrm{N}(\mu, \frac{\sigma_0^2}{n})$-verteilt. Damit ist die zugehörige Gauß-Statistik

$$\overline{Y} = \sqrt{n} \cdot \frac{\overline{X} - \mu}{\sigma_0} \qquad \mathrm{N}(0,1)\text{-verteilt.} \tag{III.4}$$

Zu gegebenem Konfidenzniveau $1 - \alpha$ ist also

$$P_{\boldsymbol{\theta}}\left(-z_{1-\frac{\alpha}{2}} \leq \overline{Y} \leq z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha\,,$$

wobei z_q das q-Quantil der Standardnormalverteilung bezeichnet, denn

$$P_{\boldsymbol{\theta}}\left(-z_{1-\frac{\alpha}{2}} \leq \overline{Y} \leq z_{1-\frac{\alpha}{2}}\right) = \Phi(z_{1-\frac{\alpha}{2}}) - \Phi(-z_{1-\frac{\alpha}{2}}) = 2\,\underbrace{\Phi(z_{1-\frac{\alpha}{2}})}_{=1-\frac{\alpha}{2}} - 1 = 1 - \alpha\,.$$

Das zugehörige Konfidenzintervall hat also die Form

$$I(X_1, \ldots, X_n) = \left[\overline{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma_0}{\sqrt{n}}\,;\, \overline{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma_0}{\sqrt{n}}\right]\,.$$

(ii) **Konfidenzintervall für μ bei unbekannter Varianz σ^2.**

$$\boldsymbol{\Theta} = \{(\mu, \sigma)^\top \mid \mu \in \mathbb{R}, \sigma > 0\}\,, \qquad \tau(\mu, \sigma) = \mu\,.$$

Bei unbekannter Varianz σ^2 muss diese erst anhand der Stichprobe $x_1, \ldots, x_n$ geschätzt werden. Dafür bietet sich die Stichprobenvarianz an,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2,$$

mit zugehörigem Schätzer

$$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2\,.$$

Einsetzen in (III.4) liefert als Schätzfunktion

$$\sqrt{n} \cdot \frac{\overline{X} - \mu}{S},$$

und diese ist gemäß Abschnitt II.4.7 t_{n-1}-verteilt. Zu gegebenem Konfidenzniveau $1-\alpha$ ist also

$$P_{\mu,\sigma}\left(-t_{n-1,1-\frac{\alpha}{2}} \leq \sqrt{n} \cdot \frac{\overline{X} - \mu}{S} \leq t_{n-1,1-\frac{\alpha}{2}}\right) = 1 - \alpha\,,$$

wobei $t_{n-1,q}$ das q-Quantil der t-Verteilung mit $n-1$-Freiheitsgraden bezeichnet. Das zugehörige Konfidenzintervall hat somit die Form

$$I(X_1, \ldots, X_n) = \left[\overline{X} - t_{n-1,1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}}\,;\, \overline{X} + t_{n-1,1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}}\right]. \tag{III.5}$$

(iii) **Konfidenzintervall für σ^2.**

$$\boldsymbol{\Theta} = \{(\mu, \sigma)^\top \mid \sigma > 0\}\,, \qquad \tau(\mu, \sigma) = \sigma^2.$$

Eine Punktschätzung für die Varianz σ^2 ist die Stichprobenvarianz

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2$$

mit zugehörigem Schätzer

$$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2\,.$$

Da $X_1, \ldots, X_n$ unabhängig $\mathrm{N}(\mu, \sigma^2)$-verteilt sind, also die $Y_i = \frac{X_i - \mu}{\sigma}$ unabhängig $\mathrm{N}(0,1)$-verteilt sind, folgt, dass

$$\frac{n-1}{\sigma^2} \cdot S^2 = \sum_{i=1}^{n} \left(\frac{X_i - \overline{X}}{\sigma}\right)^2 = \sum_{i=1}^{n} (Y_i - \overline{Y})^2$$

χ^2_{n-1}-verteilt ist, vgl. Abschnitt II.4.7. Zu gegebenem Konfidenzniveau $1-\alpha$ ist also

$$P\left(\chi^2_{n-1,\frac{\alpha}{2}} \leq \frac{n-1}{\sigma^2} \cdot S^2 \leq \chi^2_{n-1,1-\frac{\alpha}{2}}\right) = 1 - \alpha\,,$$

wobei $\chi^2_{n-1,q}$ das q-Quantil der χ^2_{n-1}-Verteilung bezeichnet, denn

$$P\left(\chi^2_{n-1,\frac{\alpha}{2}} \leq \frac{n-1}{\sigma^2} \cdot S^2 \leq \chi^2_{n-1,1-\frac{\alpha}{2}}\right) = F_{\chi^2_{n-1}}\left(\chi^2_{n-1,1-\frac{\alpha}{2}}\right) - F_{\chi^2_{n-1}}\left(\chi^2_{n-1,\frac{\alpha}{2}}\right) = 1 - \alpha\,.$$

Es ergibt sich als Konfidenzintervall zum Konfidenzniveau $1-\alpha$ somit

$$I(X_1, \ldots, X_n) = \left[\frac{(n-1)S^2}{\chi^2_{n-1,1-\frac{\alpha}{2}}}\,;\, \frac{(n-1)S^2}{\chi^2_{n-1,\frac{\alpha}{2}}}\right].$$

Bemerkung.
Ist die Normalverteilungsannahme an die Stichprobenvariablen $X_1, \ldots, X_n$ nicht gerechtfertigt, so kann man unter Ausnutzung des zentralen Grenzwertsatzes (vgl. Abschnitt II.5.3) eine Normalapproximation für die standardisierte Summe $\sqrt{n} \cdot \frac{\overline{X} - \mu}{\sigma}$ betrachten.

Dazu noch der wichtige Spezialfall von unabhängig Bernoulli-verteilten Stichprobenvariablen

$$X_1, \ldots, X_n\,.$$

In diesem Falle ist die Summe

$$S_n = X_1 + \ldots + X_n$$

$\mathrm{Bin}(n, \pi)$-verteilt, bei unbekannter Erfolgswahrscheinlichkeit π. Nach dem Satz von de Moivre-Laplace (vgl. Abschnitt II.5.4) ist

$$S_n^* := \frac{S_n - n\pi}{\sqrt{n\pi(1-\pi)}} = \sqrt{n} \cdot \frac{\overline{X} - \pi}{\sqrt{\pi(1-\pi)}}$$

näherungsweise $\mathrm{N}(0,1)$-verteilt, also

$$P\left(-z_{1-\frac{\alpha}{2}} \leq S_n^* \leq z_{1-\frac{\alpha}{2}}\right) \approx 1 - \alpha\,.$$

Hierbei bezeichnet z_q wieder das q-Quantil der $\mathrm{N}(0,1)$-Verteilung. Auflösen der Ungleichungen

$$-z_{1-\frac{\alpha}{2}} \leq \sqrt{n} \cdot \frac{\overline{X} - \pi}{\sqrt{\pi(1-\pi)}} \leq z_{1-\frac{\alpha}{2}}$$

nach π liefert

$$\overline{X} - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\pi(1-\pi)}{n}} \leq \pi \leq \overline{X} + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\pi(1-\pi)}{n}}.$$

Approximiert man ferner $\pi(1-\pi)$ durch $\overline{X}(1-\overline{X})$, so ist

$$I(X_1, \ldots, X_n) = \left[\overline{X} - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\overline{X}(1-\overline{X})}{n}}\,;\, \overline{X} + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\overline{X}(1-\overline{X})}{n}}\right]$$

ein approximatives Konfidenzintervall für π zum Konfidenzniveau $1 - \alpha$.

Beispiel. In einem Warenposten mit Bauteilen soll der Anteil der defekten Bauteile geschätzt werden. Dazu wird eine Stichprobe von 200 Bauteilen überprüft. Angenommen, es werden dabei 6 defekte Bauteile gefunden, so ergibt sich für den Ausschussanteil bei Konfidenzniveau 0.95, also $\alpha = 0.05$, das approximative Konfidenzintervall

$$[0.0064; 0.0536]\,.$$

Interpretation: Mit einer *Sicherheit* von etwa 95% liegt der tatsächliche Anteil der defekten Bauteile im getesteten Warenposten zwischen 0.64 Prozent und 5.36 Prozent.

III.2 Testen

III.2.1 Grundlagen aus der Testtheorie

Ein zentrales Problem der Statistik ist die Frage, wie eine Vermutung über eine Eigenschaft der Verteilung einer Grundgesamtheit anhand einer Stichprobe überprüft werden kann. Eine solche Vermutung bezeichnet man als **Nullhypothese** H_0. Ein **statistischer Test** ist dann zunächst einmal eine **Entscheidungsregel**

$$\varphi(x_1, \ldots, x_n) \in \{0, 1\},$$

die als Funktion der n Beobachtungen $x_1, \ldots, x_n$ die Hypothese H_0 verwirft (falls $\varphi(x_1, \ldots, x_n) = 1$) oder nicht verwirft (falls $\varphi(x_1, \ldots, x_n) = 0$). Demnach ist ein Test durch seinen **Verwerfungsbereich** (auch: **kritischer Bereich**), also durch die Menge

$$K = \{(x_1, \ldots, x_n) \mid \varphi(x_1, \ldots, x_n) = 1\},$$

eindeutig bestimmt.

Beispiel.
Wir betrachten wieder das Beispiel der Lieferung der Bauteile. Als Vermutung über den Anteil der defekten Bauteile soll die Nullhypothese

$$H_0\text{: Anteil der defekten Bauteile beträgt höchstens } 10\%$$

mit Hilfe eines statistischen Tests anhand einer Stichprobe von $n = 100$ Bauteile überprüft werden. In diesem Fall wird man den Verwerfungsbereich mit Hilfe einer kritischen Schranke c definieren, ab der man sagt: Ist die beobachtete Anzahl $S_{100} = \sum_{i=1}^{100} X_i > c$, so wird die Nullhypothese verworfen.

Es kann nun allerdings vorkommen, dass die Hypothese in Wahrheit zutrifft, aber aufgrund der getroffenen Entscheidungsregel verworfen wird, da die beobachtete Anzahl s_n der defekten Bauteile die kritische Schranke übersteigt **(Fehler 1. Art)**. Die Wahrscheinlichkeit für eine solche fälschliche Ablehnung von H_0 soll möglichst klein sein. Dazu gibt man sich ein **Niveau** α vor (etwa $\alpha = 0.05$) und bestimmt die kritische Schranke c so, dass die Wahrscheinlichkeit für eine fälschliche Ablehnung der Hypothese maximal α ist.

Man könnte natürlich c so wählen, dass die Wahrscheinlichkeit eines Fehlers 1. Art Null ist (einfach: Hypothese niemals ablehnen!). Dann wird der statistische Test aber sinnlos, da er nicht mehr zwischen „guter“ und „schlechter“ Warenprobe unterscheidet. Deshalb wählt man c minimal, um damit die Wahrscheinlichkeit dafür, die Nullhypothese zu verwerfen, wenn sie tatsächlich nicht zutrifft, zu maximieren. Diese Wahrscheinlichkeit nennt man die **Macht** (engl.: **power**) oder **Trennschärfe** des statistischen Tests. Das zug. Komplementärereignis, d.h. die Nullhypothese nicht abzulehnen, obwohl sie gar nicht zutrifft, heißt **Fehler 2. Art**.

Die möglichen Ausgänge eines statistischen Tests im Überblick:

	Entscheidung	
	für H_0	gegen H_0
H_0 wahr	richtig	falsch Fehler 1. Art
H_0 falsch	falsch Fehler 2. Art	richtig

- **Niveau** = maximale Wahrscheinlichkeit für einen Fehler 1. Art
- **Macht** = Komplementärwahrscheinlichkeit für einen Fehler 2. Art

Ein **Signifikanztest** zum **Signifikanzniveau** α, $0 < \alpha < 1$, ist ein statistischer Test zum Niveau α, d.h. ein Test mit

$$P\,(\text{„Fehler 1. Art“}) \leq \alpha\,.$$

Beispiel. Im obigen Beispiel geht man also wie folgt vor: Zu α wähle c minimal mit

$$P_{0.1}\,(S_{100} > c) \;\leq\; \alpha\,.$$

Hierbei deutet der Index 0.1 an, dass S_{100} unter H_0 im schlechtesten Fall gerade $\mathrm{Bin}(100, 0.1)$-verteilt ist. Die Normalapproximation für

$$S^*_{100} = \frac{S_{100} - 100 \cdot 0.1}{\sqrt{100 \cdot 0.1(1-0.1)}} = \frac{S_{100} - 10}{3}$$

ergibt

$$P_{0.1}\,(S_{100} > c) = P_{0.1}\left(S^*_{100} > \frac{c-10}{3}\right) \approx 1 - \Phi\left(\frac{c-10}{3}\right)\,.$$

Also ist c minimal zu wählen mit

$$\Phi\left(\frac{c-10}{3}\right) = 1 - \alpha, \qquad \text{und das liefert } c = 3z_{1-\alpha} + 10\,.$$

Setzen wir etwa ein Niveau von 5 % an, so ist $3z_{1-\alpha}+10 \approx 14.9$, d.h. die Normalapproximation führt zu folgender Entscheidungsregel:

$$\text{Lehne } H_0 \text{ ab, wenn } S_{100} \geq 15 \text{ ist.}$$

tatsächlich erhält man unter Verwendung der exakten $\mathrm{Bin}\,(100, 0.1)$-Verteilung jedoch, dass $P_{0.1}\,(S_{100} \geq 15) \approx 0.073 > 0.05$ ist, d.h. das geforderte Niveau $\alpha = 0.05$ wird nicht eingehalten. Grund: Die Normalapproximation der $\mathrm{Bin}\,(100, 0.1)$-Verteilung ist im betrachteten Beispiel nicht ausreichend gut, vgl. auch die Faustregel in Abschnitt II.5.4.

Unter Verwendung der exakten $\mathrm{Bin}\,(100, 0.1)$-Verteilung folgt aber, dass $P_{0.1}\,(S_{100} > 15) \approx 0.0399 \leq 0.05$ ist. Also sollte $c = 15$ gewählt werden.

Allgemein: Approximativer Binomialtest. („Gut-Schlecht“-prüfung)

Gegeben sei die Summe

$$S_n = X_1 + \ldots + X_n$$

von n unabhängig Bernoulli-verteilten Zufallsvariablen X_i mit unbekanntem Parameter π. Es bestehe die Nullhypothese

$$H_0 \,:\, \pi \leq \pi_0$$

zu fest gewähltem Parameter $\pi_0 \in [0; 1]$.

Zu gegebenem Niveau α bestimme man dann die kritische Schranke

$$c = \sqrt{n\pi_0(1-\pi_0)} \cdot z_{1-\alpha} + n\pi_0\,.$$

Die Hypothese ist zu verwerfen, falls die Stichprobensumme $s_n = \sum_{i=1}^n x_i$ größer als c ist.

Die hierbei gemachte Normalapproximation ist für praktische Bedürfnisse als hinreichend zu erachten, wenn $n\pi_0(1-\pi_0) > 9$ gilt.

Bemerkung. (Zweiseitiger approximativer Binomialtest)
tatsächlich haben wir bei obigem Test nur getestet, ob der Anteil der defekten Bauteile gleich 10% ist, wenn der unbekannte Parameter π aus der Menge $[0.1; 1]$ stammt. Ist allerdings auch $\pi < 0.1$ relevant, so setzt sich der Verwerfungsbereich aus einer unteren kritischen Schranke c_u und einer oberen kritischen Schranke c_o zusammen:

$$K = \{(x_1, \ldots, x_n) \,|\, s_n < c_u\} \cup \{(x_1, \ldots, x_n) \,|\, s_n > c_o\},$$

und man spricht von einem **zweiseitigen Ablehnungsbereich**.

Zweckmäßigerweise wählt man dann zu gegebenem Niveau α

$$\begin{aligned} c_u &= -\sqrt{n\pi_0(1-\pi_0)} \cdot z_{1-\frac{\alpha}{2}} + n\pi_0 \\ c_o &= \sqrt{n\pi_0(1-\pi_0)} \cdot z_{1-\frac{\alpha}{2}} + n\pi_0\,, \end{aligned}$$

d.h., die Nullhypothese wird verworfen, wenn die Stichprobensumme kleiner c_u oder größer c_o ist, oder in Größen der standardisierten Summe

$$S_n^* = \frac{S_n - n\pi_0}{\sqrt{n\pi_0(1-\pi_0)}}\,,$$

falls $|S_n^*| > z_{1-\frac{\alpha}{2}}$ ist.

Der **approximative Binomialtest** im Überblick:

Test auf den Parameter π einer Binomialverteilung.

Annahme:
$X_1, \ldots, X_n$ unabhängig Bernoulli-verteilt, also $S_n = X_1 + \ldots + X_n$ binomialverteilt.

Hypothese:

(a) $H_0 : \pi = \pi_0$; (b) $H_0 : \pi \leq \pi_0$; (c) $H_0 : \pi \geq \pi_0$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \frac{S_n - n\pi_0}{\sqrt{n\pi_0(1-\pi_0)}} = \sqrt{n} \cdot \frac{\overline{X} - \pi_0}{\sqrt{\pi_0(1-\pi_0)}},$$

welche approximativ $\mathrm{N}(0,1)$-verteilt ist, falls $\pi = \pi_0$ (und $n\pi_0(1-\pi_0) > 9$) ist.
Hierbei ist $\overline{X} := \frac{1}{n}\sum_{i=1}^n X_i$ das Stichprobenmittel.

Ablehnung von H_0, falls

(a) $|T| > z_{1-\frac{\alpha}{2}}$; (b) $T > z_{1-\alpha}$; (c) $T < -z_{1-\alpha}$.

Will man die Annahme an die Verteilung der Stichprobenvariablen fallenlassen, muss man sich im Allgemeinen auf das Testen einiger weniger Kennzahlen beschränken. Im Folgenden wollen wir einige grundlegende Testverfahren besprechen, eine umfassendere Methodensammlung bietet [8].

III.2.2 Ein-Stichproben-Tests

Gauß-Test

Test auf den Erwartungswert μ einer Verteilung bei bekannter Varianz.

Annahme:
$X_1, \ldots, X_n$ i.i.d. mit bekannter Varianz $V[X_i] = \sigma_0^2$, und $X_i \sim \mathrm{N}(\mu, \sigma_0^2)$.
Ist $n \geq 30$, so kann X_i beliebig verteilt sein (vgl. Abschnitt II.5.3), aber mit $E[X_i] = \mu$.

Hypothese:

(a) $H_0 : \mu = \mu_0$; (b) $H_0 : \mu \leq \mu_0$; (c) $H_0 : \mu \geq \mu_0$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \sqrt{n} \cdot \frac{\overline{X} - \mu_0}{\sigma_0},$$

welche (approximativ) $\mathrm{N}(0,1)$-verteilt ist, falls $\mu = \mu_0$, wobei

$$\overline{X} := \frac{1}{n} \sum_{i=1}^{n} X_i$$

das Stichprobenmittel bezeichnet.

Ablehnung von H_0, falls

(a) $|T| > z_{1-\frac{\alpha}{2}}$; (b) $T > z_{1-\alpha}$; (c) $T < -z_{1-\alpha}$.

t-Test

Test auf den Erwartungswert μ einer Verteilung bei unbekannter Varianz.

Annahme:
$X_1, \ldots, X_n$ i.i.d., und $X_i \sim \mathrm{N}(\mu, \sigma^2)$, σ^2 unbekannt.
Ist $n \geq 30$, so kann X_i beliebig verteilt sein (vgl. Abschnitt II.5.3), aber mit $E[X_i] = \mu$.

Hypothese:

(a) $H_0 : \mu = \mu_0$; (b) $H_0 : \mu \leq \mu_0$; (c) $H_0 : \mu \geq \mu_0$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \sqrt{n} \cdot \frac{\overline{X} - \mu_0}{S},$$

welche (approximativ) t_{n-1}-verteilt ist, falls $\mu = \mu_0$, wobei

$$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2$$

die Stichprobenvarianz bezeichnet.

Ablehnung von H_0, falls

(a) $|T| > t_{n-1,1-\frac{\alpha}{2}}$; (b) $T > t_{n-1,1-\alpha}$; (c) $T < -t_{n-1,1-\alpha}$.

Für $n \geq 30$ kann man die Quantile der t-Verteilung durch die entsprechenden Quantile der Standardnormalverteilung ersetzen (vgl. Abschnitt II.4.7).

χ^2-Test für die Varianz

Annahme:
$X_1, \ldots, X_n$ i.i.d., und $X_i \sim \mathrm{N}(\mu, \sigma^2)$, μ unbekannt.

Hypothese:

(a) $H_0 : \sigma^2 = \sigma_0^2$; (b) $H_0 : \sigma^2 \leq \sigma_0^2$; (c) $H_0 : \sigma^2 \geq \sigma_0^2$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \frac{n-1}{\sigma_0^2} \cdot S^2,$$

welche χ^2_{n-1}-verteilt ist, falls $\sigma^2 = \sigma_0^2$.

Ablehnung von H_0, falls

(a) $T < \chi^2_{n-1,\frac{\alpha}{2}}$ oder $T > \chi^2_{n-1,1-\frac{\alpha}{2}}$; (b) $T > \chi^2_{n-1,1-\alpha}$; (c) $T < \chi^2_{n-1,\alpha}$.

III.2.3 Ergänzung: P-Werte und Gütefunktion

Anhand des Gauß-Tests lassen sich zwei weitere wichtige Begriffsbildungen eines Signifikanztestes veranschaulichen, nämlich Überschreitungswahrscheinlichkeiten (P-Werte) und die Gütefunktion.

Überschreitungswahrscheinlichkeiten (P-Werte)

P-Werte spielen bei Signifikanztests eine wichtige Rolle und werden von statistischen Softwarepaketen standardmäßig ausgegeben. Anhand des Gauß-Tests lässt sich ihre Bedeutung besonders einfach erläutern. Betrachtet werden soll im Folgenden die Hypothese $H_0 : \mu \geq \mu_0$ über den unbekannten Erwartungswert μ einer Normalverteilung, deren Varianz σ_0^2 bekannt sei. Anhand der Teststatistik

$$T = \sqrt{n} \cdot \frac{\overline{X} - \mu_0}{\sigma_0}, \qquad \overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_i,$$

kann die Hypothese zum Signifikanzniveau α überprüft werden. In diesem Fall ergibt sich als Ablehnungsbereich das Intervall $(-\infty; z_\alpha)$.

Ist t nun der tatsächlich beobachtete Wert der Teststatistik T, so ist der P-Wert definiert durch

$$p := P_{\mu_0}(T \leq t)\,.$$

Hierbei deutet der Index μ_0 an, dass für die Verteilung der Stichprobenvariablen die $\mathrm{N}(\mu_0, \sigma_0^2)$-Verteilung angenommen wird, wie sie der Nullhypothese H_0 entspricht. Die Teststatistik T ist unter dieser Annahme gerade $\mathrm{N}(0,1)$-verteilt, und damit

$$p = P_{\mu_0}(T \leq t) = \Phi(t)\,.$$

Der **P-Wert** gibt also die Wahrscheinlichkeit dafür an, unter der Hypothese H_0 den tatsächlich beobachteten Wert der Teststatistik, t, oder einen in Richtung der Alternative $\mu < \mu_0$ noch extremeren Wert zu erhalten. Ein sehr kleiner P-Wert impliziert also, dass die Nullhypothese H_0 unplausibel ist und entsprechend abgelehnt werden sollte.

Der P-Wert ist also das größte Niveau α', bei dem der beobachtete Wert t noch zur Annahme der Nullhypothese H_0 führt. Mit Hilfe des ermittelten P-Wertes p lässt sich die **Entscheidungsregel** im Falle der Hypothese $H_0 : \mu \geq \mu_0$ und bei Signifikanzniveau α wie folgt formulieren:

Ablehnung der Hypothese H_0, falls $p < \alpha$.

Beispiel. In der Abfüllanlage einer Brauerei werden 0.5-Liter Flaschen befüllt. Die tätsächliche Füllmenge X pro Flasche (in cm^3) kann als normalverteilt mit gewissem Erwartungswert μ und mit bekannter Standardabweichung $\sigma_0 = 1.5\,[\text{cm}^3]$ betrachtet werden. Eine Verbraucherschutzorganisation will nun überprüfen, ob die tatsächliche Abfüllmenge den Sollwert $\mu_0 = 500$ im Mittel nicht unterschreitet, d. h. die folgende Nullhypothese wird betrachtet:

$$H_0 : \mu \geq \mu_0, \qquad \text{d. h. } \mu \geq 500.$$

Ein Ablehnen von H_0 würde dem Hersteller also eine signifikante Verletzung seiner eigenen Versprechen nachweisen.

Die Verbraucherschutzorganisation plant daher, eine Stichprobe der Länge $n = 25$ zu erheben, die zugehörige Teststatistik ist gemäß Abschnitt III.2.2

$$T = T(X_1, \ldots, X_{25}) = 5 \cdot \frac{\overline{X} - 500}{1.5}.$$

Der Test soll zum Signifikanzniveau $\alpha = 0.01$ ausgeführt werden, also ergibt sich wegen $z_{0.01} = -2.326$ der Ablehnungsbereich $(-\infty; -2.326)$.

Nun wurden die Daten erhoben. Angenommen, als Stichprobenmittel ergibt sich der Wert $\bar{x} = 499.28$, also eine leichte Unterschreitung der geforderten Füllmenge. Der zugehörige Wert der Teststatistik ist dann

$$t = 5 \cdot \frac{499.28 - 500}{1.5} = -2.4 \ < -2.326,$$

und damit kann die Hypothese $\mu \geq 500$ verworfen werden. Die Verbraucherschutzorganisation kann also auf Basis ihres Testergebnisses behaupten, dass der Brauereibesitzer die geforderte Füllmenge aufgrund ihres Testergebnisses zum Signifikanzniveau $\alpha = 0.01$ nicht einhält.

Als P-Wert ergibt sich in diesem Fall

$$p = P_{500}(T \leq -2.4) = \Phi(-2.4) = 0.008,$$

d.h. zum Signifikanzniveau $\alpha = 0.008$ (oder kleiner) wäre die Hypothese nicht abgelehnt worden.

Warnung: Ein „nachträgliches Anpassen“ des Signifikanzniveaus α, welches zur Annahme der Hypothese führt, ist unzulässig!

Gütefunktion

Die Gütefunktion eines statistischen Tests ist definiert als die Wahrscheinlichkeit für die Ablehnung der Nullhypothese H_0. Die Gütefunktion eines idealen Tests hat folgende Form:

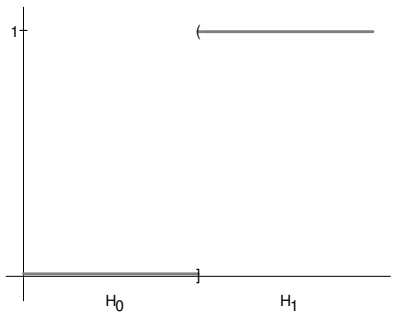

Bei diesem Ideal-Test sind sowohl die Wahrscheinlichkeit für einen Fehler 1. Art als auch die Wahrscheinlichkeit für einen Fehler 2. Art beide gleich 0.

Als konkretes Beispiel eines realen Tests betrachten wir erneut den Gauß-Test mit normalverteilten Stichprobenvariablen und der Hypothese $H_0 : \mu \leq \mu_0$ zum Signifikanzniveau α. Der Ablehnungsberereich ist diesmal das Intervall $(z_{1-\alpha}; \infty)$ (vgl. Abschnitt III.2.2), und wir können die Wahrscheinlichkeit für eine Ablehnung der Nullhypothese H_0 als Funktion des unbekannten Erwartungswertes μ schreiben, d.h.

$$g(\mu) = P_\mu\left(T > z_{1-\alpha}\right) = P_\mu\left(\sqrt{n} \cdot \frac{\overline{X} - \mu_0}{\sigma_0} > z_{1-\alpha}\right).$$

Zur Berechnung dieser Wahrscheinlichkeit beachte man, dass, falls μ den wahren Erwartungswert bezeichnet,

$$\sqrt{n} \cdot \frac{\overline{X} - \mu}{\sigma_0} \quad \mathrm{N}(0,1) - \text{verteilt ist},$$

also

$$g(\mu) \;=\; P_\mu\left(\sqrt{n} \cdot \frac{\overline{X} - \mu}{\sigma_0} > z_{1-\alpha} + \sqrt{n} \cdot \frac{\mu_0 - \mu}{\sigma_0}\right) \;=\; 1 - \Phi\left(z_{1-\alpha} + \sqrt{n} \cdot \frac{\mu_0 - \mu}{\sigma_0}\right).$$

Insbesondere ist g monoton wachsend in μ und $g(\mu_0) = \alpha$.

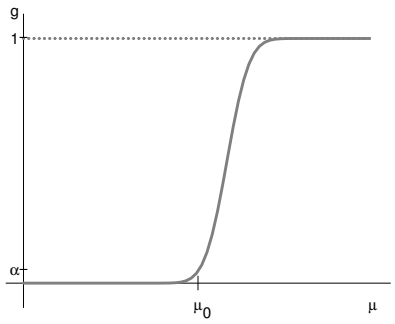

Mit wachsender Stichprobenlänge n wird die Gütefunktion optimal:

$$\lim_{n\to\infty} g_n(\mu) = \begin{cases} 0 & \text{für } \mu < \mu_0, \\ 1 & \text{für } \mu > \mu_0. \end{cases}$$

Zusammenfassung:

- für Parameterwerte aus dem Bereich der Nullhypothese H_0 ist die Gütefunktion $\leq \alpha$, für Parameterwerte aus dem Bereich der Alternativhypothese heißt die Gütefunktion auch Macht oder Trennschärfe.
- Die Macht eines Tests wird größer, wenn α wächst (man also den Fehler 1. Art öfter zulässt), oder wenn n wächst (man also mehr Aufwand in die Datenerhebung investiert).

III.2.4 Ergänzung: Tests basierend auf Häufigkeiten

Statt Verteilungen nur auf Erwartungswerte oder Varianzen zu überprüfen, kann man auch Hypothesen untersuchen, die sich direkt auf eine oder mehrere Verteilungen beziehen, vgl. auch Abschnitt I.2.1. Entsprechend werden hier Teststatistiken auf Basis von Häufigkeiten definiert. Auch der zu Beginn von Abschnitt III.2.5 zu besprechende χ^2-Homogenitätstest verwendet diesen Ansatz, um eine Mehrstichproben-Hypothese zu überprüfen.

χ^2-Anpassungstest

Häufig ist man daran interessiert zu untersuchen, ob die unbekannte Verteilung einer Grundgesamtheit gleich einer gegebenen hypothetischen Verteilung ist (mit gegebener Verteilungsfunktion F_0). Bei den obigen Testverfahren wurde z. B. oft gefordert, dass die Grundgesamtheit normalverteilt ist.

Annahme:
$X_1, \ldots, X_n$ i.i.d. mit einer (unbekannten) Verteilungsfunktion F.

Hypothese: $H_0 : F = F_0$.

Im nächsten Schritt unterteilen wir die X-Achse in $k \geqslant 2$ disjunkte Intervalle

$$A_1 = (-\infty; z_1],\ A_2 = (z_1; z_2],\ \ldots,\ A_k = (z_{k-1}; \infty),$$

und bestimmen für jedes Intervall A_j

- die Anzahl N_j der in A_j liegenden Stichprobenvariablen,

$$N_j = \big|\{X_i \mid X_i \in A_j\}\big|;$$

- die theoretische Wahrscheinlichkeit p_j dafür, dass eine Stichprobenvariable X mit Verteilungsfunktion F_0 einen Wert in A_j annimmt, also

$$p_j = P(X \in A_j) = F_0(z_j) - F_0(z_{j-1})\,.$$

  Hierbei setzt man $F_0(z_0) = 0$ und $F_0(z_k) = 1$.

Hinweis: Ist der Wertebereich der Stichprobenvariablen endlich, etwa $\{a_1, \ldots, a_k\}$, so kann man auf die Klassierung verzichten und N_j, p_j definieren durch

$$N_j = \big|\{X_i \,|\, X_i = a_j\}\big|, \qquad p_j = P(X = a_j)\,.$$

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \sum_{j=1}^{k} \frac{(N_j - np_j)^2}{np_j} \quad \left(= \left(\frac{1}{n} \sum_{j=1}^{k} \frac{N_j^2}{p_j} \right) - n \right).$$

Ablehnung von H_0, falls

$$T > \chi^2_{k-1,1-\alpha}\,.$$

Dieser Test hat dann das approximative Niveau α.

Hinweis: Diese Approximation ist für praktische Bedürfnisse als hinreichend zu erachten, wenn die *erwartete* Anzahl der Beobachtungen pro Intervall mindestens 5 ist, d. h. wenn $np_j \geq 5$ für alle $j = 1, \ldots, k$ gilt.

χ^2-Test auf Unabhängigkeit (Kontingenztest)

Ausgangspunkt des Tests auf unabhängigkeit ist die Frage, ob zwei Merkmale X und Y in einer gegebenen Grundgesamtheit voneinander unabhängig sind oder nicht. Es ist also ein statistischer Test zu konstruieren, der aufgrund einer zweidimensionalen Stichprobe

$$(x_1, y_1), \ldots, (x_n, y_n)$$

entscheidet, ob die folgende Hypothese abzulehnen ist oder nicht (siehe auch Abschnitt I.3.1):

Hypothese: $H_0 : X$ und Y sind unabhängig.

Im nächsten Schritt unterteilen wir die X-Achse in $I \geq 2$ disjunkte Intervalle

$$A_1 = (-\infty; z_1],\ A_2 = (z_1; z_2],\ \ldots,\ A_I = (z_{I-1}; \infty),$$

und die Y-Achse in $J \geq 2$ disjunkte Intervalle

$$B_1 = (-\infty; \tilde{z}_1],\ B_2 = (\tilde{z}_1; \tilde{z}_2],\ \ldots,\ B_J = (\tilde{z}_{J-1}; \infty).$$

Hierzu stellen wir dann die zughörige Kontingenztabelle mit Randhäufigkeiten auf,

		$Y:$ B_1	B_2	$\ldots$	B_J	
$X:$	A_1	N_{11}	N_{12}	$\ldots$	N_{1J}	$N_{1\bullet}$
	A_2	N_{21}	N_{22}	$\ldots$	N_{2J}	$N_{2\bullet}$
	$\vdots$	$\vdots$			$\vdots$	$\vdots$
	A_I	N_{I1}	N_{I2}	$\cdots$	N_{IJ}	$N_{I\bullet}$
		$N_{\bullet 1}$	$N_{\bullet 2}$	$\ldots$	$N_{\bullet J}$	n

und bilden die Größen (siehe auch Formel (I.3) in Abschnitt I.3.1)

$$\tilde{N}_{ij} := \frac{N_{i\bullet} N_{\bullet j}}{n} \qquad \text{für } i = 1, \ldots, I \text{ und } j = 1, \ldots, J\,.$$

Idee: Unter der Hypothese H_0 sind die Merkmale X und Y unabhängig, und damit gilt

$$P(X \in A_i,\ Y \in B_j) = P(X \in A_i) \cdot P(Y \in B_j)\,. \tag{III.6}$$

Bei großer Stichprobenlänge n sollten zudem die relativen Häufigkeiten in der Nähe der theoretischen Wahrscheinlichkeiten liegen (vgl. Abschnitt II.5.1), also

$$\frac{N_{ij}}{n} \approx P(X \in A_i, Y \in B_j)\,, \qquad \frac{N_{i\bullet}}{n} \approx P(X \in A_i) \qquad \text{und} \qquad \frac{N_{\bullet j}}{n} \approx P(Y \in B_j)\,.$$

Insgesamt sollte also gelten

$$\frac{N_{ij}}{n} \approx P(X \in A_i,\ Y \in A_j) = P(X \in A_i) \cdot P(Y \in A_j) \approx \frac{N_{i\bullet}}{n} \cdot \frac{N_{\bullet j}}{n}\,,$$

also $N_{ij} \approx \tilde{N}_{ij}$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \sum_{i=1}^{I} \sum_{j=1}^{J} \frac{\left(N_{ij} - \tilde{N}_{ij}\right)^2}{\tilde{N}_{ij}} = \left(\sum_{i=1}^{I} \sum_{j=1}^{J} \frac{N_{ij}^2}{\tilde{N}_{ij}} \right) - n\,.$$

Ablehnung von H_0, falls

$$T > \chi^2_{(I-1)(J-1),1-\alpha}.$$

Dieser Test hat dann das approximative Niveau α.

Hinweis: Diese Approximation ist für praktische Bedürfnisse als hinreichend zu erachten, wenn $\tilde{N}_{ij} = \frac{N_{i\bullet} N_{\bullet j}}{n} \geq 5$ für alle $i = 1, \ldots, I$ und $j = 1, \ldots, J$ gilt.

III.2.5 Ergänzung: Mehr-Stichproben-Tests

Bei Mehr-Stichproben-Tests sollen Zusammenhänge mehrerer unabhängiger Stichproben mit möglicherweise verschiedenen Längen,

$$\begin{array}{c} X_1^{(1)}, \ldots, X_{n_1}^{(1)}, \\ X_1^{(2)}, \ldots, X_{n_2}^{(2)}, \\ \vdots \\ X_1^{(k)}, \ldots, X_{n_k}^{(k)}, \end{array}$$

getestet werden. Die zentrale Frage in diesem Zusammenhang ist dann die nach der Gleichheit der zugrundeliegenden Verteilungen bzw. nach der Gleichheit gewisser Kennzahlen der zugrundeliegenden Verteilungen.

χ^2-Homogenitätstest

Annahme:

$$\begin{array}{ll} X_1^{(1)}, \ldots, X_{n_1}^{(1)} & \text{i.i.d. mit Verteilungsfunktion } F_1, \\ X_1^{(2)}, \ldots, X_{n_2}^{(2)} & \text{i.i.d. mit Verteilungsfunktion } F_2, \\ \vdots & \\ X_1^{(k)}, \ldots, X_{n_k}^{(k)} & \text{i.i.d. mit Verteilungsfunktion } F_k. \end{array}$$

Hypothese: $H_0 : F_1 = F_2 = \ldots = F_k$.

Im nächsten Schritt unterteilen wir zunächst die X-Achse in $m \geq 2$ disjunkte Intervalle

$$A_1 = (-\infty; z_1], \; A_2 = (z_1; z_2], \; \ldots, \; A_m = (z_{m-1}; \infty),$$

und bestimmen für jedes Intervall die Häufigkeiten

$$N_{ij} = \left| \{ X_l^{(i)} \mid X_l^{(i)} \in A_j \} \right| \qquad \text{für } i = 1, \ldots, k \text{ und } j = 1, \ldots, m.$$

Anschließend bilden wir hierzu die Spaltensummen

$$N_{\bullet j} = N_{1j} + \ldots + N_{kj} \qquad \text{für } j = 1, \ldots, m.$$

Idee: Unter der Hypothese H_0 sind die Stichprobenvariablen allesamt identisch verteilt, und damit sollten für alle j die relativen Häufigkeiten

$$\frac{N_{ij}}{n_i} \qquad \text{für } i = 1, \ldots, k$$

nahezu übereinstimmen, d.h.

$$\frac{N_{ij}}{n_i} \approx \frac{N_{\bullet j}}{n} \qquad \text{oder} \qquad N_{ij} - \frac{n_i N_{\bullet j}}{n} \approx 0\,.$$

Hierbei ist $n = n_1 + \ldots + n_k$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1^{(1)}, \ldots, X_{n_k}^{(k)}) = \sum_{i=1}^{k} \sum_{j=1}^{m} \frac{\left(N_{ij} - \frac{n_i N_{\bullet j}}{n} \right)^2}{\frac{n_i N_{\bullet j}}{n}}\,.$$

Ablehnung von H_0, falls

$$T > \chi^2_{(k-1)(m-1),1-\alpha}.$$

Dieser Test hat dann das approximative Niveau α.

Hinweis: Diese Approximation ist für praktische Bedürfnisse als hinreichend zu erachten, wenn $\frac{n_i N_{\bullet j}}{n} \geq 5$ für alle $i = 1, \ldots, k$ und $j = 1, \ldots, m$ gilt.

Zwei-Stichproben-Gauß-Test

Test auf Gleichheit der Erwartungswerte μ_X und μ_Y zweier Verteilungen bei bekannten Varianzen.

Annahme:
$X_1, \ldots, X_m$ i.i.d. mit bekannter Varianz $\sigma^2_{X,0}$, und $X_i \sim \mathrm{N}(\mu_X, \sigma^2_{X,0})$;
$Y_1, \ldots, Y_n$ i.i.d. mit bekannter Varianz $\sigma^2_{Y,0}$, und $Y_i \sim \mathrm{N}(\mu_Y, \sigma^2_{Y,0})$.
Sind $m, n \geq 30$, so können X_i, Y_j jeweils beliebig verteilt sein, aber mit

$$E[X_i] = \mu_X\,, \quad V[X_i] = \sigma^2_{X,0}\,, \quad E[Y_j] = \mu_Y\,, \quad V[Y_j] = \sigma^2_{Y,0}.$$

Hypothese:

(a) $H_0 : \mu_X = \mu_Y$; (b) $H_0 : \mu_X \leq \mu_Y$; (c) $H_0 : \mu_X \geq \mu_Y$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_m, Y_1, \ldots, Y_n) = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma^2_{X,0}}{m} + \frac{\sigma^2_{Y,0}}{n}}},$$

welche (approximativ) $\mathrm{N}(0,1)$-verteilt ist, falls $\mu_X = \mu_Y$.

Ablehnung von H_0, falls

(a) $|T| > z_{1-\frac{\alpha}{2}}$; (b) $T > z_{1-\alpha}$; (c) $T < -z_{1-\alpha}$.

Zwei-Stichproben-t-Test

Test auf Gleichheit der Erwartungswerte μ_X und μ_Y zweier Verteilungen bei unbekannten **aber gleichen** Varianzen (**Varianzhomogenität**).

Annahme:
$X_1, \ldots, X_m$ i.i.d., und $X_i \sim \mathrm{N}(\mu_X, \sigma^2_X)$;
$Y_1, \ldots, Y_n$ i.i.d., und $Y_i \sim \mathrm{N}(\mu_Y, \sigma^2_Y)$; $\sigma^2_X = \sigma^2_Y$ unbekannt.
Sind $m, n \geq 30$, so können X_i, Y_j jeweils beliebig verteilt sein, aber mit

$$E[X_i] = \mu_X\,, \quad E[Y_j] = \mu_Y\,, \quad V[X_i] = \sigma^2_X \;=\; V[Y_j] = \sigma^2_Y.$$

Hypothese:

(a) $H_0 : \mu_X = \mu_Y$; (b) $H_0 : \mu_X \leq \mu_Y$; (c) $H_0 : \mu_X \geq \mu_Y$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_m, Y_1, \ldots, Y_n) = \sqrt{\frac{mn(m+n-2)}{m+n}} \cdot \frac{\bar{X} - \bar{Y}}{\sqrt{(m-1)S^2_X + (n-1)S^2_Y}},$$

welche (approximativ) t_{m+n-2}-verteilt ist, falls $\mu_X = \mu_Y$, wobei

$$S^2_X = \frac{1}{m-1}\sum_{i=1}^{m}(X_i - \bar{X})^2 \quad \text{und} \quad S^2_Y = \frac{1}{n-1}\sum_{i=1}^{n}(Y_i - \bar{Y})^2\,.$$

Ablehnung von H_0, falls

(a) $|T| > t_{m+n-2,1-\frac{\alpha}{2}}$; (b) $T > t_{m+n-2,1-\alpha}$; (c) $T < -t_{m+n-2,1-\alpha}$.

Welch-Test

Test auf Gleichheit der Erwartungswerte μ_X und μ_Y zweier Verteilungen bei unbekannten (und möglicherweise verschiedenen) Varianzen (**Varianzheterogenität**, „Behrens-Fisher-Problem“).

Annahme:
$X_1, \ldots, X_m$ i.i.d., und $X_i \sim \mathrm{N}(\mu_X, \sigma_X^2)$;
$Y_1, \ldots, Y_n$ i.i.d., und $Y_i \sim \mathrm{N}(\mu_Y, \sigma_Y^2)$; σ_X^2, σ_Y^2 unbekannt.

Hypothese:

(a) $H_0 : \mu_X = \mu_Y$; (b) $H_0 : \mu_X \leq \mu_Y$; (c) $H_0 : \mu_X \geq \mu_Y$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_m, Y_1, \ldots, Y_n) = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_X^2}{m} + \frac{S_Y^2}{n}}},$$

welche approximativ t_ν-verteilt ist, falls $\mu_X = \mu_Y$, wobei

$$\nu = \frac{\left(\frac{S_X^2}{m} + \frac{S_Y^2}{n}\right)^2}{\frac{(S_X^2/m)^2}{m-1} + \frac{(S_Y^2/n)^2}{n-1}}.$$

Ablehnung von H_0, falls

(a) $|T| > t_{\nu,1-\frac{\alpha}{2}}$; (b) $T > t_{\nu,1-\alpha}$; (c) $T < -t_{\nu,1-\alpha}$.

F-Test

Test auf Gleichheit der Varianzen zweier Normalverteilungen (wie es beim Zwei-Stichproben-t-Test vorausgesetzt wird).

Annahme:
$X_1, \ldots, X_m$ i.i.d., und $X_i \sim \mathrm{N}(\mu_X, \sigma_X^2)$;
$Y_1, \ldots, Y_n$ i.i.d., und $Y_i \sim \mathrm{N}(\mu_Y, \sigma_Y^2)$; μ_X, μ_Y unbekannt.

Hypothese:

(a) $H_0 : \sigma_X^2 = \sigma_Y^2$; (b) $H_0 : \sigma_X^2 \leq \sigma_Y^2$; (c) $H_0 : \sigma_X^2 \geq \sigma_Y^2$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_m, Y_1, \ldots, Y_n) = \frac{S_X^2}{S_Y^2},$$

welche $F_{m-1,n-1}$-verteilt ist, falls $\sigma_X^2 = \sigma_Y^2$.

Ablehnung von H_0, falls

(a) $T < F_{m-1,n-1,\frac{\alpha}{2}}$ oder $T > F_{m-1,n-1,1-\frac{\alpha}{2}}$; (b) $T > F_{m-1,n-1,1-\alpha}$; (c) $T < F_{m-1,n-1,\alpha}$.

III.2.6 Ergänzung: Bivariate Normalverteilung und Korrelationstest

In den Abschnitten II.4.4 und II.4.5 haben wir die (univariate) Normalverteilung und einige ihrer Eigenschaften kennengelernt. Eine $\mathrm{N}(\mu, \sigma^2)$-verteilte Zufallsvariable X ist dabei durch die Dichte

$$f_{\mu,\sigma^2}(x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left(-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right)$$

bestimmt. Nun wollen wir wieder, wie in den Abschnitten II.4.2 und II.4.3 schon betrachtet, zum Fall zweier gemeinsam stetig verteilter Zufallsvariablen (X, Y) übergehen. Ist die gemeinsame stetige Dichte f_{XY} gegeben durch

$$f_{XY}(x,y) =$$

$$\frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \cdot \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_X)^2}{\sigma_X^2} + \frac{(y-\mu_Y)^2}{\sigma_Y^2} - 2\rho\frac{(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y}\right)\right],$$

wobei $\mu_X, \mu_Y \in \mathbb{R}$, $\sigma_X, \sigma_Y > 0$ und $\rho \in [-1; 1]$ sind, so nennen wir (X, Y) *bivariat normalverteilt.*

Eigenschaften der bivariaten Normalverteilung:

- Es sind $E[X] = \mu_X$ und $E[Y] = \mu_Y$,
- ferner $V[X] = \sigma_X^2$ und $V[Y] = \sigma_Y^2$,
- und die Korrelation zwischen X und Y gegeben durch $\rho_{XY} = \rho$.
- X und Y sind unabhängig genau dann, wenn sie unkorreliert sind.

Achtung: Die letztgenannte Eigenschaft gilt ansonsten i. Allg. nicht!
Allgemein gilt nur „unabhängig $\Rightarrow$ unkorreliert“.

Im vorigen Abschnitt III.2.4 hatten wir den χ^2-Test auf Unabhängigkeit kennengelernt, der bei zwei Zufallsvariablen X und Y die Nullhypothese „H_0 : X und Y sind unabhängig“ untersucht. Das eben präsentierte Resultat impliziert, dass man im Fall von bivariat normalverteilten Zufallsvariablen X, Y alternativ auch einen Test auf Basis des empirischen Korrelationskoeffizienten r_{XY}, vgl. Abschnitt I.3.3, konstruieren kann, um die Nullhypothese „H_0 : X und Y sind unabhängig“ zu überprüfen.

Korrelationstest

Annahme:
$(X_1, Y_1), \ldots, (X_n, Y_n)$ i.i.d. bivariat normalverteilt.

Hypothese:

(a) $H_0 : \rho_{XY} = \rho_0$; (b) $H_0 : \rho_{XY} \geq \rho_0$; (c) $H_0 : \rho_{XY} \leq \rho_0$.

Entscheidungsregel: Betrachte als Teststatistik

$$Z(X_1, \ldots, Y_n) = \frac{\sqrt{n-3}}{2} \cdot \left(\ln\frac{1+r_{XY}}{1-r_{XY}} - \ln\frac{1+\rho_0}{1-\rho_0}\right),$$

welche approximativ $\mathrm{N}(0,1)$-verteilt ist, falls $\rho_{XY} = \rho_0$.

Ablehnung von H_0, falls

(a) $|Z| > z_{1-\frac{\alpha}{2}}$; (b) $Z < -z_{1-\alpha}$; (c) $Z > z_{1-\alpha}$.

Dieser Test hat dann das (approximative) Niveau α.

Hinweis: Diese Approximation ist für praktische Bedürfnisse als hinreichend zu erachten, wenn $n > 25$ ist.

für den wichtigen Spezialfall $\rho_0 = 0$, d.h. wenn X und Y auf Unkorreliertheit und damit de facto auf Unabhängigkeit (da bivariat normalverteilt!) hin untersucht werden, gibt es folgende Alternative:

Annahme:
$(X_1, Y_1), \ldots, (X_n, Y_n)$ i.i.d. bivariat normalverteilt.

Hypothese:

(a) $H_0 : \rho_{XY} = 0$; (b) $H_0 : \rho_{XY} \geq 0$; (c) $H_0 : \rho_{XY} \leq 0$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, Y_n) = \sqrt{n-2} \cdot \frac{r_{XY}}{\sqrt{1 - r_{XY}^2}},$$

welche t_{n-2}-verteilt ist, falls $\rho_{XY} = 0$.

Ablehnung von H_0, falls

(a) $|T| > t_{n-2,1-\frac{\alpha}{2}}$; (b) $T < -t_{n-2,1-\alpha}$; (c) $T > t_{n-2,1-\alpha}$.

Dieser Test hat dann das Niveau α.

Konfidenzintervall für die Korrelation

Die oben angeführten Eigenschaften der Teststatistik $Z(X_1, \ldots, Y_n)$ des Korrelationstests legen nahe, ein approximatives Konfidenzintervall für ρ_{XY} zum Niveau $1 - \alpha$ wie folgt zu konstruieren:

Sei $f(z) := (e^{2z} - 1)/(e^{2z} + 1)$, d.h. es gelte $f\left(\frac{1}{2} \ln \frac{1+\rho}{1-\rho}\right) = \rho$. Das approximative Konfidenzintervall für ρ_{XY} ist gegeben durch

$$I(X_1, \ldots, Y_n) = \left[f\left(\frac{1}{2} \ln \frac{1 + r_{XY}}{1 - r_{XY}} - \frac{z_{1-\alpha/2}}{\sqrt{n-3}}\right) ; f\left(\frac{1}{2} \ln \frac{1 + r_{XY}}{1 - r_{XY}} + \frac{z_{1-\alpha/2}}{\sqrt{n-3}}\right)\right].$$

III.2.7 Ergänzung: Nichtparametrische Testverfahren

Die in den Abschnitten III.2.2 und III.2.5 besprochenen Ein- und Zwei-Stichproben-Tests setzen zumindest bei kleinen Stichprobenumfüngen eine Normalverteilung der betrachteten X- und Y-Merkmale voraus. In vielen Situationen ist diese Annahme aber nicht einmal näherungsweise erfüllt, so weisen etwa Lebensdauern häufig eine stark unsymmetrische Verteilung (z. B. Exponentialverteilung) auf. für derartige Fälle wurden sog. *nichtparametrische Tests* (auch *verteilungsfreie Tests*) entwickelt, die beispielsweise nur ganz allgemein verlangen, dass die untersuchten Merkmale stetig sind, die aber nicht fordern, dass die Merkmale einer speziellen parametrischen Verteilungsfamilie folgen. Solche nichtparametrischen Tests wollen wir im Folgenden exemplarisch für den Ein-Stichproben-Fall betrachten.

Vorzeichentest

In Analogie zum Gauß- oder t-Test soll der Vorzeichentest eine Hypothese bzgl. des Medians $Med[X] = x_{0.5}$ einer stetig verteilten Zufallsvariable X untersuchen. Abgesehen von der Forderung nach Stetigkeit werden keine weiteren Verteilungsannahmen formuliert. Die Idee ist es nun zu zählen, wieviele der i.i.d. Stichprobenvariablen $X_1, \ldots, X_n$ unterhalb des hypothetischen Medianwertes m_0 liegen; gilt nämlich tatsächlich $Med[X] = m_0$, so ist diese Anzahl gerade binomialverteilt gemäß $\mathrm{Bin}(n, 0.5)$.

Test auf den Median m einer Verteilung.

Annahme:
$X_1, \ldots, X_n$ i.i.d. mit stetiger Verteilung.

Hypothese:

(a) $H_0 : Med[X] = m_0$; (b) $H_0 : Med[X] \leq m_0$; (c) $H_0 : Med[X] \geq m_0$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \big|\{X_i \mid X_i < m_0\}\big|,$$

welche $\mathrm{Bin}(n, 0.5)$-verteilt ist, falls $Med[X] = m_0$.
für $n \geq 25$ ist T approximativ $\mathrm{N}(\frac{n}{2}, \frac{n}{4})$-verteilt, falls $Med[X] = m_0$.

Ablehnung von H_0, falls

(a) $T \leq b_{\frac{\alpha}{2}}$ oder $n - T \leq b_{\frac{\alpha}{2}}$; (b) $T \leq b_\alpha$; (c) $n - T \leq b_\alpha$.

Die Testschranke b_β wird auf Basis der Verteilungsfunktion $F_{n,0.5}(b)$ der $\mathrm{Bin}(n, 0.5)$-Verteilung wie folgt bestimmt: $F_{n,0.5}(b_\beta) \leq \beta < F_{n,0.5}(b_\beta + 1)$. für $n \geq 25$ approximiert man b_β durch das β-Quantil der $\mathrm{N}(\frac{n}{2}, \frac{n}{4})$-Verteilung.

Bemerkung: Messwerte $X_i = m_0$ (sollten bei stetiger Verteilung ja nur mit Wahrscheinlichkeit 0 auftreten) sagen nichts über die Richtung der Abweichung („Vorzeichen") aus und werden deshalb in der Praxis ignoriert, d.h. die Stichprobe wird entsprechend vor Ausführung des Tests reduziert.

Der Vorzeichentest kann für alle stetigen Verteilungen verwendet werden. Diesen Vorteil erkauft man sich aber dadurch, dass im Fall einer tatsächlich vorliegenden Normalverteilung die Güte des Vorzeichentests schlechter ist als z. B. die des Gauß-Tests (bei einer Normalverteilung stimmen Erwartungswert und Median überein). Dies illustriert folgendes Beispiel (Vorzeichentest grau-gestrichelt, Gauß-Test schwarz):

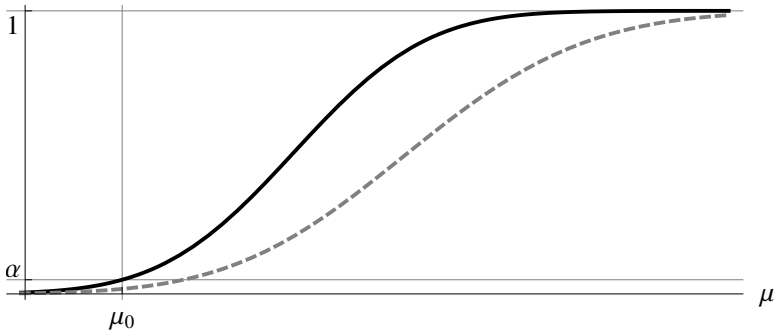

Wilcoxon-Vorzeichen-Rang-Test

Der Vorzeichentest ist zwar verteilungsfrei, aber er nutzt aus dem vorliegenden Datensatz lediglich die Information, ob die Datenwerte über oder unter dem hypothetischen Median m_0 liegen. Um mehr der im Datensatz enthaltenen Information zu nutzen, basieren viele nichtparametrische Testverfahren auf sog. *Rängen*, die auf Basis der vorliegenden Daten berechnet werden. Sind $y_1, \ldots, y_n$ paarweise verschiedene, reelle Zahlen, so ist der *Rang* des Wertes y_i definiert als dessen Position in der aufsteigend geordneten Reihe der y-Werte. So erhält y_i z. B. den Rang 1, wenn es der kleinste Wert in $y_1, \ldots, y_n$ ist, den Rang 2, wenn es der zweitkleinste Wert in $y_1, \ldots, y_n$ ist, etc.

Beispielhaft wird dieser Ansatz anhand des Wilcoxon-Vorzeichen-Rang-Tests vorgestellt, dessen Teststatistik $T(X_1, \ldots, X_n)$ folgendermaßen konstruiert wird:

1. Berechne die Differenzen $D_i = X_i - m_0$ für $i = 1, \ldots, n$.

2. Ordne den absoluten Differenzen $|D_1|, \ldots, |D_n|$ Ränge zu, Notation: $\mathrm{Rang}\big(|D_i|\big)$.

3. Bezeichnet $\mathbf{1}_A$ die Indikatorfunktion, die den Wert 1 annimmt, wenn das Ereignis A eintritt, und den Wert 0, wenn es nicht eintritt, so definiere

$$T(X_1, \ldots, X_n) \;:=\; \sum_{i=1}^{n} \mathbf{1}_{\{D_i>0\}} \cdot \mathrm{Rang}\big(|D_i|\big),$$

d.h. T ist die Summe der Ränge zu *positiven* Differenzen D_i.

Wilcoxon-Vorzeichen-Rang-Test

Test auf den Median m einer Verteilung.

Annahme:
$X_1, \ldots, X_n$ i.i.d. mit stetiger und symmetrischer Verteilung.

Hypothese:

(a) $H_0 : Med[X] = m_0$; (b) $H_0 : Med[X] \leq m_0$; (c) $H_0 : Med[X] \geq m_0$.

Entscheidungsregel: Betrachte als Teststatistik

$$T(X_1, \ldots, X_n) = \sum_{i=1}^{n} \mathbf{1}_{\{D_i>0\}} \cdot \mathrm{Rang}\big(|D_i|\big),$$

welche für $n > 20$ approximativ $\mathrm{N}(\frac{n(n+1)}{4}, \frac{n(n+1)(2n+1)}{24})$-verteilt ist, falls $Med[X] = m_0$.

Ablehnung von H_0, falls

(a) $T < w_{\frac{\alpha}{2}}$ oder $T > w_{1-\frac{\alpha}{2}}$; (b) $T > w_{1-\alpha}$; (c) $T < w_\alpha$,

wobei $w_\beta := \frac{n(n+1)}{4} + \sqrt{\frac{n(n+1)(2n+1)}{24}} \cdot z_\beta$.
für kleine Stichproben sollten die Quantile w_β auf Basis der exakten Verteilung von T bestimmt werden (mit Hilfe statistischer Software oder entsprechender Tabellen).
Gelegentlich kann es vorkommen, dass mehrere Absolutdifferenzen den gleichen Wert annehmen, d.h. dass $|D_i| = |D_j|$ für $i \neq j$ ist. In einem solchen Fall kann man die Werte $|D_1|, \ldots, |D_n|$ nicht streng aufsteigend ordnen, man spricht von *Bindungen* („*ties*“). In diesem Fall vergibt man allen betroffenen $|D_i|$ denselben *mittleren Rang*, d.h. man ignoriert erst einmal die Bindungen und vergibt fortlaufend Ränge, bildet dann aber den Mittelwert über all jene Ränge, die zur gleichen Bindung gehören.

Ferner kann es vorkommen (genau wie beim Vorzeichentest), dass manche der X_i exakt mit m_0 übereinstimmen, was zur Differenz $D_i = 0$ führen würde. Derartige Werte werden vor Ausführung des Tests aus der Stichprobe entfernt.

Beispiel:
Es soll die Hypothese $H_0 : Med[X] \leq 2.2$ auf dem Niveau $\alpha = 0.05$ getestet werden, die vorliegenden Daten $x_1, \ldots, x_6$ seien $2.4, 2.8, 2.2, 2.1, 2.4, 2.9$. Wir erstellen folgende Tabelle:

i	1	2	3	4	5	6
x_i	2.4	2.8	2.2	2.1	2.4	2.9
$d_i = x_i - 2.2$	0.2	0.6	0	−0.1	0.2	0.7
$\lvert d_i \rvert$	0.2	0.6	0	0.1	0.2	0.7

Der dritte Wert führt zur Differenz 0 und muss deshalb von der weiteren Analyse ausgeschlossen werden, d.h. der Datensatz reduziert sich auf den Umfang $n = 5$. führen wir zuerst den Vorzeichentest aus. Genau eines der x_i ist kleiner $m_0 = 2.2$, d.h. die Teststatistik T_{V} des

Vorzeichentests nimmt den Wert 1 an. Die Testschranke $b_{0.05}$ wird auf Basis der $\mathrm{Bin}(5, 0.5)$-Verteilung bestimmt:

k	0	1	2	3	4	5
$p_{5,0.5}(k)$	0.03125	0.15625	0.3125	0.3125	0.15625	0.03125
$F_{5,0.5}(k)$	0.03125	0.1875	0.5	0.8125	0.96875	1

Also ist $b_{0.05} = 0$, und da $T_{\mathrm{V}} = 1 > 0 = b_{0.05}$ ist, kann die Hypothese $H_0 : Med[X] \leq 2.2$ nicht abgelehnt werden.

führen wir nun den Wilcoxon-Vorzeichen-Rang-Test aus. Die aufsteigend geordneten Werte der $|d_i| \neq 0$ sind $0.1, 0.2, 0.2, 0.6, 0.7$, hierbei bilden die beiden Werte 0.2 eine Bindung. Ignoriert man diese für einen Moment, so würden wir die Ränge 2 und 3 vergeben, deren Mittelwert 2.5 ist; also erhält jedes der 0.2 den mittleren Rang 2.5. Insgesamt können wir obige Tabelle also wie folgt ergänzen:

i	1	2	4	5	6
x_i	2.4	2.8	2.1	2.4	2.9
$d_i = x_i - 2.2$	0.2	0.6	-0.1	0.2	0.7
$\lvert d_i \rvert$	0.2	0.6	0.1	0.2	0.7
$\mathrm{Rang}(\lvert d_i \rvert)$	2.5	4	1	2.5	5
$\mathbf{1}_{\{d_i > 0\}}$	1	1	0	1	1

Somit berechnet sich die Statistik T_{W} des Wilcoxon-Vorzeichen-Rang-Tests zu $2.5+4+2.5+5 = 14$. für $n = 5$ ist $w_{0.95} = 13$ (mit der Normalapproxmation erhielte man $w_{0.95} \approx 13.6$), siehe etwa die Tabelle in [1, Anhang F]. Da $T_{\mathrm{W}} = 14 > 13 = w_{0.95}$ ist, muss die Hypothese $H_0 : Med[X] \leq 2.2$ abgelehnt werden.

Literatur

[1] L. Fahrmeir, R. Künstler, I. Pigeot, G. Tutz, Statistik, 6. Auflage, Springer Verlag, 2007.

[2] L. Fahrmeir, R. Künstler, I. Pigeot, G. Tutz, A. Caputo, S. Lang, Arbeitsbuch Statistik, 4. Auflage, Springer Verlag, 2004.

[3] W. Linde: Stochastik für das Lehramt. De Gruyter

[4] N. Henze: Stochastik für Einsteiger. Springer.

Weitere Literatur

[5] G. Bamberg, F. Baur, M. Krapp, Statistik, 13. Auflage, R. Oldenbourg Verlag, 2007.

[6] J. Bleymüller, G. Gehlert, H. Gülicher, Statistik für Wirtschaftswissenschaftler, 14. Auflage, Verlag Vahlen, 2004.

[7] M. Falk, R. Becker, F. Marohn, Angewandte Statistik – Eine Einführung mit Programmbeispielen in SAS, Springer Verlag, 1995. (Nachdruck aus dem Jahr 2004)

[8] L. Sachs, J. Hedderich, Angewandte Statistik: Methodensammlung mit R, 12. Auflage, Springer Verlag, 2006.

[9] J. Schira, Statistische Methoden der VWL und BWL: Theorie und Praxis, 2. Auflage, Pearson Studium, 2005.

[10] C. Weigand, Statistik mit und ohne Zufall, Physica Verlag, 2006.